

Analyse von Pflanzenwachstum auf Basis von 3D-Punktwolken

Masterarbeit
zur Erlangung des Grades *Master of Science*

an der
Hochschule Niederrhein
Fachbereich Elektrotechnik und Informatik
Studiengang *Informatik*

vorgelegt von
Jakob Görner
1003660

Datum: 22. November 2021

Prüfer: Prof. Dr. Regina Pohle-Fröhlich
Zweitprüfer: Prof. Dr. Christoph Dalitz

Eidesstattliche Erklärung

Name: Jakob Görner

Matrikelnr.: 1003660

Titel: Analyse von Pflanzenwachstum auf Basis von 3D-Punktwolken

Ich versichere durch meine Unterschrift, dass die vorliegende Arbeit ausschließlich von mir verfasst wurde. Es wurden keine anderen als die von mir angegebenen Quellen und Hilfsmittel benutzt.

Die Arbeit besteht aus 44 Seiten.

Mönchengladbach, 22. November 2021

Unterschrift

Danksagungen

An dieser Stelle möchte ich mich noch bei allen jenen bedanken die mich während dieser Arbeit unterstützt haben. Zuerst möchte ich mich bei meiner betreuenden Profes- sorin Frau Prf. Dr. Pohle-Fröhlich bedanken die mir in vielen Sitzungen und auch bei der Literatur-Recherche immer wieder große Hilfe geleistet hat. Des Weiteren möchte ich mich bei Herr Lentzen für seine unermüdliche Hilfe und Ratschläge beim Training von PointNet++ bedanken. Auch bei meiner Familie und meiner Freundin möchte ich mich für das fleißige Korrekturlesen ganz herzlich bedanken.

Zusammenfassung

In dieser Arbeit soll eine Anwendung zum Analysieren von Pflanzen-Wachstum und weiteren Merkmalen des Wachstumsprozesses einer Pflanze erstellt werden. Es soll aus einer Reihe von Bildern einer Pflanze, die mit einer gängigen Smartphone-Kamera aufgenommen sind, eine Punktwolke erzeugt werden. Aus der Punktwolke sollen die Punkte die zur Pflanze gehören extrahiert werden. Die extrahierten Punkte werden zur weiteren Analyse in Stamm- und Blatt-Punkte segmentiert. Des Weiteren sollen Werte, wie das Wachstum der Pflanze, ermittelt werden. Hierzu müssen mehrere Punktwolken über Zeit miteinander verglichen werden. Die Anwendung soll mit möglichst wenig Bildern auskommen um den Datentransfer zu minimieren.

Abstract

Development of an application made to analyse plant growth over time and further growth characteristics of a plant represented as a point cloud. The point cloud will be generated out of a set of images of the plant, taken with a common smartphone. First the points representing the plant have to be extracted. After this the remaining point cloud should be splitted in leave and stem points to count leaves and analyse the stem further. Also other characteristics such as the hight should be analysed. For this reason multiple point clouds have to be compared over time. The application should use as few pictures as possible to reduce the amount of transferred data.

Inhaltsverzeichnis

1 Motivation	3
2 Stand der Technik	4
2.1 Generierung einer 3D Punktwolke aus Bildern	4
2.2 Segmentierung von 3D-Punktwolken	9
2.3 Registrierung von 3D-Punktwolken	11
3 Realisierung	16
3.1 Architektur	16
3.2 Umsetzung Generierung einer 3D Punktwolke aus Bildern	17
3.3 Umsetzung Registrierung zweier Punktwolken	18
3.4 Umsetzung Segmentierung	19
3.5 Umsetzung Server	20
3.6 Umsetzung Jobs und Pipelines	22
4 Ergebnisse	26
4.1 Vergleich von Verfahren zur Generierung von 3D-Punktwolken auf Basis von Bildern	26
4.2 Vergleich von Verfahren zur Registrierung von 3D-Punktwolken	30
4.3 Vergleich von Verfahren zur Segmentierung von Pflanzen auf 3D-Punktwolken	32
5 Fazit und Ausblick	39
Literatur	42

1 Motivation

Diese Arbeit wird im Rahmen eines Projekts der Hochschule Niederrhein (Krefeld, Deutschland) mit den Universitäten Makerere University (Kampala, Uganda) und Central University of Technology (Bloemfontein, Südafrika) durchgeführt. Im Rahmen dieser Arbeit soll eine Anwendung entstehen, die in den beiden Ländern für Kleinbauern zum Einsatz kommen soll. Die Anwendung soll mit nichtinvasiven Methoden zur Unterstützung bei der selektiven Züchtung eingesetzt werden, um Erträge und somit auch Gewinnmargen zu erhöhen und damit zur Ernährungssicherheit beizutragen. Dies ist nötig, da es im Rahmen der derzeitigen Klimaveränderungen zu höheren Ernteausfällen durch Dürren kommt [1], die durch reinen Einsatz von indigenem Wissen nicht zu kompensieren sind.

Um diesem Ziel näher zu kommen soll in dieser Arbeit eine Software entwickelt werden, die es erlaubt Daten über den Wachstums-Prozess von Pflanzen zu sammeln. Diese soll als Grundlage für weitere Analysen, wie das frühe Erkennen von Krankheitsbildern, Ertragsschätzungen oder Erkennen unzureichender Wachstumsraten der Pflanzen, dienen.

Ziel ist es also eine Software zu schaffen, die es ermöglicht aus Bildern von Pflanzen 3D Punktwolken (Punktwolken) zu generieren und diese zu analysieren. Es soll mit der zu entwickelnden Anwendung möglich sein, Aussagen über das Wachstum über Zeit, die Entwicklung der Blätter und der Stämme zu treffen. Mit diesen Daten sind Analysen möglich, die auf das Wachstum einer Pflanze unter bestimmten Bedingungen schließen lassen. Hierbei gibt es besondere Anforderungen an den Prozess der Datengewinnung und Übertragung. Zum einen muss der Betrieb kostengünstig sein - das betrifft insbesondere den Endverbraucher. Der Endverbraucher sollte möglichst wenig Datenmengen an den Server, der die Rechenkapazität bereit stellt, übertragen müssen. Das soll die Kosten auf Seiten der Kleinbauern gering halten. Des Weiteren muss die Datengewinnung mit einem Mobiltelefon oder einer anderen Kamera möglich sein. Spezielle Aufnahmegeräte, wie ein LIDAR-Scanner, die den Kleinbauern nicht schon zur Verfügung stehen, sollen nicht nötig sein.

2 Stand der Technik

Drei Kernprobleme sollen betrachtet werden, die für den Erfolg dieser Arbeit gelöst werden müssen. Zuerst muss aus einer Menge an Bildern eine Punktwolke generiert werden. Danach muss diese Punktwolke segmentiert werden, um den Hintergrund zu entfernen und die einzelnen Teile der Pflanze, wie Blätter und Stiele, zu erkennen und weiter zu analysieren. Zuletzt müssen zwei Punktwolken einer Pflanze zu verschiedenen Zeitpunkten miteinander registriert werden, um Aussagen über das Wachstum einer Pflanze treffen zu können.

2.1 Generierung einer 3D Punktwolke aus Bildern

Generell kann man zwischen zwei Methoden der Generierung von Punktwolken unterscheiden, die jeweils verschiedene Verfahren beziehungsweise Techniken anwenden.

Die erste Methode nutzt Hardware wie LIDAR-Scanner [2] um Punktwolken direkt zu erzeugen. Es gibt eine Reihe von Sensoren, die das ermöglichen. Da der Großteil der Sensoren aus Kostengründen nicht in Frage kommt, sei hier nur der RGB-D-Sensor erwähnt. Dieser liefert neben den Farbwerten für ein Bild auch eine Tiefeninformation für jedes Pixel. In einigen Smartphone-Modellen wird bereits ein solcher Sensor verbaut [3]. Ein Nachteil bei RGB-D Sensoren ist aber, dass sie anfällig für Änderungen der Lichtverhältnisse sind, was gerade im Außenbereich häufig vorkommt.

Die andere Methode ist Structure from Motion (SfM) [4], bei der die Punktwolke aus Bildern einer Szene aus verschiedenen Perspektiven generiert wird. Allgemein wird in den zugrundeliegenden Bildern nach Merkmalen (Feature) gesucht, die robust gegen Translation, Rotation, Skalierung und Beleuchtung sein sollten. Generell ist das Ermitteln von geeigneten Features in die Feature-Erkennung und die Feature-Beschreibung zu unterteilen. Bei der Feature-Erkennung müssen geeignete Punkte im Bild als Kandidaten für Feature-Punkte ermittelt werden. Sind geeignete Kandidaten gewählt worden, müssen diese beschrieben werden, also ein Deskriptor für den Punkt gefunden werden. Hier kann man die bekanntesten Umsetzungen in zwei Bereiche unterteilen. Umsetzungen wie Scale Invariant Feature Transformation (SIFT) [5] und Speeded Up Robust Features (SURF) [6] beschreiben einen Feature-Punkt als einen Vektor, der aus Gradienten-Histogrammen um den Punkt herum gebildet wird. Binary Robust Independent Elementary Features (BRIEF) [7] und FAST and Rotated BRIEF (ORB) [8] nutzen hingegen einen binären Deskriptor um den Feature-Punkt zu beschreiben. Hierbei werden die Intensitäts-Differenzen bestimmter Punkt-Paare in einem Bereich um den Punkt mit einem Schwellwert verglichen und so der binäre Deskriptor gebildet.

SIFT [5] ist der wohl bekannteste Ansatz und wird häufig als Goldstandard verwendet, um Verfahren miteinander zu vergleichen. Es hat allerdings den Nachteil, dass es zu langsam für Echtzeitanwendungen ist. SIFT ermittelt die Kandidaten-Punkte im Kern mittels des Difference of Gaussians Verfahrens (DoG), welches aus drei Schritten besteht. Im ersten Schritt wird auf das Bild in verschieden starken Stufen ein Weichzeichner (diskreter Gauß-Filter) angewandt. Damit liegt das Bild mit zunehmend niedrigerem Kontrast vor. Zwischen den einzelnen Kontraststufen wird die Differenz ermittelt. Liegen die Differenzen vor kann nach Extrempunkten in den Differenzen gesucht werden.

Hierbei wird jedes Pixel im Bild mit seinen direkten Nachbarn und denen in der vorherigen und nachfolgenden Stufe verglichen. Ist das Pixel ein Extrempunkt, wird es als Kandidat gewählt. DoG wird auf mehreren Skalierungen des Bildes angewandt um Skalierungs-Invarianz zu erreichen. Im Anschluss werden die Kandidaten gefiltert. Kandidaten, die einen niedrigen Intensitätswert haben oder eine Kante darstellen, werden hierbei ausgeschlossen. Sind die Positionen der Features bekannt, kann der Feature-Vektor f für den Punkt p ermittelt werden. Um den Deskriptor für den Punkt p zu berechnen werden zwei Größen benötigt. Zum einen die Skalierung, in der der Punkt ermittelt wurde - diese ist bereits bekannt - und zum anderen die Orientierung des Punktes. Um diese zu bestimmen werden in einem Bereich um den Punkt p die Gradienten berechnet und in ein Histogramm abgetragen. Der Histogramm-Eintrag (Bin) mit dem größten Wert entscheidet die Orientierung des Punktes. Sind Skalierung und Orientierung bekannt, wird auf Basis der beiden ein Bereich gewählt und in einen 16×16 großen Bereich skaliert. Dieser Bereich wird in 16 gleichgroße Bereiche unterteilt, für die jeweils ein Histogramm gebildet wird. Die Bins der Histogramme beschreiben in 8 diskreten Stufen die Orientierung der Punkte im jeweiligen Bereich. Die einzelnen Punkte tragen die Stärke des Gradienten im jeweiligen Bin des Histogramms ab. Diese Histogramme bilden den Feature-Vektor f , der für den Vergleich genutzt wird.

SURF [6] ist ähnlich aufgebaut wie SIFT, nur wird der genutzte Gauss-Filter durch Box-Filter, die besonders effizient berechnet werden, approximiert. Des Weiteren wird der Feature-Vektor anders gebildet. Mit beiden Anpassungen wird eine bessere Leistung erreicht. Bei der Approximation des Gauss-Filters wird zuerst das Integral-Bild I_Σ (Gleichung 1) aus den Intensitätswerten I des Bildes berechnet.

$$I_\Sigma(x, y) = \sum_{i=0}^{i \leq x} \sum_{j=0}^{j \leq y} I(i, j) \quad (1)$$

Ist I_Σ bekannt, kann die Intensitäts-Summe eines beliebigen rechteckigen Ausschnitts sehr effizient berechnet werden. Hierzu werden nur die Werte aus I_Σ für die Eckpunkte $P_1 - P_4$ eines Ausschnittes D benötigt. Die Fläche für D lässt sich dann mit $f(D)$ (Gleichung 2) effizient berechnen.

$$f(D) = I_\Sigma(x_{P_1}, y_{P_1}) + I_\Sigma(x_{P_4}, y_{P_4}) - I_\Sigma(x_{P_2}, y_{P_2}) - I_\Sigma(x_{P_3}, y_{P_3}) \quad (2)$$

Um den Gauss-Filter mit Box-Filtern zu approximieren, wird die Determinante der Hesse-Matrix genutzt. Um die approximierte Hesse-Matrix für einen Punkt p mit der Skalierung s zu bilden, muss man die zweite Ableitung der Gauss-Funktion nach x , y und xy mit Box-Filtern approximieren (Siehe Gleichung 3).

$$H_{approx.}(p, s) = \begin{pmatrix} D_{xx}(p, s) & D_{xy}(p, s) \\ D_{xy}(p, s) & D_{yy}(p, s) \end{pmatrix} \quad (3)$$

Die Determinante der Hesse-Matrix kann dann wie in Gleichung 4 berechnet werden, wobei $w \approx 0.9$ ist und den Fehler der Approximation minimieren soll.

$$\det(H_{approx.}) = D_{xx}D_{yy} - (wD_{xy})^2 \quad (4)$$

Ein Beispiel für die Box-Filter ist in Abbildung 1 zu sehen. Sowohl die verschiedenen Gauss-Stufen als auch die verschiedenen Skalierungs-Stufen werden durch ein Vergrößern der Filter-Maske erreicht. Der Deskriptor wird in zwei Schritten berechnet. Zu-

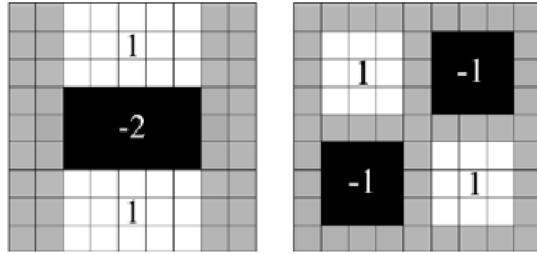


Abbildung 1: Box-Filter für zweite Ableitung nach y (links) und Ableitung nach xy (rechts). [6]

erst wird die Hauptorientierung des Punktes berechnet. Dann wird auf dieser und der Skalierung basierend ein Bereich in dem Bild gewählt und in 16 Bereiche unterteilt. Für jeden der 16 Bereiche wird die Intensität der Punkte in einem 4 Bin großen Histogramm abgetragen, was zu einem Feature-Vektor der Größe 64 führt.

BRIEF [7] lässt die Frage der Wahl der korrespondierenden Punkt-Paare, die für den Intensitäts-Vergleich nötig sind, offen. Die Autoren schlagen aber einige Möglichkeiten vor, wobei die zufällig generierten Paare die besten Ergebnisse liefern [7]. Ist die Wahl der Punkt-Paare abgeschlossen, kann der binäre Deskriptor gebildet werden. Dafür wird für jedes Paar die Differenz der Intensität zwischen den beiden Punkten ermittelt. Liegt die Differenz unter einem Schwellwert, wird die Position für das Paar im binären Deskriptor auf null gesetzt, ansonsten auf eins. Vorteil an BRIEF ist, dass es weniger rechenaufwändig ist, verglichen mit SIFT. Nachteil an der Umsetzung ist, dass die Rotation der Bilder nicht beachtet wird und BRIEF daher nicht rotationsinvariant ist.

ORB [8] geht diesen Nachteil an, indem zuerst das Massezentrum des Bildes C (Gleichung 6) und dessen Orientierung θ (Gleichung 7) über die Momente m_{00} , m_{10} und m_{01} (Gleichung 5) berechnet wird. Mit diesen Parametern werden die Koordinaten der Paare umgeformt, um so der Anfälligkeit für Rotation entgegen zu wirken. Des Weiteren liefert ORB eine gelernte Paar-Auswahl von 256 Paaren, die dahingehend optimiert ist, dass die Paare unkorreliert sind und eine hohe Varianz aufweisen.

$$m_{pq} = \sum_{x,y} x^p y^q I(x, y) \quad (5)$$

$$C = \left(\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}} \right) \quad (6)$$

$$\theta = \text{atan2}(m_{01}, m_{10}) \quad (7)$$

Wurden die Features ermittelt, müssen korrespondierende Features zwischen den Bildern ermittelt werden. Hierzu muss die Distanz zwischen den Deskriptoren einzelner Features verglichen werden. Der korrespondierende Punkt des Feature-Punktes ist der mit der geringsten Distanz. Um falsche Paare zu vermeiden, können Paare unter einem gewissen Schwellwert ausgeschlossen werden, genau so wie Paare, bei denen der

nächstbeste korrespondierende Punkt eine sehr ähnliche Distanz aufweist. Das lässt darauf schließen, dass es sich um einen Feature-Punkt handelt, der sich in einem sich wiederholenden Muster befindet. Um aus den korrespondierenden Bildpaaren auf die Positionen der Kameras zu schließen, wird die Fundamental-Matrix $F = K_1^{-1T} E K_2^{-1}$ für jedes Bildpaar ermittelt. K_1 und K_2 sind die beiden Kalibrierungs-Matrizen der Kameras und E ist die Essential-Matrix, welche die Bewegung und Rotation der Kamera beschreibt. Ist die Kalibrierung der Kamera bekannt, kann direkt E berechnet werden. F beschreibt die Kamera-Bewegung und Rotation von einem zum anderen Bild, hat den Rang 2 und bezieht dabei die Kalibrierung der Kameras mit ein. Um F zu ermitteln werden mindestens acht korrespondierende Features $(p_{A1}, p_{B1}) \dots (p_{A8}, p_{B8})$ zwischen den Bildern A und B eines Paars benötigt. Die Bildpunkte p_{Ai} und p_{Bi} der Paare sind dabei nicht in Pixel-Koordinaten, sondern relativ zum Bild-Ebenen-Zentrum angegeben. Die Koordinaten liegen also im Bereich $[-1, 1]$. Da es sich um homogene Koordinaten handelt, wird neben dem x und y Wert noch eine Eins hinzugefügt. Hierzu werden mindestens acht Gleichungen der Form $p_{Ai}^T F p_{Bi} = 0$ (Siehe auch Gleichung 8) gebildet und daraus ein Gleichungssystem der Form $Af = 0$ erzeugt, wobei f die Unbekannten aus F enthält.

$$\begin{aligned} x_{p_{Ai}} x_{p_{Bi}} f_1 + x_{p_{Ai}} y_{p_{Bi}} f_2 + x_{p_{Ai}} f_3 + \\ y_{p_{Ai}} x_{p_{Bi}} f_4 + y_{p_{Ai}} y_{p_{Bi}} f_5 + y_{p_{Ai}} f_6 + \\ x_{p_{Bi}} f_7 + y_{p_{Bi}} f_8 + f_9 = 0 \end{aligned} \quad (8)$$

Das Gleichungssystem wird mittels Singulärwertzerlegung (SVD) gelöst. Man erhält drei Matrizen U , S und V . U hat die Größe $m \times m$, S die Größe $m \times 9$ und V die Größe 9×9 . S ist eine Diagonal-Matrix, deren Einträge die Singulärwerte von A in absteigender Reihenfolge enthalten. Aus der letzten Spalte von V (Siehe Gleichung 9), welche den kleinsten Singulär-Vektor enthält, kann die Approximation \hat{F} (Siehe Gleichung 10) von F rekonstruiert werden.

$$V[9] = [\hat{f}_1 \quad \hat{f}_2 \quad \hat{f}_3 \quad \hat{f}_4 \quad \hat{f}_5 \quad \hat{f}_6 \quad \hat{f}_7 \quad \hat{f}_8 \quad \hat{f}_9] \quad (9)$$

$$\hat{F} = \begin{bmatrix} \hat{f}_1 & \hat{f}_2 & \hat{f}_3 \\ \hat{f}_4 & \hat{f}_5 & \hat{f}_6 \\ \hat{f}_7 & \hat{f}_8 & \hat{f}_9 \end{bmatrix} \quad (10)$$

Hierbei wird der Vektor der Länge 9 in drei Teile zerlegt, welche die Zeilen von \hat{F} bilden. Da durch Rauschen \hat{F} den Rang 3 haben kann, wird von \hat{F} noch einmal die SVD gebildet und in S das letzte Diagonal-Element explizit auf 0 gesetzt, was hier als Matrix \hat{S} beschrieben wird. Damit kann die Approximation von F neu berechnet werden ($\hat{F} = U \hat{S} V^T$) und hat damit Rang 2. Der Unterschied bei der Berechnung der Essential-Matrix zur Fundamental-Matrix ist, dass zum einen bei der Korrektur der Approximation neben dem letzten Eintrag der Diagonal-Elemente, der auf 0 gesetzt wird, die beiden verbleibenden Diagonal-Elemente auf 1 gesetzt werden. Die daraus resultierende Matrix wird im Folgenden mit D bezeichnet. Des Weiteren wird bei den homogenen Bildpunkten nicht 1 gesetzt, sondern c , die Kamerakonstante. Ist E bekannt, kann die Kamera-Pose, bestehend aus dem Kamera Zentrum c und der Kamera-Rotation R , geschätzt werden [9]. Hier ergeben sich vier mögliche Lösungen, die in Gleichung 11 zu sehen sind. Mit W wie in Gleichung 12 beschrieben.

$$\begin{aligned}
c_1 &= U(:, 3), & R_1 &= UWV^T \\
c_2 &= -U(:, 3), & R_2 &= UWV^T \\
c_3 &= U(:, 3), & R_3 &= UW^TV^T \\
c_4 &= -U(:, 3), & R_4 &= UW^TV^T
\end{aligned} \tag{11}$$

$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{12}$$

Um zu ermitteln, welche der vier Konfigurationen die richtige ist, kann geprüft werden ob die rekonstruierten 3D-Punkte vor beiden Kameras liegen. Es wird die Konfiguration gewählt, bei der am meisten Punkte vor den Kameras liegen. Sind nun die ersten beiden Kamera-Posen bekannt, können weitere Kameras mittels Perspektive-n-Points-Algorithmus (PnP) [10] hinzugefügt werden. Hierbei wird anhand der bereits ermittelten 3D-Punkte die Pose einer weiteren Kamera mittels Least-Square-Fit gefunden. Da die Pose der Kamera 6 Freiheitsgrade hat, werden mindesten 6 korrespondierende Punkte benötigt. Wurden alle Kamera-Posen und 3D-Punkte geschätzt, müssen diese noch einmal korrigiert werden. Diesen Schritt nennt man Bundle-Adjustment (BA) [11]. Beim BA wird für jede der m Kamera-Posen A mit den Parametern a_j jeder der n 3D-Punkte P_i , der von der Kamera aufgenommen wurde, zurück auf das Kamera-Bild projiziert und der Abstand des so ermittelten Bild-Punktes zum originalen Bild-Punkt aus der Feature-Detektion gemessen und minimiert. Das Optimierungsproblem kann, wie in Gleichung 13 zu sehen, formuliert werden.

$$\min_{a_j, P_i} = \sum_{i=1}^n \sum_{j=1}^m v_{ij} d(Q(a_j, P_i), x_{ij}) \tag{13}$$

Hierbei gilt $v_{ij} = 1$, wenn der Punkt i von Kamera j erfasst wurde, ansonsten 0. $Q(a_j, P_i)$ ist die geschätzte Projektion des Punktes P_i auf das Bild der Kamera j , und d ist die Euklidische Distanz. x_{ij} ist der detektierte Punkt auf dem Bild.

Einige bekannte Implementierungen von SfM sind Colmap [12],[13], Open Drone Map (ODM) [14], OpenCV SfM-Pipeline [15], AliceVision (Meshroom)[16],[17] und OpenMVG [18].

Colmap stellt eine Pipeline bereit, die eine inkrementelle Implementation von SfM anbietet. Initial wird nach korrespondierenden Bildern gesucht und diese dann inkrementell in die Rekonstruktion aufgenommen. Colmap nutzt Root-SIFT als Feature-Detektor. Root-SIFT nutzt im Gegensatz zu SIFT beim Feature-Matching nicht die Euklidische Distanz sondern die Hellinger-Distanz [19].

ODM stellt auch eine Pipeline bereit, die aus den Schritten SfM, Multi View Stereo und dem Ermitteln von Filterpunkten besteht. Eine Besonderheit bei ODM ist, dass es für jeden 3D-Punkt auch eine Normale liefert. Stehen Geo-Positionen für die Kameras zur Verfügung, wird SIFT als Feature-Detektor angewandt, ansonsten wird HAHOOG genutzt. HAHOOG unterscheidet sich zu SIFT nur in der Detektion der Features, der

Deskriptor - Histogramm of oriented Gradients (HOG) - ist derselbe. Als Detektor wird Hessian Affine Feature Detector (HA) [20] genutzt. HA ermittelt die Feature-Punkte, indem initial auf verschiedenen Skalierungs-Stufen eine abgewandelte Form des Harris-Detektors angewandt wird. Iterativ wird dann Position, Skalierung und die Nachbarschaft um die gefundenen Punkte herum angepasst.

Meshroom, welches zur 3D-Rekonstruktion AliceVision nutzt, erstellt auf Basis von Bildern ein 3D-Modell. Hierzu wird nach der Erstellung der 3D-Punktwolke eine Triangulierung ermittelt, um ein Mesh zu erstellen, welches danach texturiert wird.

OpenCV und OpenMVG stellen SfM-Pipelines zur Verfügung, wie sie in diesem Abschnitt beschrieben wurden. Bei der OpenCV-Implementierung muss - im Gegensatz zu den anderen Verfahren - die Kamerakonstante c angegeben werden und wird nicht ermittelt.

Es wurden in den letzten Jahren große Fortschritte im Bereich tiefer Neuronaler Netze (Deep-Learning) [21] zur Gewinnung von 3D-Punktwolken gemacht [22] [23] [24]. Mit diesen Verfahren ist es möglich, aus einer minimalen Datenbasis, die auch nur aus einem Bild bestehen kann, 3D-Punktwolken zu generieren. Nachteil der Verfahren ist, dass auf dem Bild nur ein Objekt ohne Hintergrund abgebildet sein darf, oder dass das zu erkennende Objekt mit einer binären Maske maskiert werden muss. Eine Rekonstruktion von komplexen Szenen ist so nicht oder nur mit sehr hohem Aufwand möglich [25].

2.2 Segmentierung von 3D-Punktwolken

Unter der Segmentierung von 3D-Punktwolken versteht man, dass jedem Punkt ein Label zugewiesen wird, welches Auskunft über eine Eigenschaft des Punktes gibt. Im Falle dieser Arbeit sollen Label wie Stamm, Blatt, Blüte oder Frucht vergeben werden.

Bei der Analyse von Pflanzen in Form von 3D Punktwolken gibt es einige nicht gelernte Lösungen [26] [27], die das Segmentieren von 3D Punktwolken von Pflanzen in Stiele und Blätter behandeln. Diese Ansätze haben aber das Problem, dass sie nur unter bestimmten Bedingungen gute Ergebnisse liefern.

[26] verfolgt den Ansatz, eine Punktwolke in Stamm und Blätter anhand der Hauptkrümmung um jeden Punkt zu segmentieren. Hierbei wird die Hauptkrümmung für einen Punkt so interpretiert, dass der Punkt als Stamm interpretiert wird wenn die Krümmung hoch ist. Es wird also davon ausgegangen, dass die Stämme eine höhere Krümmung aufweisen als die Blätter.

In [27] wird ein Ansatz verfolgt, der sich die zylindrische Form von Stielen zunutze macht, um diese von anderen Teilen der Pflanze, wie den Blättern, zu unterscheiden. Es wird das Modell eines Zylinders in der Punktwolke gesucht und wird dieses gefunden, werden Punkte, die in das Modell fallen, als Stamm klassifiziert.

Insbesondere die hohe Qualität der Punktwolken, die meist mit einem LIDAR-Scanner oder einem vergleichbaren Gerät erzielt wird, kann mit bildbasierten Methoden, wie SfM, nicht oder nur mit sehr großen Datenmengen und dem damit verbundenen Rechenaufwand erreicht werden. Ein weiteres Problem ist, dass der Hintergrund, also alles was nicht zur Pflanze gehört, manuell entfernt wird, oder der Hintergrund so vorbereitet

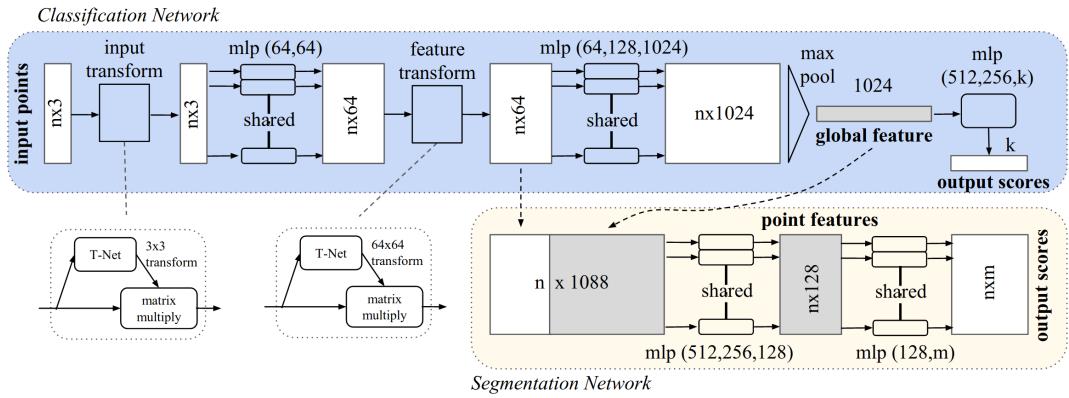


Abbildung 2: PointNet-Architektur [28]

wird, dass dieser beim erstellen der Punktwolke ignoriert wird und erst auf der freigestellten Pflanze der eigentliche Ansatz ausgeführt wird. Um diese Lösungen dennoch in einer voll automatischen Pipeline nutzen zu können, muss das Freistellen der Pflanzen erst automatisiert werden.

Auch im Bereich Segmentierung wurden große Fortschritte im Bereich Deep-Learning auf Punktwolken gemacht, die mit einer angelernten Netzarchitektur bestimmte Objekte erkennen und Teile davon segmentieren. Diese Ansätze können auch auf Pflanzen angewandt werden. Dazu müssen Architekturen wie PointNet[28]/PointNet++[29] oder Dynamic Graph CNN (DGCNN) [30] auf Punktwolken von Pflanzen trainiert werden, da für diese Klasse von Objekten noch keine Gewichte trainiert wurden.

PointNet ermöglicht Segmentierung durch zwei Schritte. Erst wird ein globaler Feature-Vektor für die Punktwolke ermittelt und dann, auf Basis dessen, für jeden Punkt ein Feature-Vektor ermittelt. Auf Basis des Feature-Vektors wird das Label bestimmt, dem der Punkt zugeordnet werden soll. Dabei wird jeder der n Punkte der Punktwolke mit einer 3×3 Matrix transformiert, deren Gewichte gelernt sind. Dieses Mininetz wird von den Autoren T-Net genannt. Anschließend wird jeder Punkt nacheinander mittels eines Multi-Layer-Perceptron (MLP) mit zwei Layern, deren Ausgabe-Schicht jeweils die Größe 64 hat, in einen neuen Feature-Raum überführt. Die Gewichte des MLP werden also über alle Punkte geteilt, was auch für die folgenden MLPs gilt. Der Feature-Vektor für einen Punkt besteht aus 64 Elementen. Die Punkte des Feature-Raums werden wieder mit einem T-Net, diesmal der Größe 64×64 , transformiert. Im Anschluss wird wieder ein MLP (drei Layer mit Ausgabeschichten der Größen 64, 128, 1024) angewandt und mittels Max-Pooling der globale Feature-Vektor der Größe 1024 ermittelt. Dieser Vektor wird mit dem lokalen Feature-Vektor für jeden Punkt kombiniert, und die daraus entstehende Matrix der Größe $n \times 1088$ wird mittels zweier MLP-Layer in eine Matrix der Größe $n \times m$ überführt, wobei m die Anzahl der möglichen Label ist. Der erste dieser MLPs hat drei Layer mit den Ausgangs-Schicht-Größen 512, 256 und 128. Der zweite besteht aus zwei Layern der Ausgangs-Schicht-Größen 128 und m . Die Architektur ist in Abbildung 2 dargestellt.

PointNet++ baut auf der Architektur von PointNet auf. Hierbei wird das Problem adressiert, dass PointNet nicht gut mit kleinen Details umgehen kann. Um das zu bewerkstell-

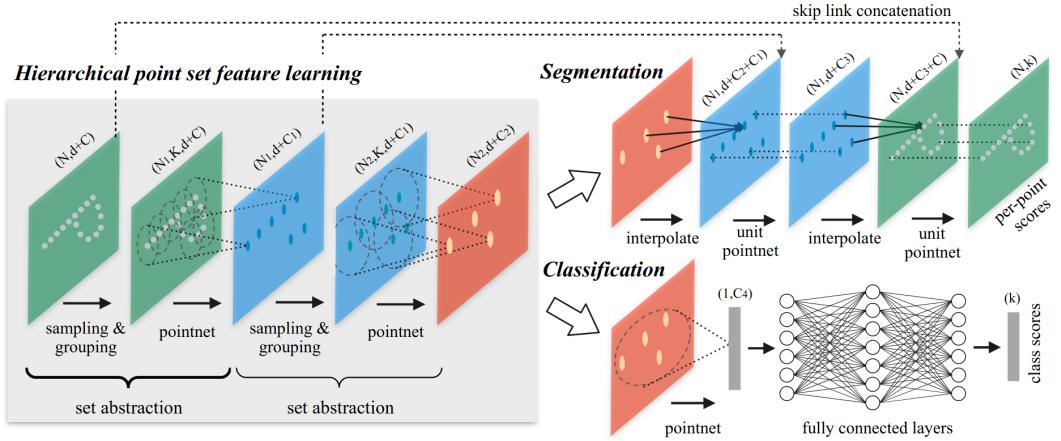


Abbildung 3: PointNet++-Architektur [29]

ligen, werden kleinere Bereiche mit PointNet untersucht. Hier wird in drei Schritten vorgegangen: Sampling, Gruppieren und Feature-Vektor Ermitteln. PointNet++ führt also PointNet auf einem kleinen Bereich um gewählte zentrale Punkte aus. Beim Sampling werden diese zentralen Punkte mittels Farthest-Point-Sampling (FPS) ermittelt. FPS ermittelt aus n Punkten eine Menge Punkte x_1, x_2, \dots, x_k , sodass der Punkt x_j der Punkt mit dem weitesten Abstand zu allen Punkten der Menge x_1, x_2, \dots, x_{j-1} ist. Beim Gruppieren werden um die gewählten Punkte alle Punkte in den Bereich aufgenommen, die einen bestimmten Abstand d von dem zentralen Punkt nicht überschreiten. Auf diesen Punkten wird PointNet angewandt. Für jeden zentralen Punkt wird also ein Feature-Vektor ermittelt. Dieser Vorgang kann je nach Model mehrfach mit variierenden Parametern ausgeführt werden. Für die Klassifizierung wird nach dem letzten Layer auf dessen Ergebnis ein letztes mal PointNet angewandt, um den globalen Feature-Vektor zu ermitteln. Bei der Segmentierung wird stattdessen, um jedem einzelnen Punkt ein Label zuzuordnen, der Prozess umgekehrt, und mittels Interpolation werden die ermittelten Feature-Vektoren schrittweise auf die originalen Punkte übertragen. Dies geschieht unter Zuhilfenahme der in den vorherigen Schritten ermittelten Feature-Vektoren der zentralen Punkte. Die vereinfachte dargestellte Architektur von PointNet++ ist in Abbildung 3 zu sehen.

DGCNN führt Faltungen auf Nachbarschafts-Grafen der Punktwolke aus und ermittelt so für jeden Punkt einen Feature-Vektor. Die Nachbarschafts-Grafen werden mittels kNN gebildet. Ähnlich wie bei PointNet wird erst der globale Feature-Vektor, der auch zur Klassifizierung genutzt wird, berechnet und dann darauf basierend die Feature-Vektoren für die einzelnen Punkte. Ein weiterer Unterschied zu PointNet ist, dass die Ausgabeschichten vor dem Max-Pooling-Layer aggregiert werden. Allerdings ist die Güte von DGCNN bei Segmentierungs-Aufgaben, laut Angaben der Autoren [30], schlechter als die von PointNet++.

2.3 Registrierung von 3D-Punktwolken

Bei der Registrierung von 3D-Punktwolken probiert man eine Transformationen T zu finden, die eine Quell-Punktwolke P_s so transformiert, dass der Abstand $d(P_s, P_t)$ zu

einer Ziel-Punktwolke P_t minimiert wird. Das Abstandsmaß $d(P_s, P_t)$ kann verschieden formuliert werden. Eine Möglichkeit besteht darin, die Summe über die Abstände eines jeden Punktes in P_s zum nächsten Punkt in P_t zu bilden und dies als Maß $d(P_s, P_t)$ zu nutzen.

Die am weitesten verbreitete Methode zur Registrierung von 3D Punktwolken ist Iterative Closest Points (ICP) [31]. ICP basiert auf dem Ansatz, dass zwei Punktwolken iterativ aneinander angenähert werden, dies kann als Optimierungsproblem (Gleichung 14) formuliert werden.

$$\underset{R, t}{\operatorname{argmin}} \left(\sum_{i=1}^N \|Rp_{s_i} + t - p_{t_i}\|^2 \right) \quad (14)$$

Hierbei sind R und t die gesuchte Rotation und Translation und p_{t_i} und p_{s_i} bilden ein korrespondierendes Punktpaar aus den beiden zu registrierenden Punktwolken. N ist die Anzahl Punkte in der Quell-Punktwolke. ICP löst dieses Problem, indem iterativ zwei Schritte durchgeführt werden: Erst werden die Zuordnungen für jeden Punkt in der Quell-Punktwolke zu einem Punkt in der Ziel-Punktwolke gesucht und danach wird die Rotation R und Translation t geschätzt, die die zugeordneten Punkte bestmöglich annähert. Um eine Zuordnung zwischen den Punkten zu erreichen, wird für jeden Punkt p_i aus der Quell-Punktwolke P_s der Punkt aus der Ziel-Punktwolke gesucht, der p_i am nächsten ist. Im zweiten Schritt wird zuerst für beide Punktwolken das Massezentrum c_s und c_t berechnet. Hierbei wird das Massezentrum c einer Punktwolke P mit n Punkten, wie in Gleichung 15 gezeigt, berechnet.

$$c = \frac{1}{n} \sum_{i=1}^n p(i) \quad (15)$$

Mit c_s und c_t lässt sich die Kreuzkovarianz-Matrix H (Gleichung 16) der beiden Punktwolken berechnen, auf der die SVD ($\text{svd}(H) = UDV^T$) angewandt wird.

$$H = \sum_{i=1}^n (p_{t_i} - c_t)(p_{s_i} - c_s)^T \quad (16)$$

Sind U und V bekannt, kann damit die Rotation $R = VU^T$ und mit R die Translation $t = c_t - Rc_s$ berechnet werden. Da die Zuordnung im ersten Schritt nicht ideal sein muss, wird der Vorgang solange wiederholt, bis es in der Transformation T , bestehend aus R und t , zu keinen größeren Änderungen mehr kommt. Das ist der Fall, wenn T etwa der Einheitsmatrix entspricht.

Ein Problem von ICP ist, dass es auch für lokale Minima konvergiert. Das heißt, dass eine initiale Transformation für P_s so gewählt werden muss, dass der ICP-Durchlauf bei einem globalen Minimum konvergiert. Ansätze wie Go-ICP [32], die mit verschiedenen initialen Transformationen starten, existieren, sind aber sehr rechenaufwändig und damit recht langsam.

Des Weiteren ist ICP anfällig für Ausreißer. Für dieses Problem gibt es allerdings existierende Lösungen wie RICP [33]. Hierbei kommt in der Regel RANSAC [34] zum

Einsatz, um Ausreißer bei der Registrierung auszuschließen. RANSAC basiert auf der Idee, ein Modell in einer Punktwolke zu suchen und möglichst viele Punkte zu finden, die in das Modell passen. Initial werden zufällig so viele Punkte wie nötig gezogen um das Modell minimal zu repräsentieren. So werden zum Beispiel für ein Linien-Modell zwei zufällige Punkte aus der Punktwolke gezogen. Nun werden die Parameter für das Modell mit den gezogenen Punkten ermittelt und alle Punkte, die nahe genug an dem so gebildeten Modell sind, mit aufgenommen. Wenn der Anteil der Punkte, die in das Modell fallen, über einem bestimmten Schwellwert liegen, terminiert der Algorithmus. Ansonsten wird der Vorgang solange wiederholt, bis eine Parametrisierung gefunden wurde, die terminiert oder eine Obergrenze an Iterationen erreicht wurde. Das Ergebnis des Algorithmus ist auf der einen Seite die gefundene Parametrisierung. Auf der anderen Seite wird eine Unterteilung der Punkte in Punkte, die in das Modell fallen und in solche, die nicht in das Modell fallen, gefunden. Letzteres kann genutzt werden um Punkte bei der Registrierung auszuschließen.

Ein weiteres Problem bei den meisten ICP-Ansätze ist das Fehlen einer Schätzung für die Skalierung der zu registrienden Punktwolke. Diese ist aber nötig, da bei SFM keine Information über die reale Ausdehnung eines Objektes ermittelt werden kann. Es gibt einige wenige Ansätze, die auch eine Schätzung für die Skalierung ermitteln [35]. In [35] wird die Skalierung geschätzt, nachdem die Rotation R bekannt ist, also nach der SVD. Ist R bekannt, können die Vektoren s und t gebildet werden (Siehe Gleichung 17).

$$s_i = R(p_{s_i} - \bar{p}_s), \quad t_j = p_{t_j} - \bar{p}_t \quad (17)$$

Mittels dieser Vektoren kann die Skalierung \hat{s} berechnet werden. Die Berechnung ist in Gleichung 18 zu sehen.

$$\hat{s} = \sum_{i,j} t_j^T s_i / \sum_i s_i^T s_i \quad (18)$$

Die Translation muss auch in angepasster Form berechnet werden, wie in Gleichung 19 zu sehen ist.

$$t = \bar{p}_t - \hat{s}R\bar{p}_s \quad (19)$$

Auch für das Registrierungs-Problem gibt es Lösungen aus dem Deep-Learning-Bereich. Aber auch hier gibt es nur wenige Ansätze, die mit Skalierung umgehen können [36]. Bekannte Ansätze sind DCP [37], PointNetLK [38] und RPM-Net [39], die in dieser Arbeit untersucht werden sollen.

DCP besteht aus drei Teilen, wobei es sich bei den ersten zwei Teilen um Netze handelt, die eine Zuordnung berechnen, die der von ICP ähnelt, aber mehrere Zuordnungen für einen Punkt nutzt und diese gewichtet. Das erste Netz berechnet für jeden Punkt einen Feature-Vektor. Hier wurde von den Autoren PointNet und DGCNN untersucht, wobei DGCNN, laut den Autoren, die besseren Ergebnisse liefert. Das zweite Netz kodiert den

Feature-Vektor mittels eines Transformer-Modells weiter. Transformer-Modelle wurden ursprünglich entwickelt um, kontextuelle Information von Sätzen zu kodieren und dekodieren, um so Aufgaben wie Übersetzung von Sprachen zu ermöglichen. Dieses Prinzip wird hier auf die Registrierung übertragen, wobei bei DCP eine Zuordnung zwischen den beiden Punktwolken gesucht wird. Bei der so gefundenen Zuordnung handelt es sich um eine weiche Zuordnung. Das heißt ein Punkt in der Quell-Punktwolke kann nicht nur einem sondern mehreren Punkten in der Ziel-Punktwolke zugewiesen werden. Der letzte Teil von DCP schätzt auf Basis dieser Zuordnung, wie bei ICP, mittels SVD Rotation und Translation, die für die Registrierung nötig sind. Auch bei DCP wird der Prozess bis zur Konvergenz des Registrierungs-Ergebnisses wiederholt.

PointNetLK kombiniert die Idee von PointNet und dem Lucas-Kanade-Algorithmus (LK) [40], der zur Registrierung von Bildern entwickelt wurde, und mit dem sich der optische Fluss von einem zum anderen Bild beschreiben lässt. Hierbei wird PointNet für die Ziel- und Quell-Punktwolke ausgeführt, die Distanz zwischen den globalen Feature-Vektoren minimiert und dabei eine Transformation G gefunden, die den Abstand zwischen Ziel- und Quell-Punktwolke minimiert. Der Vorgang wird wiederholt, bis die Distanz der Feature-Vektoren unter einem gewissen Schwellwert liegt, bzw. die Transformation G der Einheitsmatrix ähnelt. Über die Iterationen müssen sich die berechneten Transformationen gemerkt und zum Schluss miteinander multipliziert werden, um die finale Transformation zu finden, die die beiden Punktwolken miteinander registriert.

RPM-Net baut auf Robust Point Matching (RPM) [41] auf. RPM unterscheidet sich von ICP darin, dass zwischen den Punkten beider Punktwolken auch die Zuordnung der Punkte mit in das Optimierungsproblem einfließt. Damit wird das Optimierungs-Problem in Gleichung 14 umformuliert, wie in Gleichung 20 zu sehen ist.

$$\underset{M, R, t}{\operatorname{argmin}} \left(\sum_{i=1}^N \sum_{k=1}^K m_{jk} (\|Rp_{s_i} + t - p_{t_k}\|_2^2 - \alpha) \right) \quad (20)$$

Dabei ist M die Gewichtungsmatrix für die Zuordnungen zwischen den Quell- und Zielpunkten. Der Parameter α ist dazu da um Korrespondenzen zwischen schlechten Paaren zu bestrafen. Die Idee dabei ist, dass Distanzen unter dem Schwellwert α die Kosten senken und Distanzen über dem Schwellwert die Kosten erhöhen. Die Matrix M wird in jeder Iteration wie in Gleichung 21 initialisiert.

$$m_{ij} = e^{-\beta(\|Rp_{s_i} + t - p_{t_j}\|_2^2 - \alpha)} \quad (21)$$

Dabei ist β ein Parameter, der über die Iteration erhöht wird.

Im Vergleich zu RPM werden die räumlichen Entferungen bei der Berechnung von M durch hybride Feature-Distanzen ersetzt (Siehe Gleichung 22).

$$m_{ij} = e^{-\beta(\|\hat{f}_{s_i} - f_{t_j}\|_2^2 - \alpha)} \quad (22)$$

\hat{f}_{s_i} ist der hybride Feature-Vektor für den aus der vorherigen Iteration transformierten Punkt p_{s_i} und f_{t_j} ist der Feature-Vektor für den Punkt p_{t_j} . Des Weiteren werden die Parameter α und β in jeder Iteration durch ein neuronales Netz geschätzt. β wird dabei nicht zwangsläufig wie in RPM immer weiter erhöht. Zuletzt wird, wie bei ICP, die SVD

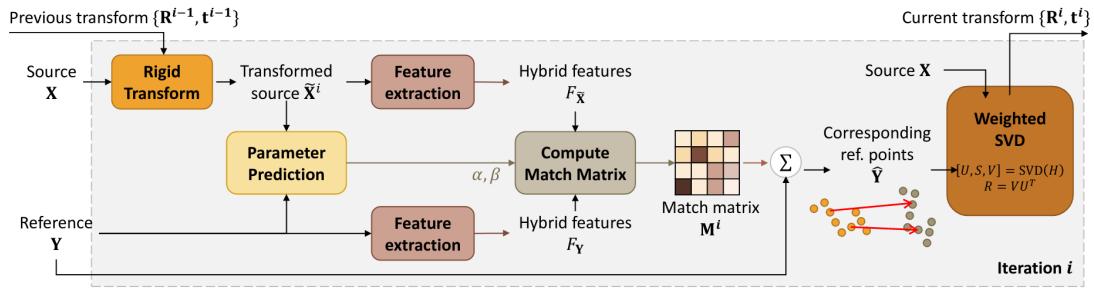


Abbildung 4: RPM-Net-Architektur [39]

der Punktpaare ermittelt und so die Rotation gefunden, nur fließt beim Bilden der SVD auch das Gewicht der einzelnen Paare mit ein. Die Transformation kann so wie bei ICP ermittelt werden.

Details der Architektur sind in Abbildung 4 zu finden.

3 Realisierung

Um die Anwendung zu realisieren müssen vier Teilprobleme berücksichtigt werden. Zu Beginn muss aus einer Reihe von Bildern einer Pflanze aus verschiedenen Perspektiven eine Punktwolke generiert werden. Hauptziel ist hierbei, mit möglichst wenigen Bildern auszukommen. Trotzdem müssen Aspekte wie die Qualität der Punktwolken berücksichtigt werden. Diese sollten die aufgenommenen Szenen klar darstellen und wenig Rauschen und andere Störungen enthalten. Bei der Aufnahme sollte darauf geachtet werden, dass zwischen den aufeinander folgenden Bildern immer mindestens 50% Überschneidung in der zu sehenden Szene sichergestellt ist, um genügend korrespondierende Features zwischen den Bildern finden zu können.

Ein zweites Problem ist die Registrierung zweier Punktwolken einer Pflanze zu verschiedenen Zeitpunkten, um diese hinsichtlich der Größe und des Volumens vergleichen zu können. Hierbei gilt es, die ideale Transformation T , bestehend aus Rotation, Skalierung und Translation, zu finden, um die beiden Punktwolken so realitätsnah wie möglich aneinander auszurichten. Es werden drei Ansätze überprüft dieses Problem zu lösen. Allen Ansätzen liegt zugrunde, dass beim Beginn einer neuen Messreihe zur Analyse eines Wachstumsprozesses eine Punktwolke des Hintergrundes erstellt wird. Die Punktwolken der einzelnen Zeitpunkte werden mit diesem Hintergrund registriert. So wird ein Verhältnis geschaffen, das dem der Realität entspricht. Wird für einen beliebigen Zeitpunkt noch die totale Größe der Pflanze angegeben, kann aus den berechneten Verhältnissen die totale Größe aller Zeitpunkte berechnet werden. Der erste Ansatz soll dabei untersuchen, ob es mit einer angepassten Version von ICP möglich ist, neben der Rotation und Transformation auch die relative Skalierung zur Hintergrund-Punktwolke zu ermitteln. Der zweite Ansatz soll untersuchen, ob DCP so angepasst werden kann, dass statt Rotation und Translation separat die komplette Transformations-Matrix mit Skalierung geschätzt werden kann. In einem letzten Ansatz soll die Skalierung durch iteratives Anwenden verschiedener Skalierungen gefunden werden, mit einer anschließenden Registrierung ohne Schätzung der Skalierung.

Das dritte Problem ist die Segmentierung der Punktwolke in Stamm, Blätter und Hintergrund. Hier gibt es viele Lösungsansätze, allerdings ist es schwer, eine allgemein gültige Lösung zu finden. Ziel ist es daher eine Lösung auszumachen, die auf möglichst vielen Varianten von Pflanzen funktioniert. Das Problem der Segmentierung ist essentiell für die weitere Analyse einer Messreihe. Ohne die Information, welche Punkte zum Stamm bzw. zu den Blättern gehören, kann nicht auf die Entwicklung von Blättern und Stielen im Einzelnen geschlossen werden.

Zuletzt müssen die Implementationen der einzelnen Probleme in geeigneten Pipelines zusammengefasst und durch einen Server angesteuert werden. Hier muss die Lastverteilung und Datenhaltung beachtet werden.

3.1 Architektur

Die Anwendung soll über eine REST-API angesteuert werden können. Mit dieser soll es möglich sein neue Messreihen anzulegen. Dazu müssen die Bilder für die initiale Punktwolke auf den Server übertragen werden. Es soll ebenfalls möglich sein, weitere

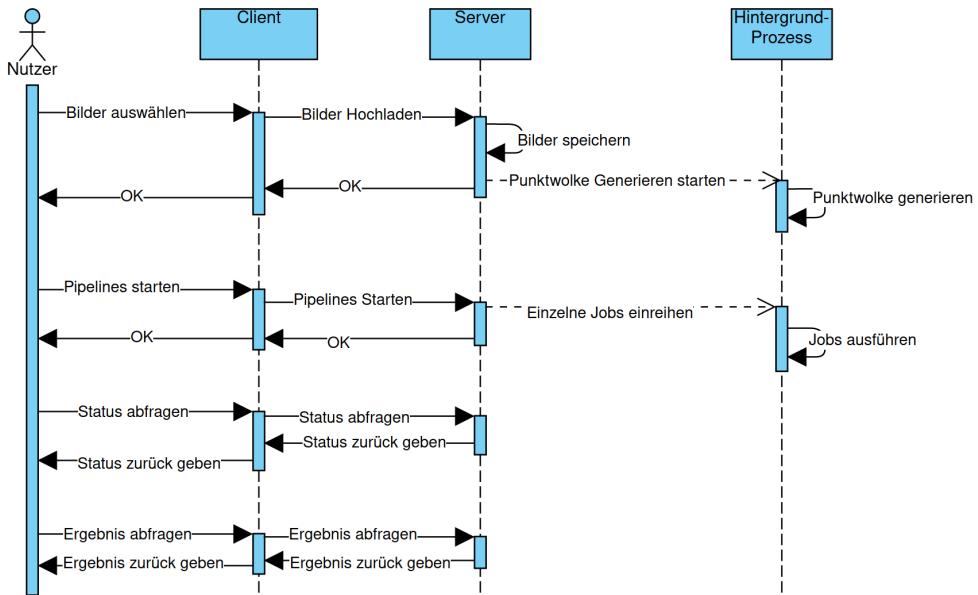


Abbildung 5: Arbeitsabläufe zwischen Nutzer, Client, Server und Hintergrundprozess.

Messpunkte, in Form von Bildern, aus denen eine Punktfolge zu einem bestimmten Zeitpunkt erstellt werden soll, zu einer Messreihe hinzuzufügen. Zu einer Messreihe sollen Auswertungen zur Verfügung gestellt werden. Da in den einzelnen Teilaufgaben mit Laufzeiten die länger als 10 Sekunden sind zu rechnen ist, sollen die Pipelines in einzelne Jobs unterteilt und diese asynchron im Hintergrund abgearbeitet werden. Dadurch reagiert die Anwendung schneller und bei größerer Last können die einzelnen Verbindungen zu den Clients schnell wieder geschlossen werden. Um trotzdem Auskunft über den aktuellen Bearbeitungsstatus einer Pipeline geben zu können, soll dieser durch eine weitere Schnittstelle abrufbar sein und Auskunft über den Status der einzelnen Jobs geben.

Die einzelnen Abläufe werden in Abbildung 5 gezeigt.

3.2 Umsetzung Generierung einer 3D Punktfolge aus Bildern

Die aus der Analyse der verschiedenen Verfahren (siehe Kapitel 4.1) ausgewählte Anwendung ODM wird als Docker bereit gestellt. Um den Docker erfolgreich auszuführen, muss ein Ordner bereit gestellt werden. In diesem Ordner muss ein Ordner „images“ enthalten sein, der die Bilder des Datensatzes, aus dem eine Punktfolge generiert werden soll, enthält.

Ist das Verzeichnis angelegt, kann der Docker gestartet werden. Hierbei muss allerdings beachtet werden, dass der Docker mit denselben Rechten wie der User ausgeführt wird. Ansonsten werden per Standardeinstellung Root-Rechte genutzt. Das führt dazu, dass auf die erstellten Daten nur noch lesend zugegriffen werden kann, was das Aufräumen nur mit Root-Rechten ermöglicht. Nach dem Ausführen des Dockers sollten in jedem Fall alle nicht benötigten Dateien gelöscht werden, da diese je nach Anzahl genutzter Bilder mehrere Gigabyte an Festplattenspeicher belegen.

3.3 Umsetzung Registrierung zweier Punktwolken

Bei der Umsetzung der Registrierung muss die Besonderheit beachtet werden, dass die Skalierungen der Punktwolken nicht bekannt sind und sich unterscheiden, also Punktwolken in unterschiedlichen Maßstäben vorliegen. Um ein gutes Verfahren zu finden, was mit dieser Besonderheit umgehen kann, werden mehrere Ansätze verglichen.

In einem ersten Ansatz wird versucht, eine Pipeline auf Basis von ICP zu erstellen, die eine gute initiale Lösung findet, ohne den ganzen möglichen Suchraum zu durchsuchen. Die Pipeline sucht zuerst für die Quell- und Ziel-Punktwolke S und T nach der größten Ebene in der Punktwolke und richtet die Punktwolke so aus, dass die gefundene Ebene auf der Ebene liegt, die die x und y Achse bilden. Zudem werden die Punktwolken so skaliert, dass die begrenzenden Boxen gleich groß sind. Des Weiteren werden aus beiden Punktwolken nur eine Teilmenge P_c der Punkte in einem Radius r um den Punkt c , der das Zentrum der Masse der Punktwolken repräsentiert, entnommen. Damit soll Rauschen und unvollständige Fragmente an den Rändern unterdrückt werden und ein Teil des Hintergrundes soll ausgeblendet werden. Aus dieser Teilmenge werden Subsample gezogen um den Rechenaufwand zu minimieren. In diesem Zustand haben Quell- und Ziel-Punktwolke eine gute initiale Transformation. Für die zu registrierende Punktwolke wird zunächst mittels SIFT 3D [42] eine Verbesserung der initialen Transformation gesucht. Danach wird ein ICP-Durchlauf gestartet, der auch die Skalierung der Ziel-Punktwolke schätzt. Um das Ergebnis weiter zu verbessern, wird erneut ein ICP-Durchlauf gestartet - diesmal ohne Schätzung der Skalierung.

Ein weiterer Ansatz ist es, DCP so abzuwandeln, dass statt Translations-Vektor und Rotations-Matrix direkt die ganze Transformations-Matrix geschätzt wird. Dazu muss der SVD-Head so angepasst werden, dass statt einer 3×3 Rotations-Matrix R und dem Translations-Vektor t die Transformations-Matrix T zurück geliefert wird. Um das zu erreichen muss die Eingabe der Größe $N \times 3$, durch einfügen eines Vektors gefüllt mit Einsen, auf eine Eingabe der Größe $N \times 4$ erweitert werden. Das führt dazu, dass die SVD von H im SVD-Head nun eine 4×4 Matrix ist. Wir nehmen an, dass die SVD von H als Transformations-Matrix interpretiert werden kann.

In einem letzten Ansatz wird die Skalierung geschätzt, indem ein vorgegebener Bereich an Werten für die Skalierung in einer vorgegebenen Schrittgröße s durchsucht wird. Wieder werden, wie im ersten Ansatz, Quell- und Ziel-Punktwolke an der XY-Ebene ausgerichtet und eine Teilmenge P_c um das Zentrum c entnommen. Auch werden wieder Subsample gezogen. In jedem Skalierungs-Schritt wird die Punktwolke mit der aktuellen Skalierung skaliert und danach mit einem Registrierungsverfahren registriert. Um die Ergebnisse der einzelnen Registrierungen zu messen, wird der Abstand zwischen der transformierten Quell-Punktwolke und der Ziel-Punktwolke berechnet. Der Abstand $d(S, T)$ wird so berechnet, dass für jeden Punkt p aus der Punktwolke T der Abstand zum nächsten Punkt in der Punktwolke S berechnet und diese Abstände aufsummiert werden.

Man könnte auch den Abstand von allen Punkten in S messen, aber das kann zu Problemen bei kleinen Skalierungen führen, da im Extremfall einer sehr kleinen Punktwolke S alle darin enthaltenen Punkte nahezu keinen Abstand mehr zueinander haben. Man könnte S also auch durch einen Punkt p_S abstrahieren. Bei der Registrierung muss S

nur sehr nah an einem Punkt p_t in T sein, sodass gilt $p_t \approx p_S$ und der Abstand zwischen S und T geht gegen 0. Dadurch werden sehr kleine Skalierungen durch dieses Maß bevorzugt. Nimmt man statt aller Punkte in S alle Punkte in T , wird der Fehler in diesem Fall größer als 0 sein, es sei denn T ist auch sehr klein. Dies wird aber nicht passieren, da T im Shapenet-Format vorliegt. Es besteht nun natürlich noch die Möglichkeit, dass S sehr groß ist und das selbe Problem hervorruft, aber das wird durch die Nutzung des Shapenet-Formates verhindert.

Mit diesem Maß kann man nun die Güte der einzelnen Skalierungs-Iterationen bewerten und die beste Skalierung mit zugehöriger Transformation für Rotation und Translation finden. Da die Wahl des Registrierungsverfahrens offen bleibt, wurden hier mehrere Verfahren miteinander verglichen. Es wurden neben zwei ICP-Implementierungen DCP, PointNetLK und RPM-Net miteinander verglichen. Zur Messung des Fehlers, die bei der Findung der Skalierung genutzt wird, können auch die Fehlermaße der einzelnen Verfahren genutzt werden. Nur zum Vergleich der Verfahren untereinander sollte ein einheitliches Fehlermaß genutzt werden.

3.4 Umsetzung Segmentierung

Zur Segmentierung der Pflanzen-Punktwolke in Stamm und Blätter wurde ein Ansatz verfolgt, der an den in [26] angelehnt ist. In [26] wird mittels der Hauptkrümmung eines Punktes ermittelt, ob es sich bei dem Punkt p um ein Blatt oder einen Stiel handelt. Hierbei wird eine einfache Entscheidungsregel $f(p)$ mittels eines Schwellwerts T_k genutzt: Ist die Stärke der Krümmung $k(p)$ des Punktes höher als der Schwellwert, handelt es sich um einen Stiel, da diese eine größere Krümmung haben als Blätter. Die Schwierigkeit besteht darin einen guten Schwellwert und eine gute Kennzahl für die Stärke der Krümmung zu finden.

Die Hauptkrümmung eines Punktes p_i kann über die Normale des Punktes n_i und die Normalen der k nächsten Nachbarpunkte $n_j \in P_i$ berechnet werden.

$$m_j = (I - n_i \otimes n_i) \cdot n_j \quad (23)$$

Aus den Abbildungen m_j (siehe Gleichung 23) für alle P_i kann die Kovarianzmatrix C_i berechnet werden, wie in Gleichung 24 zu sehen ist.

$$C_i = \frac{1}{k} \sum_{j=1}^k (m_j - \bar{m}) \otimes (m_j - \bar{m}) \quad (24)$$

Die Hauptkrümmung kann aus den Eigenwerten $0 \leq \lambda_1 \leq \lambda_2 \leq \lambda_3$ von C_i bestimmt werden. λ_3 ist die stärkste Krümmung und λ_2 die schwächste Krümmung.

In den Gleichungen in 25 sind einige der untersuchten Ansätze für eine Funktion $k(p_i)$ aufgeführt.

$$\begin{aligned} k_1(p_i) &= \lambda_3 \\ k_2(p_i) &= \lambda_2 \\ k_3(p_i) &= (\lambda_3 + \lambda_2)/2 \end{aligned} \tag{25}$$

Je höher der Wert der Funktion $k(p_i)$ aus den Gleichungen in 25 ist, desto wahrscheinlicher gehört ein Punkt zum Stiel einer Pflanze. Die Entscheidungsdregel dafür zeigt Gleichung 26. Ein guter Wert für den Schwellwert T_k muss in Experimenten für die Funktionen k_1 , k_2 und k_3 gefunden werden. Diese Experimente haben gezeigt, dass k_1 die besten Ergebnisse liefert.

$$f(p_i) = \begin{cases} 1 & k(p_i) \geq T_k \\ 0 & \text{sonst} \end{cases} \tag{26}$$

In einem weiteren Ansatz wurde eine Implementierung von PointNet auf einem Datensatz von Pflanzen-Punktwolken zur Findung eines geeigneten Classifiers trainiert. Der Classifier soll für jeden Punkt einer Punktwolke, bestehend aus Position und Normalen, eine Schätzung liefern, was der Punkt repräsentiert. Mögliche Repräsentationen können Stamm, Blatt oder Hintergrund sein. Weitere denkbare Repräsentationen können die Früchte und Blüten der Pflanzen sein. Wird die Farbe der Punktwolke mit einbezogen, können auch Krankheitsbilder, wie vertrocknende Blätter, in die Repräsentation eingeschlossen werden. Da die Ergebnisse mit PointNet Probleme im Erkennen einzelner Blätter zeigen, wird eine verbesserte Version PointNet++ auf dem Datensatz trainiert. PointNet++ wurde mit und ohne Normalen, mit 2 Labeln ohne Hintergrund und mit 3 Labeln mit Hintergrund trainiert.

Nach der Segmentierung wird das Ergebnis abschließend überarbeitet. Für jeden Punkt p_i werden die Schätzungen N_i der k ($k = 10$) nächsten Nachbarn bestimmt und aus deren Repräsentations-Schätzungen ein Histogramm H_i erzeugt. Die Schätzung mit dem höchsten Histogramm-Wert wird als neue Schätzung s_i für den Punkt p_i genutzt. Die Berechnungs-Vorschrift ist in den Gleichungen in 27 zu finden. Dieser Vorgang wird für alle Punkte solange wiederholt, bis es bei den Punkten zu keinen Änderungen mehr kommt oder eine maximale Iterations-Obergrenze erreicht wird.

$$\begin{aligned} L &= \{0, 1, 2\} \\ x &\in L \\ w(x) &= \begin{cases} 0,5 & x = 2 \\ 1 & \text{sonst} \end{cases} \\ H_i(x) &= \sum_{j=0}^k (w(x)|N_{ij} = x) \\ s_i &= \operatorname{argmax}_x(H_i(x)) \end{aligned} \tag{27}$$

3.5 Umsetzung Server

Der Server ist mit der Python-Bibliothek Flask erstellt. Flask bietet eine schlanke API um REST-Endpunkte zu erstellen und Daten vom Client anzunehmen.

Ein Hintergrund-Prozess führt die einzelnen Jobs aus und sorgt für den Lastausgleich. Die Anfragen an den Server werden asynchron verarbeitet. Jede Anfrage wird in die Job-Queue eingeordnet. Diese wird vom Hintergrund-Prozess abgearbeitet. Einzige Ausnahme bildet hier das Speichern der Bilder. Die Bilder müssen synchron zum Request auf der Platte persistiert werden, da Flask die Datei-Streams nach dem Lebenszyklus eines Requests schließt.

Beim Start des Servers wird neben dem Starten des Hintergrund-Prozesses auch der aktuelle Stand der Datenhaltung eingelesen und der Status des Servers aufgebaut. Bei der Datenhaltung wurde auf eine Datenbank verzichtet, da die Anwendung datenhaltungstechnisch simpel ist und die meisten Daten als BLOB [43] vorliegen und daher nicht ideal für ein relationales Datenbank-Modell sind. Die Daten werden direkt auf der Festplatte des Host-Systems abgelegt, wobei die Ergebnisse als JSON-Datei abgelegt werden. Des Weiteren werden zwei Instanzen von PointNet++ gestartet, eine für die Segmentierung des Hintergrundes und eine für die Segmentierung der Pflanze.

Der Server bietet folgende Schnittstellen, die den Betrieb der Anwendung ermöglichen:

GET /listings/{Messreihe}

Holt zu einer Messreihe den aktuellen Status ab. Der Status der Messreihe setzt sich aus den einzelnen Pipeline-Status zusammen.

PUT /results/{Messreihe}/{Zeitstempel}

Holt zu einem Zeitpunkt einer Messreihe die ermittelten Werte, wie Anzahl Blätter oder Volumen, ab. Listing 1 zeigt dies beispielhaft.

```
{
    "LeaveCount": 7,
    "Height": 0.276259834557858,
    "Volume": 0.025656320729475497,
    "GrowthSinceLastSnapshot": 1.1,
    "BackgroundRegistration": {
        "Transformation": [
            [0.9995419979095459, 0.0299260001629591, -0.00
                4519070032984018, -0.030479200184345245],
            [-0.029895899817347527, 0.9995309710502625, 0.
                0065834098495543, 0.025272000581026077],
            [0.004713969770818949, -0.006445290055125952,
                0.9999679923057556, 0.0013244400033727288],
            [0.0, 0.0, 0.0, 1.0]
        ],
        "Scale": 1.3
    }
}
```

Listing 1: Beispiel Ergebnisse eines Zeitstempels

POST /data/{Messreihe}/{Zeitstempel}

Fügt neue Datensätze hinzu. Es muss eine Sammlung von Bildern einer Pflanze mitgeliefert werden. Wird der Endpunkt angesprochen, werden die Bilder gespeichert und die Pipeline zum Generieren der Punktwolke in der Job-Queue hinzugefügt. Wird als Zeitstempel “background“ angegeben, wird dieser Datensatz als Hintergrund für diese Messreihe interpretiert.

PUT /data/{Messreihe}/{Zeitstempel}

Startet übergebene Jobs für einen Zeitstempel einer Messreihe (Details siehe Kapitel 3.6). Hierzu wird im Payload des Requests eine JSON-Datei an den Server übermittelt, welche eine Liste der Jobs enthält (Beispiel siehe Listing 2). Die spezifizierten Jobs werden in der angegebene Reihenfolge der Job-Queue hinzugefügt.

```
{  
    "jobs" : [  
        {  
            "jobName" : "SegmentBackground",  
            "jobParameter" : {}  
        }  
    ]  
}
```

Listing 2: Beispiel Payload zum starten einer Pipeline

Folgende Jobs stehen zur Verfügung:

- Punktwolke generieren
- Überführung In Shapnet-Format
- Entfernung des Hintergrundes
- Segmentierung Pflanze
- Blatt/Stamm Trennung
- Blätter zählen
- Überführen in Registrierungs-Format
- Hintergrund-Registrierung
- Größen berechnen

3.6 Umsetzung Jobs und Pipelines

Um möglichst flexible Pipelines anbieten zu können werden die Pipelines in einzelne Jobs unterteilt. So können auch gemeinsame Teile der einzelnen Pipelines für ander Pipelines wieder verwertet werden. Zudem ist der Ansatz leicht erweiterbar. Es stehen drei

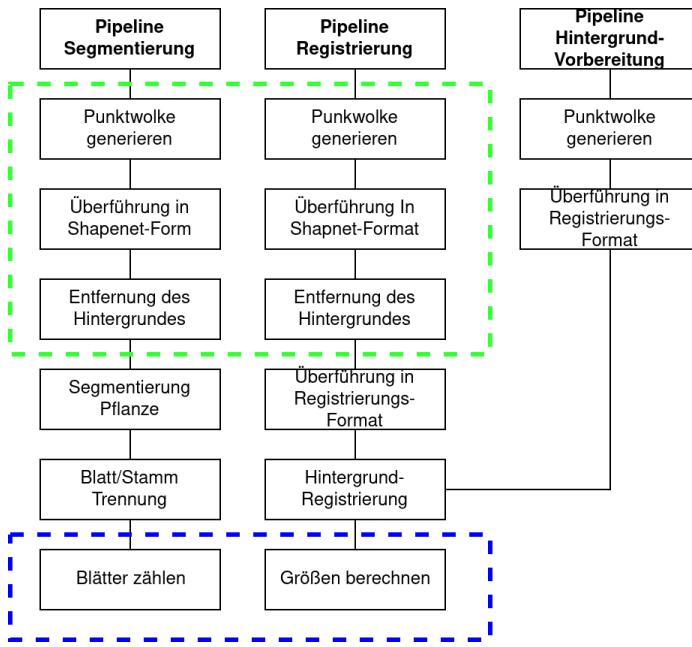


Abbildung 6: Übersicht über die einzelnen Pipelines und die darin enthaltenen Jobs. Die Striche zwischen den Jobs zeigen die Abhängigkeiten der Jobs von oben nach unten. Die Ergebnisse der grün markierten Jobs können wieder verwertet werden. Die blau markierten Jobs sind nicht Teil der Pipeline, aber sollen den praktischen Anwendungszweck der Pipeline-Ergebnis verdeutlichen.

Pipelines zur Verfügung: Eine zur Segmentierung der Punktwolke, eine zur Registrierung der Punktwolke mit dem Hintergrund, wobei diese auf der letzten Pipeline basiert. Die letzte Pipeline überführt die Hintergrund-Punktwolke in das Registrierungs-Format. Die Zusammensetzung der einzelnen Pipelines ist in Abbildung 6 zu sehen.

Punktwolke generieren

Die Punktwolke wird auf Basis der hochgeladenen Bilder zu einem Zeitstempel generiert. Beim Anlegen eines neuen Zeitstempels wird dieser Job automatisch gestartet, kann aber auch manuell neu gestartet werden, sollte es während der Generierung zu einem Server-Ausfall kommen.

Überführung in Shapenet-Format

Dieser Job überführt die Punktwolke in das Shapenet-Format. Die Punktwolke muss in diesem Format vorliegen um beide Segmentierungs-Jobs nutzen zu können. Bevor die Punktwolke in das Shapenet-Format überführt wird, können zwei optionale Schritte durchgeführt werden. Bei der Hintergrund-Segmentierung wird die Punktwolke mittels der größten in der Punktwolke zu findenden Ebene an der XY-Ebene ausgerichtet. Bei der Pflanzen-Segmentierung werden alle als Hintergrund gelabelten Punkte entfernt. Danach beginnt die eigentliche Überführung in das Shapenet-Format. Zuerst wird die Punktwolke so verschoben, dass die Bounding-Box im Koordinaten-Ursprung beginnt und sich auf den positiven Bereich der Achsen erstreckt. Danach wird die Punktwolke in der Form normiert, dass sich alle Punkte der Punktwolke zwischen den Punkten (0, 0, 0)

und $(1, 1, 1)$ befinden. Zuletzt werden $n = 16384$ Punkte aus der Punktwolke zufällig gezogen, wobei die Punkte nicht zurück gelegt werden.

Entfernung des Hintergrundes

Die im Shapenet-Format vorliegende Punktwolke wird mit der Instanz von PointNet++ für die Hintergrund-Segmentierung segmentiert. Das Ergebnis wird im Speicher des Host-Systems abgelegt. Da die Segmentierung etwas verrauscht ist, wird das Ergebnis mit einem “nächste Nachbarn Vote” verbessert. Im Anschluss wird das Ergebnis auf die originale Punktwolke übertragen, da sonst zu wenige Punkte für die Segmenetierung der Pflanze übrig bleiben. Auch der Hintergrund wird entfernt und aus den verbleibenden Punkten, die nun nur noch Pflanzen-Punkte enthalten, wieder eine Punktwolke im Shapenet-Format erstellt. Um die als Pflanze erkannten Punkte auf die originale Punktwolke zu übertragen, wird zu jedem als Pflanze erkannten Punkt, in einem Radius r in der originalen Punktwolke nach Punkten gesucht und die gefundenen Punkte in die neue Punktwolke, die nur die Punkte der Pflanze enthält, übertragen. Die verbleibenden Punkte in der Original-Punktwolke, die nur noch Hintergrund enthalten, werden auch gespeichert, um diese später für die Registrierung zu nutzen.

Segmentierung Pflanze

Auf der in der Hintergrund-Entfernung gefundenen Punktwolke, die nur Punkte der Pflanze enthält, wird PointNet++ zur Segmentierung der Pflanze gestartet. Auch hier wird das Ergebnis im Speicher des Host-Systems abgegelegt. Wieder wird das Segmentierungs-Ergebnis wie bei der Hintergrundentfernung verbessert. Im Falle der Pflanzen-Segmentierung ist dieser Schritt nicht zwangsläufig nötig, da die Ergebnisse gut genug sind.

Blatt/Stamm Trennung

Die Punktwolke, welche die segmentierte Pflanze enthält, wird in zwei Punktwolken aufgeteilt, wobei die eine Punktwolke nur noch Punkte enthält, die Blätter repräsentieren und eine, die nur noch Punkte enthält, die Stiele repräsentieren.

Blätter zählen

Die Punktwolke P , die die Blätter enthält, wird nun mit einer 3D Interpretation des Flood-Fill-Algorithmus untersucht. Hierbei wird ein zufälliger Punkt in der Punktwolke gewählt und in die Menge Q aufgenommen. Nun wird solange, bis Q keine Punkte mehr enthält, ein Punkt p aus Q entnommen und mittels nächster Nachbarn-Suche im Radius r nach weiteren Punkten in der Nähe gesucht. Gefundene Punkte werden in Q aufgenommen, wenn sie nicht in B enthalten sind. Der Punkt p wird danach in die Menge B aufgenommen. Ist Q leer, wird die Menge B aus P entfernt und der Blatt-Zählstand um eins erhöht. Der Vorgang wird so lange wiederholt, bis keine Punkte mehr in P enthalten sind. Da r von Pflanze zu Pflanze variieren kann, besteht die Möglichkeit, r als Parameter dem Request hinzuzufügen, ansonsten wird eine Standard-Einstellung genutzt.

Überführung in Registrierungs-Format

Zuerst wird die Punktwolke wieder anhand der größten Ebene, die in der Punktwolke zu

finden ist, an der XY-Ebene ausgerichtet. Dabei kann es sich entweder um die Punktwolke des Hintergrundes oder der bei der Entfernung des Hintergrundes übrig gebliebenen Punktwolke eines Zeitstempels handeln. Danach wird um das Zentrum der Punktwolke ein Ausschnitt entnommen. Im folgenden wird die Punktwolke in das Shapenet-Format überführt und es werden zufällig $n = 2048$ Punkte aus der Punktwolke gezogen. Es stehen Parameter zur Nutzung des Shapenet-Formats und der Entnahme des Zentrums zur Verfügung.

Hintergrund-Registrierung

Um einen Zeitstempel t einer Messung mit dem Hintergrund der Messreihe zu registrieren, muss sowohl die Punktwolke P_t für den Zeitstempel t als auch die Punktwolke für den Hintergrund im Registrierungs-Format vorliegen. Ist das gegeben, kann die Registrierung gestartet werden. Hierbei wird ein Skalierungs-Faktor s und eine Transformation T ermittelt. Das Registrierungs-Ergebnis $P_{Registration}$ der Punktwolke P_t kann dann mit der Formel $P_{Registration} = (P_t \cdot s) \cdot T$ ermittelt werden. Wobei beachtet werden muss, dass zuerst die Skalierung und dann die Transformation angewandt wird. Hier stehen Parameter für die Registrierungsmethode und den zu untersuchenden Salierungs-Raum. Dieser kann durch einen Start- und Endpunkt sowie eine Schrittweite angegeben werden. Dieser Bereich wird überprüft und es werden nicht mehr als 500 Iterationen zugelassen.

Größen berechnen

Ist die Punktwolke P_t zum Zeitstempel t mit dem Hintergrund registriert, können die Größen *Höhe* und *Volumen* nun leicht berechnet werden. Die Höhe kann über den höchsten z-Wert der Punkte in P_t ermittelt werden. Um das Volumen zu berechnen, muss für P_t die Länge l , Breite b und Höhe h ermittelt werden (siehe Gleichungen 28 - 30). Das Volumen v lässt sich dann folgendermaßen berechnen: $v = h \cdot b \cdot l$.

$$l = \begin{cases} |minX| + maxX & minX \leq 0 \\ maxX - minX & \text{sonst} \end{cases} \quad (28)$$

$$b = \begin{cases} |minY| + maxY & minY \leq 0 \\ maxY - minY & \text{sonst} \end{cases} \quad (29)$$

$$h = \begin{cases} |minZ| + maxZ & minZ \leq 0 \\ maxZ - minZ & \text{sonst} \end{cases} \quad (30)$$

Ist die Höhe für den vorherigen Zeitstempel $t-1$ auch bekannt, kann das relative Wachstum seit dem letzten Zeitpunkt $g = \frac{h_t}{h_{t-1}}$ ermittelt werden. Dieser Schritt kann nicht für den ersten Zeitstempel ausgeführt werden.

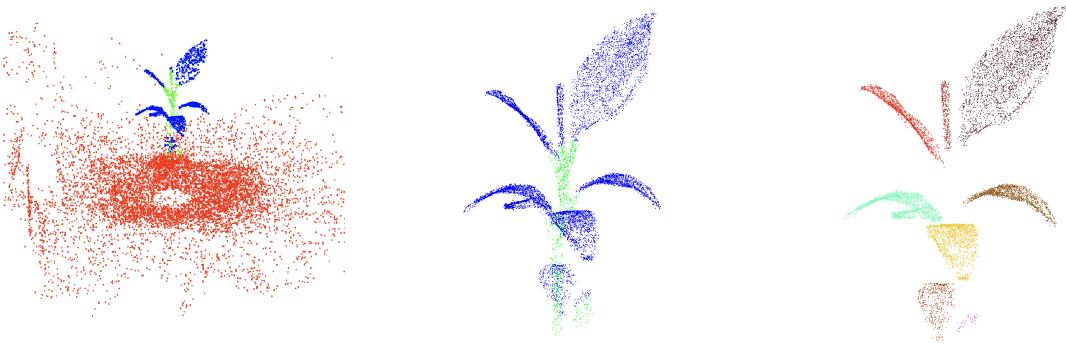


Abbildung 7: Hintegrund-Segmentierung

Abbildung 8: Planzen-Segmentierung

Abbildung 9: Blatt-Segmentierung

4 Ergebnisse

4.1 Vergleich von Verfahren zur Generierung von 3D-Punktwolken auf Basis von Bildern

Um eine geeignete Anwendung zur Generierung von 3D-Punktwolken auszuwählen, muss erst entschieden werden, nach welchen Gütekriterien verschiedene Verfahren betrachtet werden sollen und wie wichtig diese sind. Bei dieser Arbeit sind die nötige Anzahl der Bilder, die zur Generierung einer Punktwolke mit genug Information nötig sind, sowie die Dauer zur Generierung einer Punktwolke die wichtigsten Kriterien.

Zur Messung der Anzahl benötigter Bilder, um eine Szene gut zu repräsentieren muss ein Goldstandard von der fotografierten Szene als 3D-Punktwolke erstellt werden, mit dem verglichen werden kann. Dieser Goldstandard kann erstellt werden, indem alle Verfahren auf derselben Menge an Bildern ausgeführt werden. Die Menge der Bilder besteht aus allen Bildern einer Pflanze, die zu einem Zeitpunkt zur Verfügung stehen. Unter den erstellten Punktwolken kann diejenige ausgesucht werden, die die Szene am besten repräsentiert. Das trifft auf die Punktwolke zu, die den höchsten Detail-Grad hat und möglichst wenig Fehler, wie fehlende Teile der Szene oder Rauschen enthält. Die gewählte Punktwolke sollte nachbearbeitet werden, um etwaige Fehler wie Rauschen manuell zu entfernen.

Nun kann mit weniger Bildern aus demselben Datensatz eine weitere Punktwolke generiert werden und die Distanz der Punkte der Goldstandard-Punktwolke zum jeweils nächsten Punkt der erstellten Punktwolke gemessen werden. Die Summe dieser Abstände kann als Fehlermaß genutzt werden. Bei der Berechnung der Abstände muss beachtet werden, dass die Punktwolken mit dem Goldstandard registriert sind.

Nach einem manuellen Auswahlverfahren sind ODM und Colmap als geeignete Anwendung zur Generierung von Punktwolken gewählt worden, da diese die einzigen untersuchten Anwendungen sind, die bei wenig Bildern gute Ergebnisse erzielen, die die Szene mit allen wichtigen Details erkennen lassen. Für die manuelle Auswertung wurden auf einer Menge von 25 Bildern die Implementationen ODM, Colmap, OpenCV SfM-Pipeline, Meshroom (nutzt AliceVision) und OpenMVG miteinander verglichen. Es wurden 25 Bilder gewählt, da Experimente gezeigt haben, dass zwischen 20 bis 30



Abbildung 10: Ergebnisse auf Datensatz mit 25 Bildern. Von oben links nach unten rechts: ODM, Colmap, Meshroom, OpenMVG, OpenCV

Bilder benötigt werden um eine Pflanze von allen Seiten in einer Punktwolke abzubilden, ohne Details zu verlieren. Die generierten Punktwolken sind in Abbildung 10 zu sehen. Es ist deutlich zu erkennen, dass bis auf Colmap und ODM alle anderen Verfahren schwerwiegende Probleme in der Representation haben. Meshroom hat Probleme, feine Strukturen zu erkennen. OpenMVG generiert zu wenig Punkte und OpenCV hat ein Problem bei der Berechnung der Kamera-Pose, wodurch es zu Fehlern bei der Rekonstruktion kommt.

Zum weiteren Vergleich beider Anwendungen wird aus 73 Bildern sowohl mit Colmap als auch mit ODM eine Punktwolke generiert. Da ODM die Szene besser repräsentiert und weniger Rauschen beinhaltet, wird die mit ODM erstellte Punktwolke als Goldstandard gewählt.

Im Folgenden werden aus Teilmengen der Bilder jeweils für ODM und Colmap Punktwolken generiert. Die Teilmengen bestehen aus 5 bis 70 Bildern, wobei immer 5 Bilder mehr pro Schritt genutzt werden. Bei der Wahl der Bilder pro Schritt wird beachtet, dass die Bilder ähnliche Ausschnitte enthalten, da diese zur Generierung von Punktwolken nötig sind.

In zwei Vergleichen wurden zum einen die durchschnittliche Distanz für jeden Punkt zum nächsten Punkt in der Goldstandard-Punktwolke verglichen und zum anderen die Anzahl generierter Punkte pro Schritt. Die Ergebnisse sind in Abbildung 11 und 12 zu sehen. Es ist zu erkennen, dass Colmap zwar mehr Punkte generiert als ODM, ab einer bestimmten Anzahl Bilder überwiegt aber das Rauschen in den mit Colmap generierten

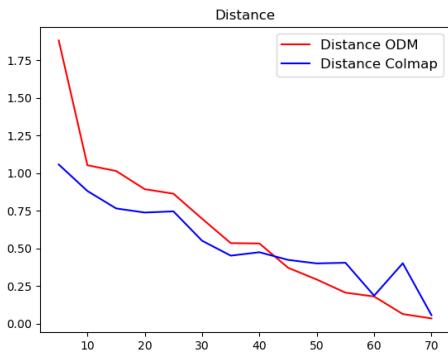


Abbildung 11: Distanz der Punktwolke mit bestimmter Anzahl Bilder zur Goldstandard-Punktwolke.

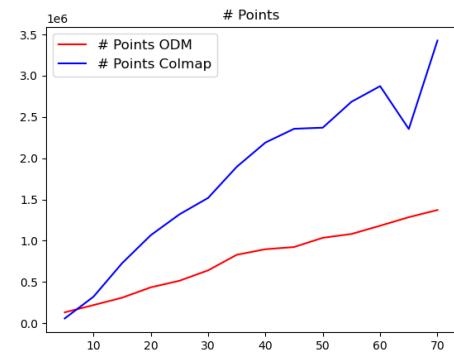


Abbildung 12: Anzahl Punkte die mit einer bestimmten Anzahl Bilder generiert werden kann.



Abbildung 13: ODM mit 40 Bildern - Ansicht von der Seite



Abbildung 14: Colmap mit 40 Bildern - Ansicht von der Seite

Punktwolken so stark, dass der Abstand zur Goldstandard-Punktwolke größer als der mit ODM erreichte Abstand wird.

Generell lässt sich in den generierten Punktwolken beobachten, dass Colmap mehr Rauschen enthält als ODM. Exemplarisch zeigen dies Abbildungen 13 und 14. Ein Nachteil von ODM ist, dass um die Kanten herum sehr viele Hintergrundpunkte mit aufgenommen werden, die eine Art Halo um die erkannten Strukturen bilden. Dadurch können feine Strukturen ineinander überfließen. Dies ist auch bei Colmap zu beobachten, allerdings nur in einem kleineren Ausmaß. Bei Colmap hat man zusätzlich das Problem, dass es zu größeren Lücken in erkannten Oberflächen kommt. Beide Probleme sind in Abbildung 15 und 16 zu sehen. Des Weiteren kann es vorkommen, dass Colmap zwei Szenen in den Bildern erkennt, was insbesondere bei Nutzung von vielen Bildern vorkommt (Abbildung 17).

Ein weiterer Aspekt bei der Bewertung des Verfahrens zur Generierung von 3D Punkt-



Abbildung 15: ODM mit 40 Bildern - Ansicht von Oben



Abbildung 16: Colmap mit 40 Bildern - Ansicht von Oben



Abbildung 17: Colmap mit 55 Bildern und doppelt erkannter Szene.

	DCP	RPM-Net	PointNetLK
Distanz	0, 0292	0, 0663	0, 026
Loss	0, 922	0, 061	0, 111

Tabelle 1: Vergleich von Registrierungsverfahren auf ModelNet40. Distanz und Loss sind jeweils Mittelwerte über alle Datensätze in der Iteration.

wolken ist die Zeit, die benötigt wird, die Punktwolke zu generieren. Hier dominiert ODM klar. Obwohl ODM, mangels der GEO-Positionen der Bilder, nur in der Lage ist die CPU parallel zu nutzen und nicht die GPU, werden die Punktwolken wesentlich schneller generiert als mit Colmap, welches die GPU nutzt und diese auch gut auslastet. ODM benötigt zur Generierung einer Punktwolke mit 73 Bildern 566 Sekunden, während Colmap für die gleiche Datenbasis 4148 Sekunden benötigt. Sollten GEO-Positionen für die Bilder bekannt sein, kann ODM die GPU nutzen und somit die Zeit die benötigt wird, die Punktwolken zu generieren, weiter verbessern.

Da ODM wesentlich weniger Rauschen beinhaltet, keine Probleme mit doppelt erkannten Szenen hat und weniger Zeit zur Generierung der Punktwolken benötigt, wird in dieser Arbeit ODM zur Generierung von Punktwolken ausgewählt, wobei die Dauer, die zur Generierung der Punktwolke benötigt wird, der ausschlaggebende Faktor für die Entscheidung ist.

4.2 Vergleich von Verfahren zur Registrierung von 3D-Punktwolken

Die Annahme, dass DCP eine gute Schätzung für die Transformations-Matrix liefern kann, hat sich, auch nach umfangreichem Training, nicht bestätigt. Auch der ICP basierte Ansatz hat nicht zum Erfolg geführt. Dies liegt in erster Linie daran, dass für jede Registrierungs-Aufgabe individuelle Parameter gefunden werden müssen. Da dies nicht praxistauglich ist, wird auch dieser Ansatz verworfen. Lediglich der letzte Ansatz hat sich in Experimenten als relativ robust heraus gestellt. Daher soll dieser Ansatz mit verschiedenen Registrierungsverfahren untersucht werden.

In einem ersten Schritt werden verschiedene Lösungen aus dem Deep-Learning Bereich miteinander verglichen um deren Güte besser einschätzen zu können. Dazu wird die Distanz zwischen transformierter Quell-Punktwolke und Ziel-Punktwolke, wie in Kapitel 3.3 beschrieben, gemessen. Neben der Distanz berichten wir über den bei der Evaluation gemessenen Loss. Die einzelnen Verfahren sind alle in dem Python-Paket learning3d [44] implementiert, nutzen die selbe Datenbasis ModelNet40 für das Training und sind somit gut vergleichbar. Für DCP und RPM-Net wird das vortrainierte Modell vom Autor des Pakets genutzt. Für PointNetLK liegt kein vortrainiertes Modell vor und wird daher mit den empfohlenen Angaben des Autors trainiert. Die Evaluation wird drei mal mit zufälligen Daten wiederholt und aus den drei Durchläufen der Mittelwert für die ermittelten Werte gebildet. Die Ergebnisse sind in Tabelle 1 veranschaulicht.

In einem zweiten Schritt werden die Verfahren, auf Basis von konkreten Beispielen der Problemstellung, miteinander verglichen. Neben DCP, RPM-Net und PointNetLK wird auch die ICP Implementation aus dem Python-Paket open3d [45] und eine weitere in

	DCP	RPM-Net	PointNetLK	ICP	RICP
Banane	0.0585	0.0129	0.1673	0.0117	0.0178
Avocado	0.0721	0.012	0.2235	0.0122	0.0245

Tabelle 2: Vergleich von Registrierungsverfahren auf konkreten Beispielen der Problemstellung. Für jede Pflanze wird die Distanz zwischen Quelle und Ziel angegeben

c++ implementierte ICP Version RICP verglichen. Hier werden exemplarisch je eine Avocado- und eine Bananenpflanze verglichen. Wie im vorherigen Vergleich wird die Distanz zur Zielpunktfolge in den Ergebnissen wiedergegeben. Die Ergebnisse sind in Tabelle 2 zu sehen und lassen erkennen, dass ICP die besten Ergebnisse für die Registrierung liefert. Die Neuronalen-Netze liefern, mit Ausnahme von RPM-Net, keine guten Ergebnisse. Die Ergebnisse für RPM-Net liegen in etwa gleich auf mit den Ergebnissen, die für ICP erreicht werden und sind besser als die Ergebnisse von RICP. Die Ergebnisse der einzelnen Registrierungsverfahren sind in Abbildung 18 zu sehen.

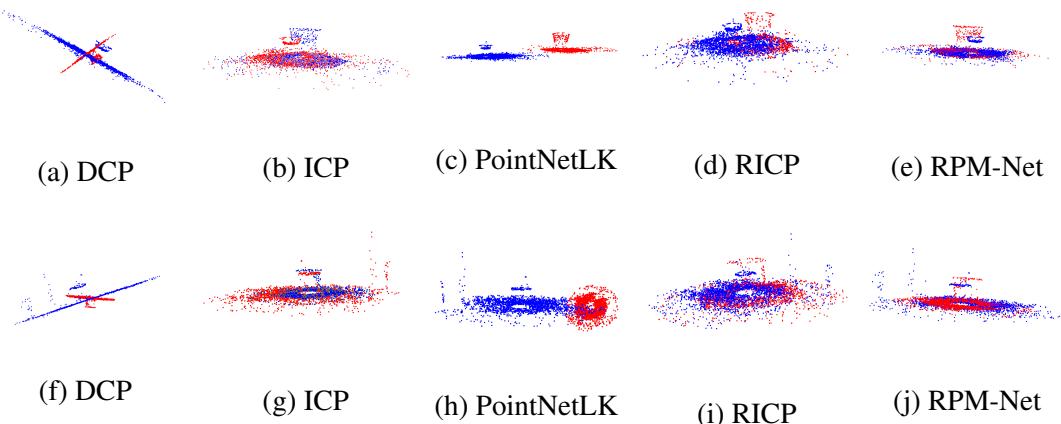


Abbildung 18: Registrierungsergebnisse für Avocado (oben) und Banane (unten)

Die Registrierungs-Ergebnisse mit iterativer Schätzung der Skalierung einer Messreihe sind in Abbildung 19 zu sehen. Die Registrierung wurde mit der ICP-Implementation von open3d durchgeführt, da diese die besten Ergebnisse liefert. Es sind kleine Fehler in der Skalierung zu erkennen, daher wird es auch bei der iterativen Schätzung der Skalierung zu Fehlern bei der Wachstumsberechnung kommen.

In den Registrierungs-Ergebnissen der Messreihe ist ein weiteres Problem zu erkennen, welches mit ICP einhergeht. ICP hat Schwierigkeiten die korrekte Translation auf Ebenen zu finden. Sind große Ebenen mit einem dominierenden Anteil an Punkten in beiden Punktfolgen vorhanden, gibt es viele Lösungen mit einem niedrigen Fehler, wenn die Ebenen aufeinander liegen. Ist die Quell-Punktwolke nun kleiner als die Ziel-Punktwolke, kann die Translation in der Ebene der Ziel-Punktwolke verschoben sein. Auch die Skalierung kann von dominanten Ebenen betroffen sein. Liegen dominante Ebenen in einer Punktwolke vor, wird die Skalierung gewählt, die die beiden Ebenen best möglich auf eine Ebene bringt. Da in der Praxis mit eher unebenen Böden zu rechnen ist, wurden einige Oberflächen generiert und auf diesen die Registrierung getestet.

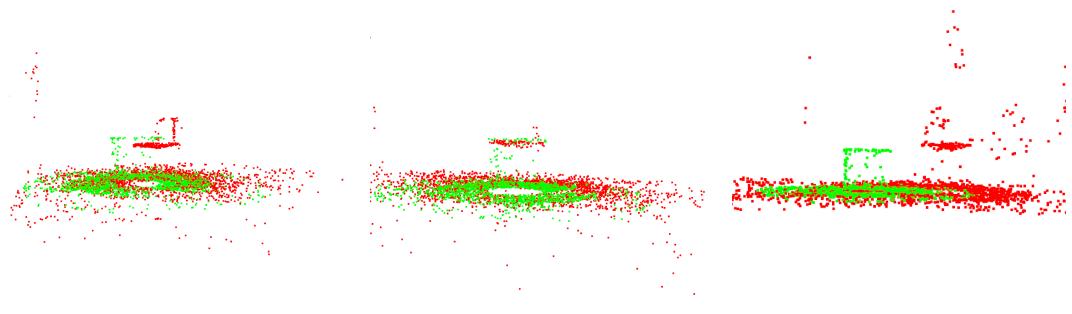
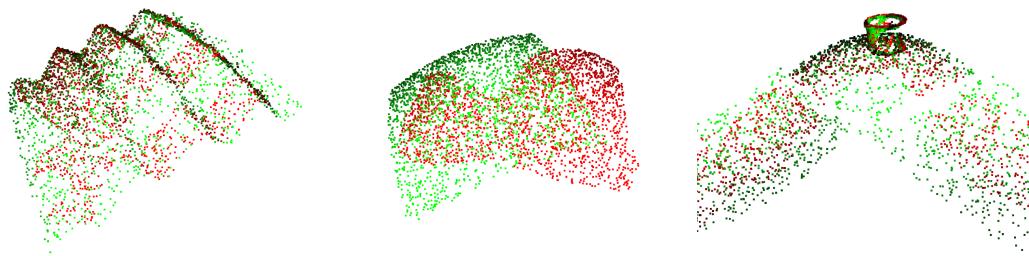


Abbildung 19: Registrierungsergebnisse für die Messreihe einer Bananenpflanze mit drei Zeitpunkten

Die Oberflächen werden mit Punkten die in einem Gitter angeordnet sind erreicht. Die Höhe der Punkten wird mit Sinus-Funktionen, basierend auf dem X-Wert der Punkte, manipuliert um Furchen und Abhänge zu simulieren. Mit Gauss-Verteilungen wird eine Wölbung auf die Oberflächen addiert. Es werden verschiedene starke Gaussverteilungen angewandt um Erosion zu simulieren. Zufällige Transformationen und Ausschnitte werden händisch erstellt.

Wie Abbildung 20a zeigt kann das bei ausgeprägten Oberflächen, wie etwa Feldfurchen, gut funktionieren. In Abbildung 20b ist ein Beispiel zu sehen, wo dies nur Teilweise gelingt. Die Translation konnte hier im Vergleich zu Ebenen deutlich verbessert werden, aber die Skalierung ist immer noch fehlerbehaftet. Platzliert man ein Objekt, wie in Abbildung 20c zu sehen, gut sichtbar in der Szene, dann gelingt die Registrierung meist. Dieses Objekt sollte eine markante Struktur haben und immer an der gleichen Position stehen.



(a) Oberfläche die Furchen
simulieren soll.
(b) Oberfläche mit
Gaussverteilung
(c) Oberfläche mit platzier-
tem Objekt

Abbildung 20: Registrierungsergebnisse für Generierte Punktwolken.

4.3 Vergleich von Verfahren zur Segmentierung von Pflanzen auf 3D-Punktwolken

In Experimenten mit dem handgeschriebenen Classifier konnte keine Parametriesierung, die eine gute Unterteilung in Blätter und Stämme erreicht, gefunden werden. Dies liegt

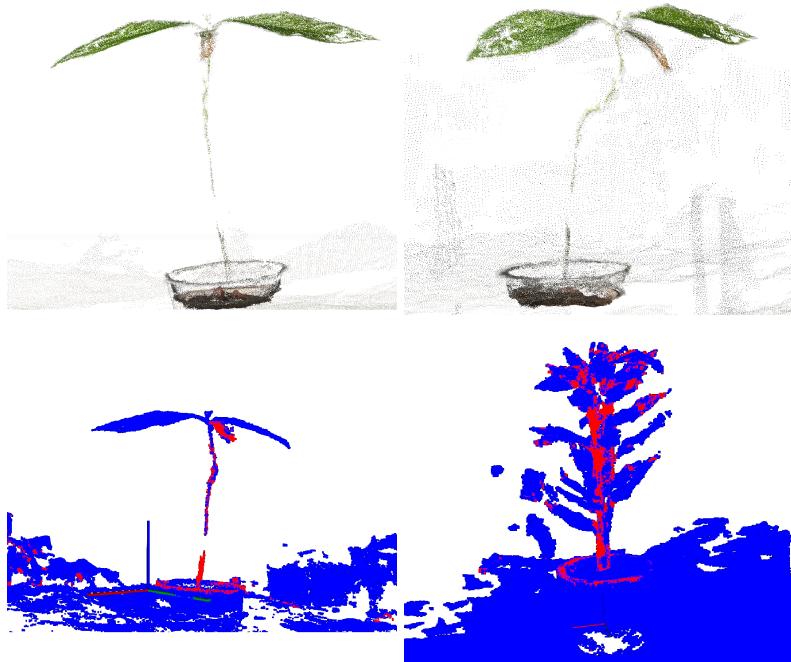


Abbildung 21: Oben: ODM Seitenansicht die als Ebene erkannten Stiel zeigt.
Unten: Segmentierungs-Ergebniss für zwei verschiedene Pflanzen mit demselben Schwellwert. Rote Punkte stehen für Stiele und blaue für Blätter.

in erster Linie an der Qualität der Punktwolken. Diese haben das Problem, dass die oft sehr feinen Stiele der Pflanze nicht als Zylinder sondern als Ebene in den Punktwolken repräsentiert werden, wie in Abbildung 21 (oben) zu sehen ist. Ein weiteres Problem ist eine allgemeingültige Parametrisierung für den Schwellwert zu finden, wie Abbildung 21 (unten) zeigt. Hier wurden mit demselben Schwellwert verschiedene Pflanzen segmentiert. Es ist zu erkennen, dass bei der linken Abbildung die Blätter (blau) bis auf eins eindeutig als solche erkannt wurden, wohingegen in der rechten Abbildung die Ergebnisse stark verrauscht sind. Des Weiteren ist in beiden Abbildungen zu erkennen, dass die Ergebnisse für den Stiel (rot) durch die nicht zylindrische Form stark verrauscht sind. Zuletzt ist bei diesem Ansatz auch zu beachten, dass es Blätter gibt, die eine ähnlich starke Krümmung wie die Stiele der Pflanze aufweisen. Dieses Phänomen ist in Abbildung 21 links unten zu sehen.

Datenbasis für das Training von PointNet++

Als Datenbasis für das Training von PointNet++ werden 144 handgelabelte Punktwolken von verschiedenen Pflanzen gewählt. Darunter sind Tomaten, Mais, Paprika, Avocado, Bananen und weitere nicht bekannte Arten. Da diese Datenbasis für das Training eines Neuronalen Netzes recht klein ist, werden aus jeder einzelnen Punktwolke bis zu 20 Subsample erstellt. Diese werden so erstellt, dass zufällig n Punkte aus einer Punktwolke gezogen und entfernt werden. Außerdem sind die Daten so aufbereitet, dass der Boden der Punktwolke an der XY-Ebene ausgerichtet ist und der Stiel bei geradem Wachstum Richtung z-Achse zeigt. Auch sind die Punkte in der Punktwolke auf 1 normiert, sie liegen also in dem Raum, den die beiden Punkte $(0, 0, 0)$ und $(1, 1, 1)$ bilden. Die

Daten werden in einem Verhältnis 80 zu 10 zu 10 in Trainings-, Test- und Evaluations-Datensatz aufgeteilt. Sowohl beim Training als auch bei der Evaluation wird die Genauigkeit, der Loss und die durchschnittliche Intersection over Union (IoU) gemessen. IoU wird über alle zu segmentierenden Klassen gemittelt. Für jede Klasse C wird dazu der Jaccard-Koeffizient $j_c(\hat{P}_c, P_c) = \frac{|\hat{P}_c \cap P_c|}{|\hat{P}_c \cup P_c|}$ gebildet, wobei \hat{P}_c die Menge an Punkten aus der Schätzung des Netzes, die als C klassifiziert werden ist und P_c die Menge der als C klassifizierten Punkte aus dem Groundtruth ist. Die angegebenen IoU-Werte sind über alle Klassen gemittelt (mIoU).

Vergleich Training mit und ohne Hintergrund

In einem ersten Vergleich wird die Güte der Segmentierung zwischen dem Training mit und ohne Hintergrund verglichen. Die Ergebnisse des Trainings sind in Abbildung 23 und 24 zu sehen. Die Ergebnisse der Evaluation zeigt Tabelle 3. Sowohl die Ergebnisse des Trainings als auch die Ergebnisse der Evaluation lassen darauf schließen, dass die Segmentierung ohne Hintergrund die besseren Ergebnisse liefert, was vermutlich daran liegt, dass der Anteil der Punkte, die zum Hintergrund gehören, dominiert. Da die Segmentierung mit Hintergrund aber zur Entfernung des Hintergrundes benötigt wird, wird in einem zweiten Vergleich die Hintergrund-Segmentierung neu trainiert. Diesmal wird jedoch ein Großteil der Hintergrund-Punkte entfernt, indem nur das Zentrum der Punkt-wolke beim Training betrachtet wird. Die Ergebnisse sind in Abbildung 25 zu sehen und lassen erkennen, dass sich die Ergebnisse für das Training mit weniger Hintergrund deutlich verbessern. Ein Vergleich der Segmentierung mit und ohne Hintergrund ist in Abbildung 22 zu sehen. Dort ist zu erkennen, dass bei der Hintergrund-Segmentierung Teile der Pflanze als Hintergrund erkannt werden. Dies betrifft vor allem den Stiel-Ansatz und niedrig hängende Blätter.

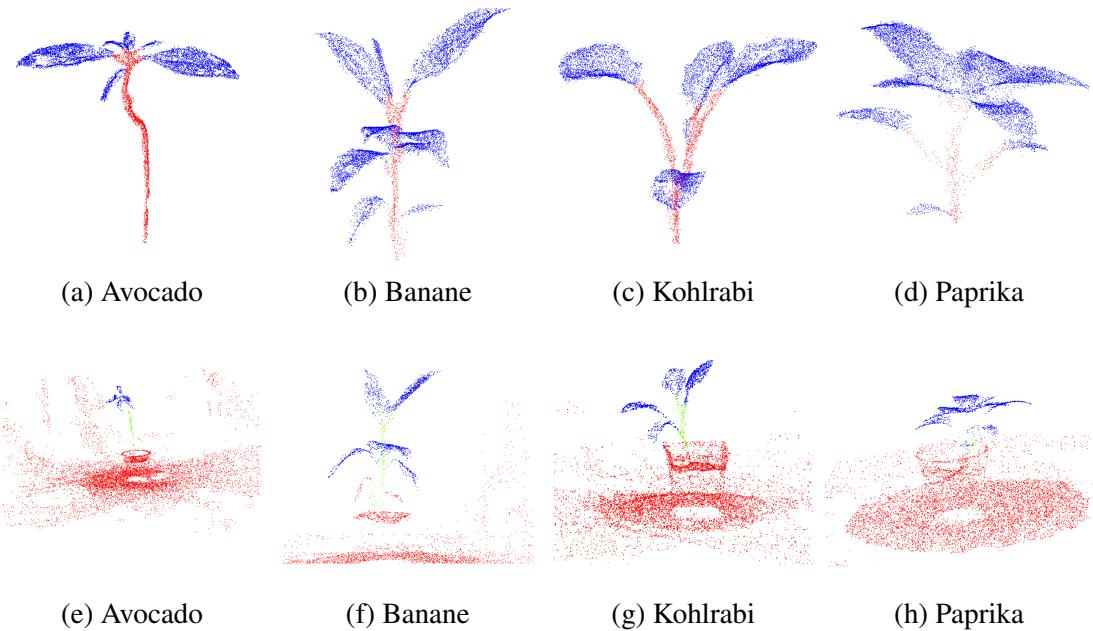


Abbildung 22: Segmentierungsergebnisse für Vordergrund(a-d) und Hintergrund(e-h)

Vergleich Training mit und ohne Normalen

	t11	t6	t10	t9	t4	t7	t12	t13
Loss	0,044	0.056	0.079	0.05	0.038	0.054	0.051	0.127
Genauigkeit	0,98	0.976	0.969	0.982	0.986	0.981	0.98	0.95
mIoU	0.925	0.908	0.893	0.811	0.813	0.788	0.841	0.827

Tabelle 3: Evaluations-Ergebnisse der verschiedenen Netze. Links ohne Hintergrund. Rechts mit Hintergrund.

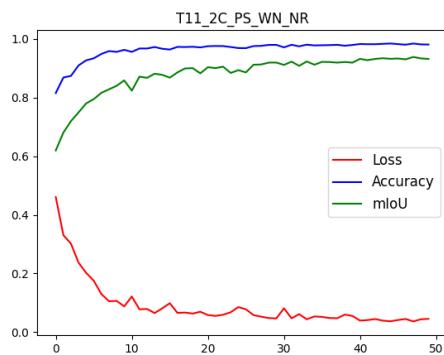


Abbildung 23: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen und Normalisierung ohne zufällige Rotationen

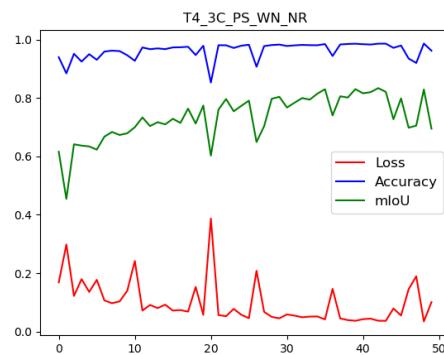


Abbildung 24: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen und Normalisierung ohne zufällige Rotationen

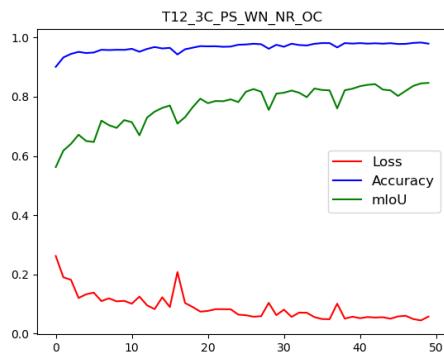


Abbildung 25: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen und Normalisierung ohne zufällige Rotationen. Mit Ausschnitt um das Zentrum.

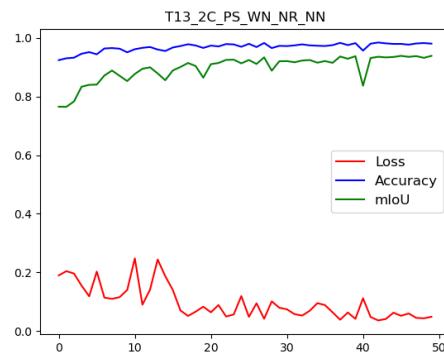


Abbildung 26: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen und Normalisierung ohne zufällige Rotationen. Ohne Normalen

	t4 mit normalisiert Daten	t4 mit nicht normalisiert Daten
Loss	0, 038	0, 175
Genauigkeit	0, 986	0, 946
mIoU	0, 81	0, 684

Tabelle 4: Vergleich der Evaluations-Ergebnisse mit normalisierten und nicht normalisierten Daten für das mit normalisierten Daten trainierten Netz t4.

Um zu überprüfen, ob sich der Einsatz von Normalen lohnt, wird PointNet++ ohne Normalen trainiert und die Ergebnisse mit den Ergebnissen des Trainings mit Normalen (Abbildung 23) verglichen. Die Ergebnisse des Trainings ohne Normalen, in Abbilung 26 zu sehen, lassen einen kleinen Unterschied zum Training mit Normalen erkennen. Mit Normalen liefern die ersten Epochen zwar schlechtere Ergebnisse, aber nach einigen weiteren Epochen gleicht sich die Güte an und es kommt zudem zu weniger Ausreißern. In den Evaluations-Ergebnissen ist auch zu erkennen, dass der mIoU-Wert für das mit Normalen trainierte Netz deutlich besser ist. Diese zwei Beobachtungen führen zu dem Schluss, dass sich der Einsatz von Normalen lohnt.

Vergleich Training mit und ohne Normalisierung

Es soll überprüft werden, ob PointNet++ mit oder ohne Normalisierung bessere Ergebnisse liefert. Des Weiteren soll geprüft werden, ob auch nichtnormalisierte Eingabedaten gute Segmentierungs-Ergebnisse liefern, wenn PointNet++ mit normalisierten Daten trainiert wird. Dieser Vergleich wird aufgestellt, da die Punktwolken für die Segmentierung auf eine bestimmte Anzahl Punkte reduziert werden und das Ergebnis - zumindest bei der Hintergrund-Segmentierung - zurück auf die vollständige Punktwolke übertragen werden muss. Muss die Punktwolke nicht normalisiert werden, kann das Ergebniss direkt auf die vollständige Punktwolke übertragen werden. Im Falle einer Normalisierung müsste diese erst umgekehrt werden, aber diese Information wird von PointNet++ nicht zur Verfügung gestellt und müsste ermittelt werden. Alternativ dazu könnten auch die Ergebnisse von der normalisierten Punktwolke auf die nicht normalisierte Punktwolke übertragen werden, was aber mit mehr Rechenaufwand verbunden ist.

Wird die Normalisierung komplett verhindert, kann das Auswirkungen auf die Güte der Ergebnisse der Segmentierung haben.

In Tabelle 4 werden die Ergebnisse der Evaluation von PointNet++ zwischen nicht normalisierten Daten und normalisierten Daten nach dem Training mit normalisierten Daten verglichen. Da die Ergebnisse sich für die Segmentierung mit Hintergrund stark verschlechtern, wenn die Daten nicht normalisiert werden, wird PointNet++ ohne Normalisierung erneut trainiert. Die Ergebnisse für das erneute Training sind in Abbildung 27 für zwei Klassen und in Abbildung 28 für drei Klassen zu sehen.

Gegenüber dem Training mit Normalisierung fällt das Training ohne Normalisierung etwas schlechter aus. Insbesondere für das Netz mit drei Klassen haben die Ausreißer für Loss-, Genauigkeit- und mIoU-Werte zugenommen. Auch die Evaluations-Ergebnisse lassen darauf schließen, dass der Einsatz von Normalisierung lohnenswert ist. Das führt zu dem Schluss, dass PointNet++ mit Normalisierung genutzt werden sollte und der

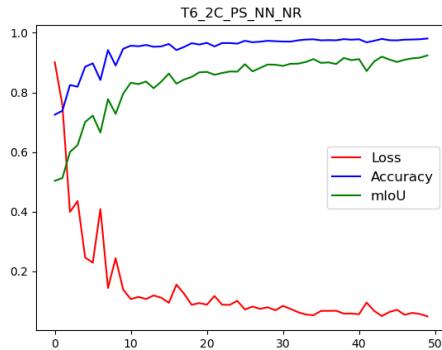


Abbildung 27: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen, ohne Normalisierung und ohne zufällige Rotationen

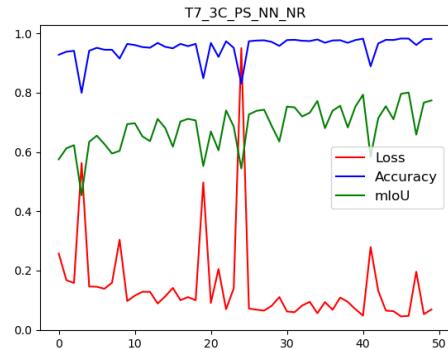


Abbildung 28: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen, ohne Normalisierung und ohne zufällige Rotationen

zusätzliche Rechenaufwand zum Übertragen der Ergebnisse auf die vollständige Punkt-wolke in Kauf genommen werden sollte.

Vergleich Training mit und ohne zufällige Rotationen

Die Tests des Servers haben gezeigt, dass es bei der Segmentierung der freigestellten Pflanzen zu starken Fehlern kommt, wenn diese zufällig rotiert sind, wie in den Abbildungen 31 und 32 zu sehen ist. Wird die Evaluation eines ohne zufällig rotierte Punktwolken trainierten Netzes mit zufällig rotierten Punktwolken ausgeführt, sinkt der mIoU-Wert von 0,925 auf 0,6 und die Genauigkeit von 0,98 auf 0,875. Da dieser Unterschied signifikant ist, ist davon auszugehen, dass PointNet++ anfällig für Rotationen ist, wenn diese im Training nicht berücksichtigt wurden.

Aus diesem Grund wird das Training für das Zwei- und Drei-Klassen-Netz mit zufälligen Rotationen wiederholt, um eine Robustheit gegen Rotationen anzutrainieren. Die Ergebnisse für das Zwei-Klassen-Netz sind in Abbildung 29 zu sehen, die Ergebnisse für das Drei-Klassen-Netz in Abbildung 30. Beim Training des Netzes mit drei Klassen sind starke Ausreißer in den Loss-Werten zu erkennen, die sich auch in der Genauigkeit und dem mIoU - wenn auch nicht so stark - widerspiegeln. Diese Beobachtung kann man für das Zwei-Klassen-Netz nur in wesentlich kleinerem Ausmaß feststellen. Dennoch sind die Ergebnisse für das Training mit zufälligen Rotationen wesentlich schlechter als die des Trainings ohne zufällige Rotationen. Im Einsatz sollte also bei der Entfernung des Hintergrundes darauf geachtet werden, dass dieser zumindest grob an der XY-Ebene ausgerichtet ist.

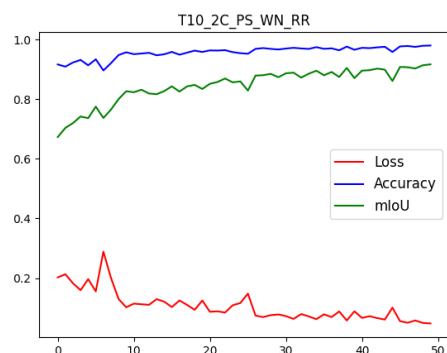


Abbildung 29: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen, mit Normalisierung und zufälliger Rotationen

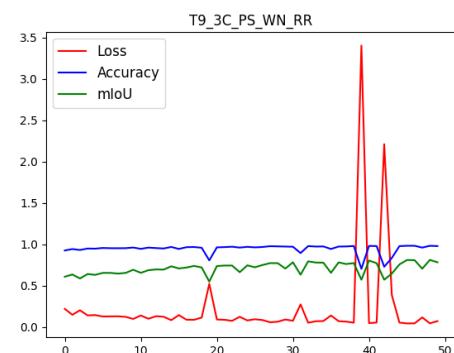


Abbildung 30: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen, mit Normalisierung und zufälliger Rotationen

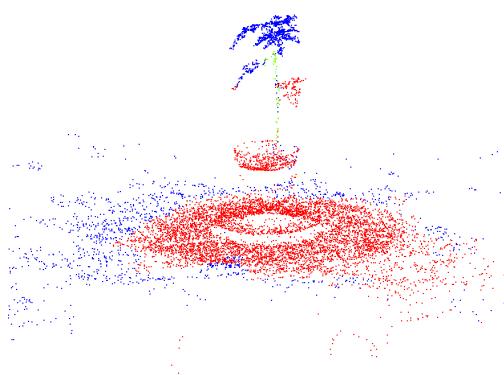


Abbildung 31: Durch Rotation verursachte fehlgeschlagene Segmentierung einer Tomaten-Pflanze.

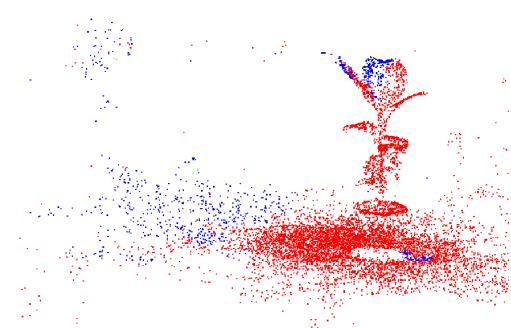


Abbildung 32: Durch Rotation verursachte fehlgeschlagene Segmentierung einer Bananen-Pflanze.

5 Fazit und Ausblick

Generierung der Punktwolken

Die Generierung von Punktwolken mit ODM liefert zwar gute Ergebnisse und ist vergleichsweise schnell. Allerdings ist es dennoch die Komponente, die am meisten Laufzeit in Anspruch nimmt. Da keine Geo-Informationen zu den Bildern vorliegen, kann die GPU von ODM nicht eingesetzt werden. An der Stelle könnte ODM erweitert werden und die alternative Implementierung, die ohne Geo-Informationen auskommt, könnte parallelisiert werden.

Sollte sich in Zukunft bei Smartphones eine RGB-D Kamera als Standard etablieren, ließe sich diese Technologie nutzen, um eine schnelle Generierung der Punktwolken zu ermöglichen. Hierbei müsste allerdings beachtet werden, dass es bei schwankenden Belichtungs-Verhältnissen zu Problemen kommen kann.

Ein weiterer Ansatz, der untersucht werden könnte, ist die Generierung von Punktwolken mit Neuronalen Netzen. Hier gibt es einige interessante Ansätze, die im Rahmen dieser Arbeit nicht untersucht wurden. Diese Ansätze ermöglichen es, aus einem Bild eine Punktwolke zu generieren, was dem Ziel, die zu übertragende Datenmenge gering zu halten, entgegen kommt. Dazu würden sie vorraussichtlich nach dem Training schnellere Laufzeiten als ODM liefern. Ein Nachteil dieser Implementationen ist, dass diese meist nur wenige 1000 Punkte effizient berechnen können, was zu SfM-Implementation wie ODM einen Nachteil darstellt. ODM kann je nach Datenbasis einige 100000 Punkte berechnen. Um dem entgegen zu wirken könnten aus verschiedenen Perspektiven Bilder aufgenommen werden aus denen separat Punktwolken generiert werden. Diese Punktwolken könnten mittels Registrierung zu einer fusioniert werden, was den Nachteil kompensieren könnte.

Registrierung

Die Ergebnisse der Registrierung sind zwar für den Zweck, die Punktwolken auf die selbe Größe zu skalieren, ausreichend, könnten aber zuverlässiger und genauer sein. Insbesondere beim Schätzen der Skalierung kommt es noch zu Fehlern, allerdings ähneln sich die Fehler in den einzelnen Messreihen zumeist und daher können die Ergebnisse genutzt werden. Trotzdem ist mit Fehlern zu rechnen.

Bei der Datengewinnung könnte zu den Bildern auch eine GPS-Position ermittelt und auf diese Weise Punktwolken mit gleichem Maßstab erstellt werden. Das würde die Registrierung erleichtern, da die Skalierung nicht mehr geschätzt werden müsste. Zudem könnte so die exakte Größe der Pflanze berechnet werden und damit auch der totale Größenunterschied zwischen zwei Wachstums-Zeitpunkten einer Pflanze. Außerdem würde die Generierung der Punktwolken mit ODM beschleunigt, da die GPU von ODM genutzt werden könnte.

Ein weiterer Ansatz, der in dieser Arbeit nicht verfolgt wurde, ist ScaleLK. ScaleLK hat eine ähnliche Architektur wie PoinNetLK, allerdings wird neben Rotation und Translation auch eine Schätzung für die Skalierung geliefert.

Ein letzter Ansatz, der nicht zur Gänze untersucht wurde, ist es, RPM-Net mit dem

Ansatz in [35] zu verbinden. Hierbei wird die Architektur von RPM belassen, allerdings wird, nach dem die Rotation bekannt ist, die Skalierung, wie in den Gleichungen 17 und 18 beschrieben, berechnet. Des Weiteren muss die Berechnung der Translation, wie in Gleichung 19, angepasst werden. Für das Training des angepassten Netzes müssen auch die Trainings-Daten überarbeitet werden. Zu jedem Trainings-Datensatz muss eine zufällige Skalierung hinzugefügt werden. Dieses Vorgehen wurde im Ansatz implementiert, wird aber aktuell noch untersucht und daher nicht in dieser Arbeit behandelt.

Segmentierung

Für die Hintergrundentfernung ist die Segmentierung noch recht fehleranfällig. Hier könnte probiert werden, mit einem größeren Datensatz zu trainieren, mehr Punkte während des Trainings zu nutzen oder - wie untersucht - nur einen Ausschnitt um das Zentrum der Punktwolke zu segmentieren.

Der untersuchte Ansatz, einen Ausschnitt aus der Szene um dessen Zentrum zu nehmen, wirkt sich zwar positiv auf die Ergebnisse aus, aber wird im praktischen Einsatz auf das Problem stoßen, dass nicht garantiert werden kann, dass der relevante Teil der Szene ausgeschnitten wird. Statt dessen könnte die Szene als Ganzes im Vorfeld untersucht und so relevante Bereiche ermittelt werden. Szenen-Segmentierung ist mittels Point-Net++ möglich, hier müssten nur geeignete Daten gesammelt werden, die dem Einsatz in der Realität entsprechen. So könnten auch einzelne Pflanzen isoliert untersucht werden sowie der Einfluss, den die Pflanzen beim Wachstum aufeinander haben. Neben Nutzpflanzen könnten bei einer Szenen-Segmentierung auch Unkräuter erkannt werden und deren Wachstum unter bestimmten Bedingungen, analysiert werden.

Ebenfalls kann die Segmentierung der Pflanze erweitert werden, um zusätzliche Informationen über eine Pflanze zu erhalten. Zum Beispiel können neben Blättern und Stielen auch Blüten und Früchte erkannt werden, was für die Analyse des Ertrags einer Fruchtfolge genutzt werden könnte. Um das zu bewerkstelligen, muss für jedes Merkmal ein weiteres Label hinzugefügt und die Datenbasis, die für das Training genutzt wird, um Punktwolken erweitert werden, die diese Merkmale auch beinhalten.

Bisher wurden beim Training die Farbe nicht mit einbezogen. Auch diese könnte zusätzlich genutzt werden um weitere Informationen, wie den Zustand einzelner Segmente der Pflanze, zu erkennen. Die Farbe kann bei Früchten Aufschluss über den Reifegrad geben und bei Blättern und Stamm Anzeichen von Krankheiten erkennen lassen.

Server

Um die Performance des Servers zu steigern könnte für die in c++ implementierten Funktionalitäten ein Python-Binding erstellt werden oder die Funktionalitäten in Python-Code portiert werden. Bisher werden diese Funktionalitäten über System-Kommandos angesteuert. Mit einem Python-Binding oder einer entsprechenden Portierung könnten diese direkt aus dem Python-Code angesprochen werden. Dadurch könnten die Daten zwischen den einzelnen Pipelines im Hauptspeicher gehalten werden und müssten nur noch zu Persistierungs-Zwecken auf der Festplatte abgelegt werden.

Da der Server keine Sicherheitsmechanismen zur Verfügung stellt, ist von einem Ein-

satz in der Praxis in diesem Zustand abzuraten. Zum Schutz der Schnittstellen vor Missbrauch sollte mindestens ein User-Management hinzugefügt werden. Auch die parametrisierten System-Aufrufe sollten vor Schadcode-Injektion geschützt werden um zu vermeiden, dass ein Angreifer Zugriff auf das Host-System erlangt.

Übergreifend

Rückblickend betrachtet konnte eine gute Basis geschaffen werden, auf der weiter aufgebaut werden kann. Es stehen erste Funktionalitäten bereit, die eine Analyse des Wachstums-Prozesses einer Pflanze ermöglichen. Die Anwendung ist zudem so designed, dass weitere Funktionalitäten leicht zu integrieren sind, somit ist die Anwendung erweiterbar. Da auch die Zwischenergebnisse der einzelnen Pipelines persistiert werden, können auch neue Funktionalitäten geschaffen werden, die auf diesen aufbauen. Lediglich bei der Registrierung der Punktwolken konnte nicht abschließend beantwortet werden, ob die Anwendung in der Praxis robust arbeiten wird. Dies hängt davon ab, wie die Szenen aufgekommen werden. Sollten mehrere Objekte platziert werden und der Boden zumindest einige Wölbungen aufweisen, sollte die Registrierung funktionieren. Auch die Segmentierung des Hintergrundes könnte noch weiter verbessert werden. Die Segmentierung der Pflanzen hingegen hat sehr gute Ergebnisse geliefert und sollte um weitere Merkmale erweitert werden.

In diesem Zustand ist die Software für einen praktischen Einsatz nur bedingt bereit, da einige Problematiken, die sich in der Praxis ergeben können, noch nicht untersucht wurden. So wird beispielsweise bisher immer davon ausgegangen, dass einzelne Pflanzen isoliert betrachtet werden. Das wird in der Praxis aber nicht der Fall sein, da auch ganze Felder mit mehreren Pflanzen untersucht werden sollen. Auch der Einfluss, den das Wetter bei der Aufnahme der Bilder haben kann, wurde bisher nicht untersucht. Ist es beispielsweise sehr windig bei der Aufnahme von Bildern und bewegt sich die Pflanze dadurch, führt dies zu Fehlern bei der Generierung der Punktwolke.

Literatur

- [1] I. Masih, S. Maskey, F. Mussá, and P. Trambauer, “A review of droughts on the african continent: A geospatial and long-term perspective,” *Hydrology and Earth System Sciences*, vol. 18, pp. 3635–3649, 09 2014.
- [2] N. Mehendale and S. Neoge, “Review on lidar technology,” *ssrn preprint ssrn:3604309*, 2020.
- [3] A. Taneja, “Top 10 smartphones with a dedicated depth sensor camera to capture perfect bokeh shots,” 2020.
- [4] D. Robertson and R. Cipolla, “Practical image processing and computer vision - chapter 13 structure from motion,” 2008.
- [5] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *International journal of computer vision*, vol. 60, no. 2, pp. 91–110, 2004.
- [6] H. Bay, A. Ess, T. Tuytelaars, and L. Van Gool, “Speeded-up robust features (surf),” *Computer vision and image understanding*, vol. 110, no. 3, pp. 346–359, 2008.
- [7] M. Calonder, V. Lepetit, C. Strecha, and P. Fua, “Brief: Binary robust independent elementary features,” in *European conference on computer vision*, pp. 778–792, Springer, 2010.
- [8] E. Rublee, V. Rabaud, K. Konolige, and G. Bradski, “Orb: An efficient alternative to sift or surf,” in *2011 International conference on computer vision*, pp. 2564–2571, Ieee, 2011.
- [9] C. D. Singh, “Structure from motion - the traditional approach,” 2021.
- [10] X. X. Lu, “A review of solutions for perspective-n-point problem in camera pose estimation,” in *Journal of Physics: Conference Series*, vol. 1087, p. 052009, IOP Publishing, 2018.
- [11] B. Triggs, P. F. McLauchlan, R. I. Hartley, and A. W. Fitzgibbon, “Bundle adjustment—a modern synthesis,” in *International workshop on vision algorithms*, pp. 298–372, Springer, 1999.
- [12] J. L. Schönberger and J.-M. Frahm, “Structure-from-motion revisited,” 2016.
- [13] J. L. Schönberger, E. Zheng, M. Pollefeys, and J.-M. Frahm, “Pixelwise View Selection for Unstructured Multi-View Stereo,” in *European Conference on Computer Vision (ECCV)*, 2016.
- [14] pierotofy, “Open drone map - a command line toolkit to generate maps, point clouds, 3d models and dems from drone, balloon or kite images.,” 2020.
- [15] alalek, “Structure from motion module,” 2016.
- [16] P. Moulon, P. Monasse, and R. Marlet, “Adaptive structure from motion with a contrario model estimation,” in *Proceedings of the Asian Computer Vision Conference (ACCV 2012)*, pp. 257–270, Springer Berlin Heidelberg, 2012.

- [17] M. Jancosek and T. Pajdla, “Multi-view reconstruction preserving weakly-supported surfaces,” in *CVPR 2011*, IEEE, jun 2011.
- [18] P. Moulon, P. Monasse, R. Perrot, and R. Marlet, “Openmvg: Open multiple view geometry,” in *International Workshop on Reproducible Research in Pattern Recognition*, pp. 60–74, Springer, 2016.
- [19] R. Arandjelović and A. Zisserman, “Three things everyone should know to improve object retrieval,” in *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2911–2918, IEEE, 2012.
- [20] K. Mikolajczyk and C. Schmid, “An affine invariant interest point detector,” in *European conference on computer vision*, pp. 128–142, Springer, 2002.
- [21] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [22] H. Fan, H. Su, and L. Guibas, “A point set generation network for 3d object reconstruction from a single image,” 2016.
- [23] M. Tatarchenko, A. Dosovitskiy, and T. Brox, “Octree generating networks: Efficient convolutional architectures for high-resolution 3d outputs,” 2017.
- [24] N. Wang, Y. Zhang, Z. Li, Y. Fu, W. Liu, and Y.-G. Jiang, “Pixel2mesh: Generating 3d mesh models from single rgb images,” 2018.
- [25] Y. Xia, C. Wang, Y. Xu, Y. Zang, W. Liu, J. Li, and U. Stilla, “Realpoint3d: Generating 3d point clouds from a single image of complex scenarios,” *Remote Sensing*, vol. 11, no. 22, 2019.
- [26] I. Ziatsov and S. Navlakha, “Machine Learning Approaches to Improve Three Basic Plant Phenotyping Tasks Using Three-Dimensional Point Clouds1[OPEN],” *Plant Physiology*, vol. 181, pp. 1425–1440, 10 2019.
- [27] W. Gélard, M. Devy, A. Herbulet, and P. Burger, “Model-based segmentation of 3d point clouds for phenotyping sunflower plants,” in *12. International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications*, 2017.
- [28] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, “Pointnet: Deep learning on point sets for 3d classification and segmentation,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 652–660, 2017.
- [29] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, “Pointnet++: Deep hierarchical feature learning on point sets in a metric space,” *arXiv preprint arXiv:1706.02413*, 2017.
- [30] Y. Wang, Y. Sun, Z. Liu, S. E. Sarma, M. M. Bronstein, and J. M. Solomon, “Dynamic graph cnn for learning on point clouds,” *ACM Transactions on Graphics (TOG)*, 2019.
- [31] P. J. Besl and N. D. McKay, “Method for registration of 3-d shapes,” in *Sensor fusion IV: control paradigms and data structures*, vol. 1611, pp. 586–606, International Society for Optics and Photonics, 1992.

- [32] J. Yang, H. Li, D. Campbell, and Y. Jia, “Go-icp: A globally optimal solution to 3d icp point-set registration,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, p. 2241–2254, Nov 2016.
- [33] J. Zhang, Y. Yao, and B. Deng, “Fast and robust iterative closest point,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021.
- [34] K. Derpanis, “Overview of the ransac algorithm,” 2005.
- [35] T. Zinßer, J. Schmidt, and H. Niemann, “Point set registration with integrated scale estimation,” in *Point Set Registration with Integrated Scale Estimation*, 2005.
- [36] S. Xu and Y. Shang, “ScaleLK: Registration of point clouds with different scales using deep learning methods,” *IOP Conference Series: Materials Science and Engineering*, vol. 768, p. 072089, mar 2020.
- [37] Y. Wang and J. M. Solomon, “Deep closest point: Learning representations for point cloud registration,” in *The IEEE International Conference on Computer Vision (ICCV)*, October 2019.
- [38] Y. Aoki, H. Goforth, R. A. Srivatsan, and S. Lucey, “Pointnetlk: Robust and efficient point cloud registration using pointnet,” 2019.
- [39] Z. J. Yew and G. H. Lee, “Rpm-net: Robust point matching using learned features,” *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun 2020.
- [40] B. Lucas and T. Kanade, “An iterative image registration technique with an application to stereo vision (ijcai),” vol. 81, 04 1981.
- [41] S. Gold, C.-P. Lu, A. Rangarajan, S. Pappu, and E. Mjolsness, “New algorithms for 2d and 3d point matching: Pose estimation and correspondence,” *Advances in neural information processing systems*, pp. 957–964, 1995.
- [42] R. Hänsch, T. Weber, and O. Hellwich, “Comparison of 3d interest point detectors and descriptors for point cloud fusion,” *ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. II-3, 09 2014.
- [43] R. Sears, C. Van Ingen, and J. Gray, “To blob or not to blob: Large object storage in a database or a filesystem?,” *arXiv preprint cs/0701168*, 2007.
- [44] V. Sarode, “Learning3d: A modern library for deep learning on 3d point clouds data.,” 2021.
- [45] Q.-Y. Zhou, J. Park, and V. Koltun, “Open3d: A modern library for 3d data processing,” *arXiv preprint arXiv:1801.09847*, 2018.