

Analyse von Pflanzenwachstum auf Basis von 3D-Punktwolken

Masterarbeit
zur Erlangung des Grades *Master of Science*

an der
Hochschule Niederrhein
Fachbereich Elektrotechnik und Informatik
Studiengang *Informatik*

vorgelegt von
Jakob Görner
1003660

Datum: 25. Oktober 2021

Prüfer: Prof. Dr. Regina Pohle-Fröhlich
Zweitprüfer: Prof. Dr. Christoph Dalitz

Eidesstattliche Erklärung

Name: Jakob Görner

Matrikelnr.: 1003660

Titel: Analyse von Pflanzenwachstum auf Basis von 3D-Punktwolken

Ich versichere durch meine Unterschrift, dass die vorliegende Arbeit ausschließlich von mir verfasst wurde. Es wurden keine anderen als die von mir angegebenen Quellen und Hilfsmittel benutzt.

Die Arbeit besteht aus 36 Seiten.

Mönchengladbach, 25. Oktober 2021

Unterschrift

Zusammenfassung

In dieser Arbeit soll eine Anwendung zum Analysieren von Pflanzen-Wachstum und weiteren Merkmalen des Wachstumsprozesses einer Pflanze erstellt werden. Es soll aus einer Reihe Bilder einer Pflanze, die mit einer gängigen Smartphone-Kamera aufgenommen sind, eine Punktwolke erzeugt werden. Aus der Punktwolke sollen die Punkte die zur Pflanze gehören extrahiert werden. Die extrahierten Punkte werden zur weiteren Analyse in Stamm und Blatt Punkte segmentiert. Des weiteren sollen Werte wie das Wachstum der Pflanze ermittelt werden. Hierzu müssen mehrere Punktwolken über Zeit miteinander verglichen werden. Die Anwendung soll mit möglichst wenig Bildern auskommen um den Datentransfer zu minimieren.

Abstract

Development of an application made to analyse plant growth over time and further characteristics of a plant represented as a point cloud. The point cloud should be generated out of a set of images of the plant, taken with a common smartphone. The point cloud should be splitted in leave and stem points to count leaves and analyse the stem further. Also other characteristics as the hight should be analysed. For this reason multiple point clouds has to be compared over time. The application should use as few pictures as possible to reduce the amount of transferred data.

Inhaltsverzeichnis

1 Motivation	3
2 Stand der Technik	4
2.1 Generierung einer 3D Punktwolke aus Bildern	4
2.2 Segmentierung von 3D-Punktwolken	8
2.3 Registrierung von 3D-Punktwolken	10
3 Realisierung	13
3.1 Architektur	13
3.2 Umsetzung Generierung einer 3D Punktwolke aus Bildern	14
3.3 Umsetzung Registrierung zweier Punktwolken	14
3.4 Umsetzung Segmentierung	16
3.5 Umsetzung Server	17
3.6 Umsetzung Pipelines	19
4 Ergebnisse	22
4.1 Vergleich von Verfahren zur Generierung von 3D-Punktwolken auf Basis von Bildern	22
4.2 Vergleich von Verfahren zur Registrierung 3D-Punktwolken	25
4.3 Vergleich von Verfahren zur Segmentierung von Pflanzen auf 3D-Punktwolken	26
5 Fazit und Ausblick	32
Literatur	34

1 Motivation

Diese Arbeit wird im Rahmen eines Projekts mit den Universitäten Makerere University (Kampala, Uganda) und Central University of Technology (Bloemfontein, South Africa) durchgeführt. Im Rahmen dieser Arbeit soll eine Anwendung entstehen, die in den beiden Ländern für Kleinbauern zum Einsatz kommen soll. Die Anwendung soll mit nicht invasiven Methoden zur Unterstützung bei der selektiven Züchtung eingesetzt werden, um Erträge und somit auch Gewinnmargen zu erhöhen und damit zur Ernährungssicherheit beizutragen. Dies ist nötig, da es im Rahmen der derzeitigen Klimaveränderungen zu höheren Ernteausfällen durch Dürren kommt [1] die durch reinen Einsatz von indigenem Wissen nicht zu kompensieren sind.

Um diesem Ziel näher zu kommen soll in dieser Arbeit eine Software entwickelt werden die es erlaubt Daten über den Wachstums-Prozess von Pflanzen zu sammeln. Diese soll als Grundlage für weiter Analysen wie das frühe Erkennen von Krankheitsbildern, Ertragsschätzungen oder Erkennen unzureichende Wachstumsraten der Pflanzen dienen.

Ziel ist es also eine Software zu schaffen die es ermöglicht aus Bildern von Pflanzen 3D Punktwolken (Punktwolken) zu generieren und diese zu analysieren. Es soll mit der zu entwickelnden Anwendung möglich sein Aussagen über das Wachstum über Zeit, die Entwicklung der Blätter und der Stämme zu treffen. Mit diesen Daten sind Analysen möglich die auf das Wachstum einer Pflanze unter bestimmten Bedingungen schließen lassen. Hierbei gibt es besondere Anforderungen an den Prozess der Datengewinnung und Übertragung. Zum einen muss der Betrieb kostengünstig sein - das betrifft insbesondere den Endverbraucher. Der Endverbraucher sollte möglichst wenig Datenmengen an den Server, der die Rechenkapazität bereit stellt übertragen müssen. Das soll die Kosten auf Seiten der Kleinbauern gering halten. Des weiteren muss die Datengewinnung mit einem Mobiltelefon oder einer anderen Kamera möglich sein. Spezielle Aufnahmegeräte, wie ein LIDAR-Scanner, die den Kleinbauern nicht schon zur Verfügung stehen sollten nicht nötig sein.

2 Stand der Technik

Drei Kernprobleme müssen betrachtet werden, die für den Erfolg dieser Arbeit gelöst werden müssen. Zuerst muss aus einer Menge an Bildern eine Punktwolke generiert werden. Danach muss die Punktwolke segmentiert werden um den Hintergrund zu entfernen und die einzelnen Teile der Pflanze wie Blätter und Stiele zu erkennen und weiter zu analysieren. Zuletzt müssen zwei Punktwolken einer Pflanze zu verschiedenen Zeitpunkten miteinander registriert werden um Aussagen über das Wachstum einer Pflanze treffen zu können.

2.1 Generierung einer 3D Punktwolke aus Bildern

Generell kann man zwischen zwei Methoden der Generierung von Punktwolken unterscheiden, die jeweils verschiedene Verfahren beziehungsweise Techniken anwenden.

Die erste Methode nutzt Hardware wie LIDAR-Scanner [2] um Punktwolken direkt zu erzeugen. Es gibt eine Reihe von Sensoren die das ermöglichen. Da der Großteil der Sensoren aus kostengründen nicht in Frage kommt sei hier nur noch der RGB-D-Sensor erwähnt. Dieser liefert neben den Farbwerten für ein Bild auch noch eine Tiefeninformation für jeden Pixel. In einigen Smartphone-Modellen wird bereits ein solcher Sensor verbaut [3]. Ein Nachteil bei RGB-D Sensoren ist aber dass sie anfällig für Änderungen der Lichtverhältnisse sind. Was gerade im Außenbereich häufig vorkommt.

Die andere Methode ist Structure from Motion (SfM), bei der die Punktwolke aus Bildern, einer Szene aus verschiedenen Perspektiven, generiert wird. Allgemein werden auf den zugrundeliegenden Bildern nach Merkmalen (Feature) gesucht die robust gegen Translation, Rotation, Skalierung und Beleuchtung seien sollten. Generell ist das ermitteln von geeigneten Feature in zwei Teile zu unterteilen, die Feature-Erkennung und Beschreibung. Bei der Feature-Erkennung müssen geeignete Punkte im Bild als Kandidaten für Feature-Punkte ermittelt werden. Sind geeignete Kandidaten gewählt worden, müssen diese beschrieben werden, also ein Deskriptor für den Punkt gefunden werden. Hier kann man die bekanntesten Umsetzungen in zwei Bereiche unterteilen. Umsetzungen wie Scale Invariant Feature Transformation (SIFT) [4] und Speeded Up Robust Features (SURF) [5] beschreiben einen Feature-Punkt als einen Vektor der aus Gradienten-Histogrammen um den Punkt herum gebildet wird. Binary Robust Independent Elementary Features (BRIEF) [6] und FAST and Rotated BRIEF (ORB) [7] nutzen statt dessen einen binären Deskriptor um den Feature-Punkt zu beschreiben. Hierbei werden die Intensitäts-Differenzen bestimmter Punkt-Paare in einem Bereich um den Punkt mit einem Schwellwert verglichen und so der binäre Deskriptor gebildet.

SIFT ist der wohl bekannteste Ansatz und wird häufig als Goldstandard verwendet um Verfahren miteinander zu vergleichen. Hat allerdings den Nachteil dass es zu langsam für Echtzeitanwendung ist. SIFT ermittelt die Kandidaten-Punkte im Kern mittels dem Differenz of Gaussians Verfahren (DoG). DoG besteht aus drei Schritten. Im ersten Schritt wird das Bild in verschieden starken Stufen ein Weichzeichner (diskreter Gauß-Filter) angewandt. Damit liegt das Bild mit zunehmend niedrigeren Kontrast vor. Zwischen den einzelnen Kontraststufen wird die Differenz ermittelt. Liegen die Differenzen vor kann nach Extrempunkten in den Differenzen gesucht werden. Hierbei wird für jeden

Pixel im Bild mit seinen direkten Nachbarn und denen in den benachbarten Stufen verglichen. Ist er ein Extrempunkt wird er als Kandidat gewählt. DoG wird auf mehreren Skalierungen des Bild angewandt um Skalierungs-Invarianz zu erreichen. Im Anschluss werden die Kandidaten noch gefiltert. Kandidaten die einen niedrigen Intensitätswert haben oder eine Kante darstellen werden hierbei ausgeschlossen. Sind die Positionen der Feature bekannt, kann der Feature-Vektor f für den Punkt p ermittelt werden. Um den Deskriptor für den Punkt p zu berechnen werden zwei Größen benötigt. Zum einen die Skalierung in der der Feature ermittelt wurde - diese ist bereits bekannt - und die Orientierung des Punktes. Um diese zu bestimmen wird in einem Bereich um den Punkt p die Gradienten berechnet und in ein Histogramm abgetragen. Der Histogramm-Eintrag mit dem größten Wert entscheidet die Orientierung des Punktes. Sind Skalierung und Orientierung bekannt wird ein Bereich auf Basis der beiden gewählt und in einen 16×16 großen Bereich skaliert. Dieser Bereich wird in 16 gleichgroße Bereiche unterteilt für die jeweils ein Histogramm gebildet wird. Die Einträge beschreiben in 8 diskreten Stufen die Orientierung der Punkte im jeweiligen Bereich. Die einzelnen Punkte tragen die Stärke des Gradienten im jeweiligen Bin des Histogramms. Diese Histogramme bilden den Feature-Vektor f der für den Vergleich genutzt wird.

SURF ist ähnlich aufgebaut wie SIFT, nur wird der genutzte Gauss-Filter durch Box-Filter die besonders Effizient berechnet werden approximiert. Des weiteren wird der Feature-Vektor anders gebildet. Mit beiden Anpassungen wird eine bessere Leistung erreicht. Bei der Approximation des Gauss-Filters wird zuerst das Integral-Bild I_Σ aus den Intensitätswerten des Bildes I berechnet 1.

$$I_\Sigma(x, y) = \sum_{i=0}^{i \leq x} \sum_{j=0}^{j \leq y} I(i, j) \quad (1)$$

Ist I_Σ bekannt, kann die Intensitäts-Summe eines beliebigen rechteckigen Ausschnitts sehr effizient berechnet werden. Hierzu werden nur die Werte aus I_Σ für die Eckpunkte $P_1 - P_4$ eines Ausschnittes D benötigt. Die Fläche für D lässt sich dann mit $f(D)$ effizient berechnen 2.

$$f(D) = I_\Sigma(P1) + I_\Sigma(P4) - I_\Sigma(P2) - I_\Sigma(P3) \quad (2)$$

Um den Gauss-Filter mit Box-Filtern zu approximieren wird die Determinante der Hesse-Matrix genutzt. Um die approximierte Hesse-Matrix für einen Punkt p mit der Skalierung s zu bilden muss man die zweite Ableitung der Gauss-Funktion nach x , y und xy mit Box-Filtern approximieren 3.

$$H_{approx.}(p, s) = \begin{pmatrix} D_{xx}(p, s) & D_{xy}(p, s) \\ D_{xy}(p, s) & D_{yy}(p, s) \end{pmatrix} \quad (3)$$

Die Determinante der Hesse-Matrix kann dann wie in Gleichung 4 berechnet werden. Wobei $w \approx 0.9$ ist und den Fehler der Approximation minimieren soll.

$$\det(H_{approx.}) = D_{xx}D_{yy} - (wD_{xy})^2 \quad (4)$$

Ein Beispiel für die Box-Filter ist in Abbildung 1 zu sehen. Sowohl die verschiedenen Gauss-Stufen, als auch die verschiedenen Skalierungs-Stufen werden durch vergrößern

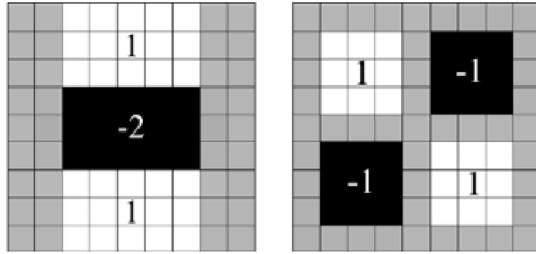


Abbildung 1: Box-Filter für zweite Ableitung nach y (links) und Ableitung nach xy (rechts). [5]

der Filter-Maske erreicht. Der Deskriptor wird in zwei Schritten berechnet. Erst wird die Hauptorientierung des Punktes berechnet. Dann wird auf dieser und der Skalierung basierend ein Bereich in dem Bild gewählt und in 16 Bereiche unterteilt. Für jeden der Bereiche wird die Intensität der Punkte in einem 4 Bin großen Histogramm abgetragen was zu einem Feature-Vektor der Größe 64 führt.

BRIEF lässt die Frage der Wahl der korrespondierenden Punkt-Paare die für den Intensitäts-Vergleich nötig sind offen, schlägt aber einige vor, wobei die zufällig generierten Paare die besten Ergebnisse liefern. Ist die Wahl der Punkt-Paare abgeschlossen kann der binäre Deskriptor gebildet werden. Dafür wird für jedes Paar die Differenz der Intensität zwischen den beiden Punkten ermittelt. Liegt die Differenz unter einem Schwellwert wird die Position für das Paar im binären Deskriptor auf null gesetzt ansonsten auf eins. Vorteil an der Umsetzung ist das sie wenig Rechenaufwand hat verglichen mit SIFT, Nachteil an der Umsetzung ist das es nicht Rotationsinvariant ist.

ORB geht diesen Nachteil an indem zuerst das Massezentrum des Bildes C 6 und dessen Orientierung θ 7 über die Moment m_{00} , m_{10} und m_{01} 5 berechnet wird. Mit diesen Parametern werden die Koordinaten der Paare umgeformt um so der Anfälligkeit für Rotationen entgegen zu wirken. Des weiteren liefert ORB eine gelernte Paar-Auswahl von 256 Paaren die dahingehend optimiert ist, dass die Paare unkorreliert sind und eine hohe Varianz aufweisen.

$$m_{pq} = \sum_{x,y} x^p y^q I(x, y) \quad (5)$$

$$C = \left(\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}} \right) \quad (6)$$

$$\theta = \text{atan2}(m_{01}, m_{10}) \quad (7)$$

Wurden die Feature ermittelt müssen korrespondierende Feature zwischen den Bildern ermittelt werden. Hierzu muss einfach nur die Distanz zwischen den Deskriptoren einzelner Feature verglichen werden. Der korrespondierende Punkt des Feature-Punktes ist der mit der geringsten Distanz. Um falsche Paare zu vermeiden können Paare unter einem gewissen Schwellwert ausgeschlossen werden und Paare bei denen der nächst beste korrespondierende Punkt eine sehr ähnliche Distanz aufweist. Das lässt darauf

schließen, dass es sich um einen Feature-Punkt handelt der in einem sich wiederholenden Muster befindet. Nun wird die Fundamental-Matrix F für jedes Bildpaar ermittelt. Ist die Kalibrierung der Kamera bekannt kann direkt die Essential-Matrix E berechnet werden. F beschreibt die Kamera-Bewegung von einem zum anderen Bild und hat den Rang 2. Um F zu ermitteln werden mindestens 8 korrespondierende Feature $(p_{A1}, p_{B1}) \dots (p_{A8}, p_{B8})$ zwischen den Bildern A und B eines Paars benötigt. Hierzu werden mindestens 8 Gleichungen der Form $p_{Ai}^T E p_{Bi} = 0$ gebildet und daraus ein Gleichungssystem der Form $Ax = 0$ erzeugt wobei, wobei x die Unbekannten aus F enthält. Das Gleichungssystem wird mittels SVD-Zerlegung gelöst. Man erhält drei Matrizen U , S und V . U hat die Größe $m \times m$, S die Größe $m \times 9$ und V die Größe 9×9 . S ist eine Diagonal-Matrix deren Einträge die Singulärwerte in absteigender Reihenfolge enthält. Aus der letzten Spalte von V , welche den kleinsten Singulär-Vektor enthält, kann die Approximation \hat{F} von F rekonstruiert werden. Wobei der Vektor der Länge 9 zu einer Matrix der Größe 3×3 umgeformt wird. Da durch Rauschen \hat{F} den Rang 3 haben kann wird von \hat{F} noch einmal die SVD gebildet und in S das letzte Diagonal-Element explizit auf 0 gesetzt was hier als Matrix \hat{S} beschrieben wird. Damit kann die Approximation von F neu berechnet werden ($\hat{F} = U \hat{S} V^T$) und hat damit Rang 2. Unterschied bei der Berechnung der Essential-Matrix ist, dass zum einen bei der Korrektur der Approximation neben dem letzten Eintrag der Diagonal-Elemente, das auf 0 gesetzt wird, die beiden verbleibenden Diagonal-Elemente auf 1 gesetzt werden. Die daraus resultierende Matrix wird im Folgenden mit D bezeichnet. Zum anderen werden die Bildpunkte normiert. Der Bildmittelpunkt bildet dabei den Koordinaten-Ursprung und die Bildpunkte werden im Bereich von -1 bis 1 angegeben. Ist E bekannt, kann die Kamera-Pose, bestehend aus dem Kamera Zentrum c und der Kamera-Rotation R , geschätzt werden. Hier ergeben sich vier mögliche Lösungen, die in Gleichung 8 zu

sehen sind. Wobei $W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$ ist.

$$\begin{aligned} C_1 &= U(:, 3), & R_1 &= UWV^T \\ C_2 &= -U(:, 3), & R_2 &= UWV^T \\ C_3 &= U(:, 3), & R_3 &= UW^T V^T \\ C_4 &= -U(:, 3), & R_4 &= UW^T V^T \end{aligned} \tag{8}$$

Um zu überprüfen welche der vier Konfigurationen die richtige ist, kann geprüft werden ob die rekonstruierten 3D-Punkte vor beiden Kameras sind. Es wird die Konfigurationen gewählt bei der am meisten Punkte vor den Kameras sind. Sind nun die ersten beiden Kamera-Posen bekannt, können weitere Kameras mittels Perspektive-n-Points-Algorithmus (PnP) hinzugefügt werden. Hierbei wird anhand der bereits ermittelten 3D-Punkte die Pose einer weiteren Kamera mittels Least-Square-Fit gefunden. Da die Pose der Kamera 6 Freiheitsgrade hat, werden mindesten 6 korrespondierende Punkte benötigt. Wurden alle Kamera-Posen und 3D-Punkte geschätzt müssen diese noch einmal korrigiert werden. Diesen Schritt nennt man Bundle-Adjustment (BA). Beim BA wird für jede der m Kamera-Posen A mit den Parametern a_j jeder der n 3D-Punkt P_i der von der Kamera aufgenommen wurde zurück auf das Kamera-Bild projiziert und der Abstand des so ermittelten Bild-Punktes zum originalen Bild-Punkt aus der

Feature-Detektion gemessen und minimiert. Das Optimisierungs-Problem kann wie in Gleichung 9 zu sehen formuliert werden.

$$\min_{a_j, P_i} = \sum_{i=1}^n \sum_{j=1}^m v_{ij} d(Q(a_j, P_i), x_{ij}) \quad (9)$$

Wobei $v_{ij} = 1$ wenn der Punkt i von Kamera j erfasst wurde und ansonsten 0. $Q(a_j, P_i)$ ist die geschätzte Projektion des Punktes P_i auf das Bild der Kamera j und $d(x, y)$ ist die Euklidische Distanz.

Einige bekannte Implementationen von SfM sind Colmap [8],[9], Open Drone Map (ODM) [10], OpenCV SfM-Pipeline [11], AliceVision (Meshroom)[12],[13] und OpenMVG [14].

Colmap stellt eine Pipeline bereit die eine inkrementelle Implementation von SfM anbietet. Initial wird nach korrespondierenden Bildern gesucht und diese dann inkrementell in die Rekonstruktion aufgenommen. Colmap nutzt Root-SIFT als Feature-Detektor. Root-SIFT nutzt im Gegensatz zu normalen SIFT beim Feature-Matching nicht die Euklidische Distanz sondern die Hellinger-Distanz [15].

ODM stellt auch eine Pipeline bereit die aus den Schritten SfM, Multi View Stereo und Filterpunkte ermitteln besteht. Eine Besonderheit bei ODM ist, dass es für jeden 3D-Punkt auch eine Normale liefert.

Es wurden in den letzten Jahren große Fortschritte im Bereich tiefer Neuronaler Netze (Deep-Learning) [16], zur Gewinnung von 3D-Punktwolken, gemacht [17] [18] [19]. Mit diesen Verfahren ist es möglich aus einer minimalen Datenbasis die auch nur aus einem Bild bestehen kann 3D-Punktwolken zu generieren. Was dem Ziel die Datenübertragung zum Server gering zu halten entgegenkommt. Nachteil der Verfahren ist, dass auf dem Bild nur ein Objekt ohne Hintergrund abgebildet sein darf, oder das zu erkennende Objekt mit einer binären Maske maskiert werden muss. Eine Rekonstruktion von komplexen Szenen ist so nicht oder nur mit sehr hohem Aufwand möglich [20] und wird daher nicht weiter untersucht. Der in [20] vorgestellte Ansatz geht diese Problematik an und soll daher untersucht werden.

2.2 Segmentierung von 3D-Punktwolken

Unter der Segmentierung von 3D-Punktwolken versteht man, dass jedem Punkt ein Label zu zugewiesen wird, welches Auskunft über eine Eigenschaft des Punktes gibt. Im Falle dieser Arbeit sollen Label wie Stamm, Blatt, Blüte oder Frucht vergeben werden.

Bei der Analyse von Pflanzen in Form von 3D Punktwolken gibt es einige nicht gelernte Lösungen [21] [22] die das segmentieren von 3D Punktwolken von Pflanzen in Stiele und Blätter behandeln, diese Ansätze haben aber das Problem, dass sie nur unter bestimmten Bedingungen gute Ergebnisse liefern.

[21] verfolgt den Ansatz eine Punktwolke in Stamm und Blätter anhand der Hauptkrümmung um jeden Punkt zu segmentieren. Hierbei wird die Hauptkrümmung für einen Punkt so interpretiert, dass der Punkt als Stamm interpretiert wird wenn die

Krümmung hoch ist. Es wird also davon ausgegangen, dass die Stämme eine höhere Krümmung aufweisen als die Blätter.

In [22] wird ein Ansatz verfolgt, der sich die zylindrische Form von Stielen zunutze macht um diese von anderen Teilen der Pflanze wie Blätter zu unterscheiden. Es wird das Modell eines Zylinders in der Punktwolke gesucht und wird dieses gefunden werden Punkte die in das Modell fallen als Stamm klassifiziert.

Insbesondere die hohe Qualität der Punktwolken die meist mit einem LIDAR-Scanner oder einem vergleichbaren Gerät erzielt wird, kann mit Bild basierten Methoden wie SfM nicht oder nur mit sehr großen Datenmengen und dem damit verbundenen Rechenaufwand erreicht werden. Ein weiteres Problem das viele Lösungen haben ist, dass der Hintergrund, also alles was nicht zur Pflanze gehört, manuell entfernt wird, oder der Hintergrund so vorbereitet wird das dieser beim erstellen der Punktwolke ignoriert wird und erst auf der freigestellten Pflanze der eigentliche Ansatz ausgeführt wird. Um diese Lösungen dennoch in einer voll automatischen Pipeline nutzen zu können muss das Freistellen der Pflanzen erst automatisiert werden.

Auch im Bereich Segmentierung wurden große Fortschritte im Bereich Deep-Learning auf 3D-Punktwolken gemacht, die mit einer angelernten Netzarchitektur bestimmte Objekte erkennen und Teile davon segmentieren. Diese Ansätze können auch auf Pflanzen angewandt werden. Dazu müssen Architekturen wie PointNet[23]/PointNet++[24] oder DGCNN [25] auf Punktwolken von Pflanzen trainiert werden, da für diese Klasse von Objekten noch keine Gewichte trainiert wurden.

Bei PointNet wird jeder der n Punkt der Punktwolke mit einer 3×3 Matrix transformiert deren Gewichte gelernt sind. Dieses Mininetz wird von den Autoren T-Net genannt. Danach wird jeder Punkt nacheinander mittels eines Multi-Layer-Perceptron (MLP) mit zwei Layern, deren Ausgabe-Schicht jeweils die Größe 64 hat, in einen neuen Feature-Raum überführt. Die Gewichte des MLP werden also über alle Punkte geteilt, was auch für die folgenden MLPs gilt. Der Feature-Vektor für einen Punkt besteht aus 64 Elementen. Die Punkte des Feature-Raums werden wieder mit einem T-Net der Größe 64×64 transformiert. Danach wird wieder ein MLP (drei Layer mit Ausgabeschicht der Größe 64, 128, 1024) angewandt und mittels Max-Pooling eine globaler Feature-Vektor der Größe 1024 ermittelt. Dieser Vektor wird mit dem lokalen Feature-Vektor für jeden Punkt kombiniert und die daraus entstehende Matrix der Größe $n \times 1088$ wird mittels zwei MLP-Layern in eine Matrix der Größe $n \times m$ überführt, wobei m die Anzahl möglichen Label sind. Der erste dieser MLPs hat drei Layer mit den Ausgangs-Schicht-Größen 512, 256 und 128, der Zweite besteht aus zwei Layern der Ausgangs-Schicht-Größe 128 und m . Die Architektur ist in Abbildung 2 zu finden.

PointNet++ baut auf der Architektur von PointNet auf. Hierbei wird das Problem adressiert, dass PointNet nicht gut mit kleinen Details umgehen kann. PointNet++ führt PointNet auf einem kleinen Bereich um gewählte zentrale Punkte aus. Die zentralen Punkte werden mittels Farthest-Point-Sampling ermittelt. Um die gewählten Punkte werden alle Punkte in den Bereich aufgenommen, die einen bestimmten Abstand k von dem zentralen Punkt nicht überschreiten. Auf diesen Punkten wird PointNet angewandt. Für jeden zentralen Punkt wird ein Feature-Vektor ermittelt. Dieser Vorgang wird so lange wiederholt, bis alle zentralen Punkte zu einem vereint werden könnten. Für klassifizie-

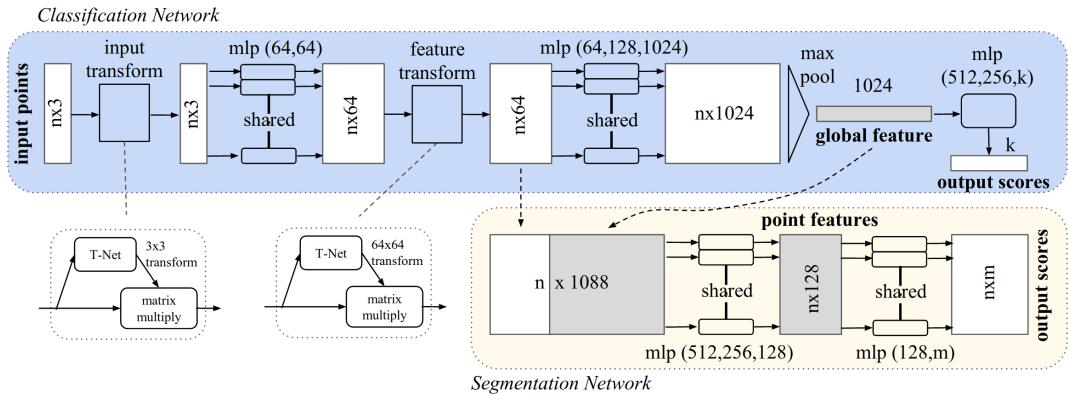


Abbildung 2: PointNet-Architektur [23]

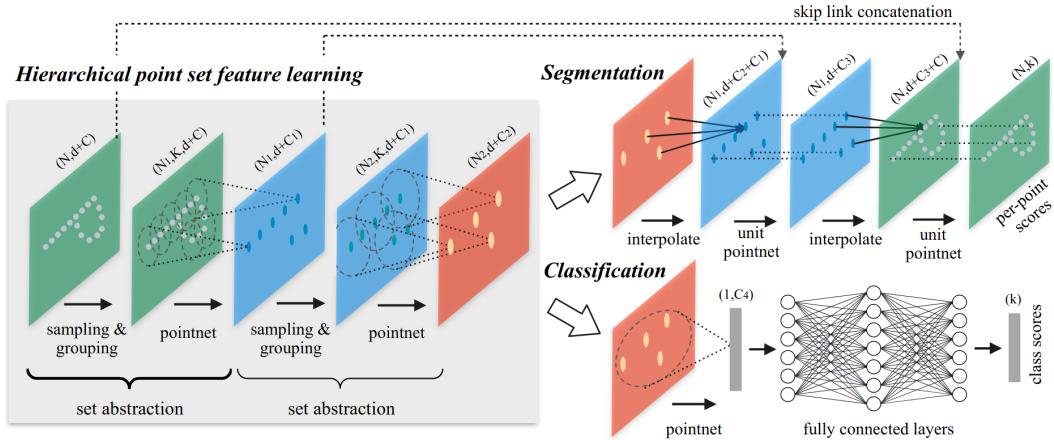


Abbildung 3: PointNet++-Architektur [24]

rung würde dieser Schritt auch durchgeführt, bei der Segmentierung allerdings nicht. Um jeden einzelnen Punkt ein Label zuzuordnen wird der Prozess nun umgekehrt und mittels Interpolation werden die ermittelten Feature-Vektoren schrittweise auf die originalen Punkte übertragen unter zuhilfenahme der in den vorherigen Schritten ermittelten zentralen Punkte. Die Architektur von PointNet++ ist in Abbildung 3 zu sehen.

2.3 Registrierung von 3D-Punktwolken

Bei der Registrierung von 3D-Punktwolken probiert man eine Transformationen T zu finden die eine Quell-Punktwolke S_p so transformiert, dass der Abstand $d(S_p, T_p)$ zu einer Ziel-Punktwolke T_p minimiert wird. Das Abstandsmaß $d(S_p, T_p)$ kann verschieden formuliert werden. Eine Möglichkeit besteht darin die Summe über die Abstände eines jeden Punktes in S_p zum nächsten Punkt in T_p zu bilden und dies als Maß $d(S_p, T_p)$ zu nutzen.

Die am weitesten verbreitete Method zur Registrierung von 3D Punktwolken ist Iterative Closest Points (ICP) [26]. ICP basiert auf dem Ansatz das zwei Punktwolken iterativ aneinander angenähert werden. Dabei wird bei jeder Iteration für jeden Punkt p_i aus der Quellpunktwolke S_p der Punkt aus der Zielpunktwolke gesucht der p_i am nächsten ist.

In einem zweiten Schritt wird der Abstand zwischen den korrespondierenden Punkten minimiert. Zuerst wird für jede Punktwolke das Massenzentrum c_s und c_t berechnet und S_p um die Differenz $c_t - c_s$ verschoben. Danach wird mittels Singulärwertzerlegung die Rotation R ermittelt und auf S_p angewandt. Der Vorgang wird wiederholt bis es zu einer Konvergenz kommt, also T nahezu der Einheitsmatrix I entspricht.

Ein Problem das ICP hat ist, dass es auch für lokale Minima konvergiert. Das heißt, dass eine initiale Transformation für S_p so gewählt werden muss, so dass der ICP-Durchlauf bei einem globalen Minimum konvergiert. Ansätze wie Go-ICP [27], die mit verschiedenen initialen Transformationen starten existieren sind aber sehr Rechenaufwendig und damit recht langsam.

Des weiteren ist ICP anfällig für Ausreißer. Für diese Problem gibt es allerdings existierende Lösungen wie RICP [28]. Hierbei kommt in der Regel RANSAC [29] zum Einsatz um Ausreißer bei der Registrierung auszuschließen. RANSAC basiert auf der Idee ein Model in einer Punktwolke zu suchen und möglichst viele Punkte zu finden die in das Model passen. Initial werden zufällig so viele Punkte wie nötig gezogen um das Model minimal zu repräsentieren. So werden zum Beispiel für ein Linien-Model zwei zufällige Punkte aus der Punktwolke gezogen. Nun werden die Parameter für das Model mit den gezogenen Punkten ermittelt und alle Punkte die nahe genug an dem so gebildeten Model sind mit aufgenommen. Wenn der Anteil der Punkte die in das Model fallen über einem bestimmten Schwellwert liegen, terminiert der Algorithmus. Ansonsten wird der Vorgang solange wiederholt bis eine Parametrisierung gefunden wurde die terminiert oder eine Obergrenze an Iterationen erreicht wurde. Das Ergebnis des Algorithmus ist auf der einen Seite die gefundene Parametrisierung und auf der anderen Seite eine Unterteilung der Punkte in der Punktwolke in Punkte die in das Model mit gegebener Parametrisierung fallen und in die die nicht in das Model fallen. Letzteres kann genutzt werden um Punkte bei der Registrierung auszuschließen. Dieser Schritt ist allerdings optional und wird nicht in allen Verfahren angewandt.

Ein weiteres Problem ist, dass die meisten ICP-Ansätze keine Werte für die Skalierung schätzen. Dies ist aber nötig, da bei SFM keine Information über die reale Ausdehnung eines Objektes ermittelt werden kann. Es gibt einige wenige Ansätze für dieses Problem die auch eine Schätzung für die Skalierung ermitteln [30]. In [30] wird die Skalierung geschätzt nachdem die Rotation R bekannt ist, also nach der SVD-Zerlegung. Ist R bekannt können die Vektoren S_P^* und T_P^* gebildet werden (Siehe Gleichung 10).

$$S_{P_i}^* = S_{P_i} - \bar{S}_P, \quad T_{P_j}^* = T_{P_j} - \bar{T}_P \quad (10)$$

Mittels dieser Vektoren kann die Skalierung s berechnet werden. Die Berechnung ist in Gleichung 11 zu sehen.

$$s = \sum_{i,j} T_{P_j}^{*T} S_{P_i}^* / \sum_i S_{P_i}^{*T} S_{P_i}^* \quad (11)$$

Auch für das Registrierung-Problem gibt es Lösungen aus dem Deep-Learning-Bereich, aber auch hier gibt es das Problem, dass es nur wenige Ansätze gibt die mit Skalierung

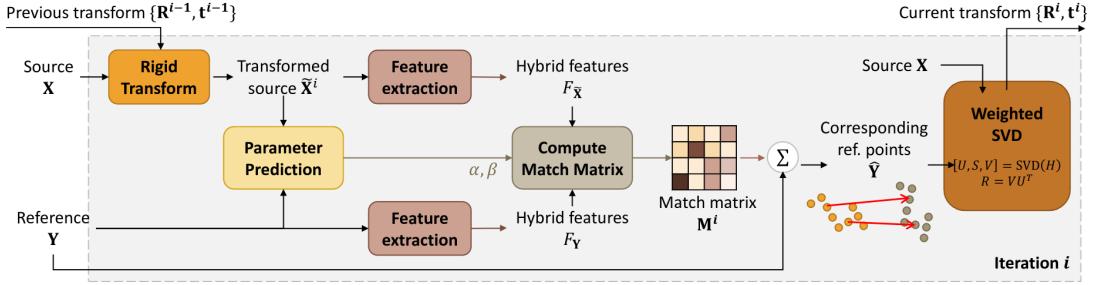


Abbildung 4: RPM-Net-Architektur [34]

umgehen können [31]. Bekannt Ansätze sind DCP [32], PointNetLK [33] und RPM-Net [34]. Dieser Ansätze sollen in dieser Arbeit untersucht werden.

DCP besteht aus drei Teilnetzen. Das erste Netz (PointNet oder DGCNN) überführt die Punktwolke in einen hochdimensionalen Raum. Das zweite Netz codiert die kontextuelle Information mittels eines Transformer-Modells und das letzte Netz schätzt auf Basis der kontextuellen Information mittels eines differenzierbaren SVD Layers die Rotation und Translation.

PointNetLK basiert auf der Idee von PointNet und dem LK-Algorithmus [38] der für die Berechnung des Optischen-Flusses bei einer Folge von Bildern entwickelt wurde. Es wird für jeden Pixel im Bild die Richtung ermittelt in der sich der Pixel über Zeit Bewegen wird. Diese Prinzip wird hier auf die Registrierung übertragen. Initial wird die Ziel-Punktwolke der Größe $nx3$ in einen hochdimensionalen Vektorraum der Größe nxk mittels eines MLP überführt. Aus der Ausgabe des MLP-Layers wird mittels einer symmetrischen Polling-Funktion ein k großer globaler Feature-Vektor ermittelt. Für diesen wird die Jakobi-Matrix J berechnet. Die Quell-Punktwolke wird nun iterativ an die Ziel-Punktwolke angenähert. Die Quell-Punktwolke wird dabei ähnlich wie die Ziel-Punktwolke behandelt. Es wird allerdings nach dem ermitteln des globalen Feature-Vektors nicht die Jakobi-Matrix gebildet, sondern mittels der Moore-Penrose Inversen Matrix von J und der Differenz der beiden globalen Feature-Vektoren die Parameter für die in dieser Iteration auszuführenden Transformation ermittelt. Die Transformation wird angewandt und der Vorgang solange wiederholt bis es zu keinen oder nur noch kleinen unter einem Schwellwert liegenden Änderungen in den Parametern für die Transformation kommt. Die einzelnen Transformationen aus den Iterationen werden miteinander multipliziert um die Transformation zu erlangen die die Quell-Punktwolke mit der Ziel-Punktwolke registriert.

RPM-Net baut auf RPM [39] auf. Nur werden im Gegensatz zu RPM die räumlichen Entfernungne durch hybride Feature-Distanzen ersetzt und die Parameter α und β werden in jeder Iteration durch ein neuronales Netz geschätzt. Details der Architektur sind in Abbildung 4 zu finden.

3 Realisierung

Es müssen vier Teilprobleme berücksichtigt werden. Zu Beginn muss aus einer Reihe Bilder eine Punktwolke generiert werden. Hauptziel hierbei ist es möglichst wenig Bilder zu benötigen. Trotzdem müssen Aspekte wie die Qualität der Punktwolken berücksichtigt werden. Diese sollte die aufgenommene Szene klar darstellen und wenig Rauschen und andere Störungen enthalten.

Ein zweites Problem ist die Registrierung zweier Punktwolken einer Pflanze zu verschiedenen Zeitpunkten um diese Vergleichen zu können. Hierbei gilt es die ideale Transformation T bestehend aus Rotation, Skalierung und Translation zu finden um die beiden Punktwolken so realitätsnah wie möglich aneinander aus zu richten. Es werden drei Ansätze überprüft dieses Problem zu lösen. Der erste Ansatz basiert auf der Idee, beim Beginn einer neuen Zeitserie zur Analyse eines Wachstumsprozesses, eine Punktwolke des Hintergrunds zu erstellen und die Punktwolken der einzelnen Zeitpunkte mit diesem Hintergrund zu registrieren. So wird ein Verhältnis geschaffen das dem der Realität entspricht. Wird für einen beliebigen Zeitpunkt noch die totale Größe der Pflanze angegeben, kann aus den Verhältnissen die totale Größe aller Zeitpunkte berechnet werden. Der zweite Ansatz soll untersuchen ob DCP so angepasst werden kann, dass statt Rotation und Translation separat, die komplette Transformations-Matrix mit Skalierung geschätzt werden kann. In einem letzten Ansatz soll die Skalierung durch iteratives Anwenden verschiedener Skalierungen gefunden werden mit einer anschließenden Registrierung ohne Schätzung der Skalierung.

Das dritte Problem ist die Segmentierung der Punktwolke in Stamm, Blätter und Hintergrund. Hier gibt es viele Ansätze dieses Problem zu lösen. Allerdings ist es schwer eine allgemein gültigen Lösung zu finden. Ziel ist es daher eine Lösung zu finden die auf möglichst vielen Varianten von Pflanzen funktioniert. Das Problem der Segmentierung ist essentiell für die weitere Analyse einer Zeitserien. Ohne die Information welche Punkte zu Stamm und Blättern gehören kann nicht auf die Entwicklung von Blättern und Stielen geschlossen werden.

Zuletzt müssen die bisherigen Problemen in geeignete Pipelines zusammengefasst werden und durch einen Server angesteuert werden. Hier muss die Lastverteilung und Datenhaltung beachtet werden.

3.1 Architektur

Die Anwendung soll über eine REST-API angesteuert werden können. Es soll möglich sein eine neue Messreihe anzulegen. Dazu müssen die Bilder für die initiale Punktwolke auf den Server übertragen werden. Es soll möglich sein weitere Messpunkte zu einer Messreihe hinzuzufügen. Zu einer Messreihe sollen Auswertungen zur Verfügung gestellt werden. Zu jeder Messreihe soll ein Bearbeitungs-Status abgerufen werden können, da die einzelnen Pipelines asynchron im Hintergrund ausgeführt werden sollen. Die einzelnen Abläufe sind in Abbildung 5 zu sehen.

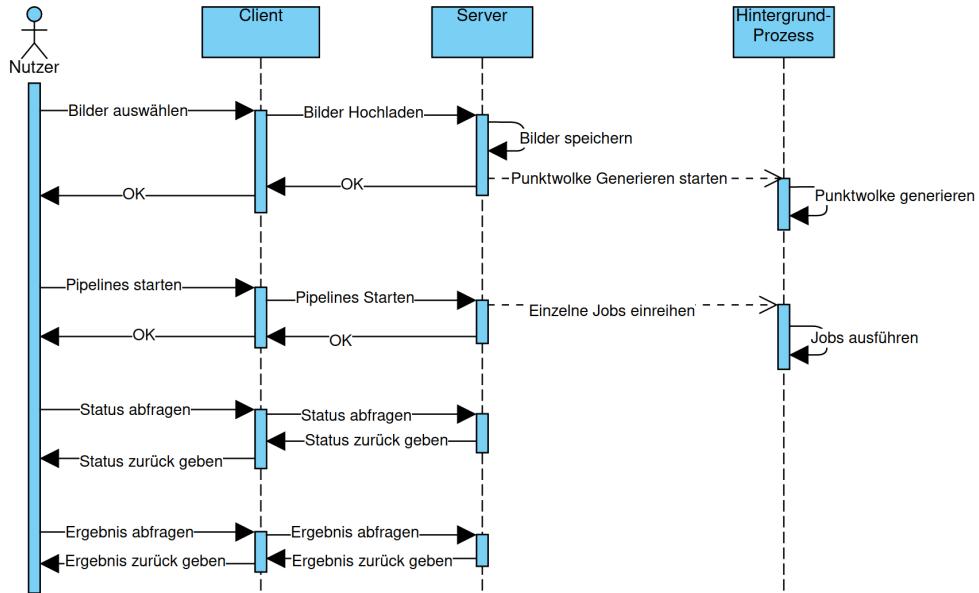


Abbildung 5: Arbeitsabläufe zwischen Nutzer, Client, Server und Hintergrundprozess.

3.2 Umsetzung Generierung einer 3D Punktwolke aus Bildern

Die aus der Analyse der verschiedenen Verfahren (siehe Evaluation) ausgewählte Anwendung ODM wird als Docker bereit gestellt. Um den Docker erfolgreich auszuführen muss eine Ordner-Struktur bereit gestellt werden. In dieser Ordner-Struktur muss ein Ordner „images“ enthalten sein, der die Bilder des Datensatzes, aus dem eine Punktwolke generiert werden soll, enthält.

Ist das Verzeichnis angelegt kann der Docker gestartet werden. Hierbei muss allerdings beachtet werden, dass der Docker mit den selben Rechten wie der User ausgeführt wird. Ansonsten werden per Standardeinstellung Root-Rechte genutzt. Das führt dazu das auf die erstellten Daten nur noch lesend zugegriffen werden kann, was das Aufräumen erschwert. Nach dem Ausführen des Dockers sollte in jedem Fall alle nicht benötigten Dateien gelöscht werden, da diese je nach Anzahl genutzter Bilder mehrere Gigabyte an Festplattspeicher belegen.

3.3 Umsetzung Registrierung zweier Punktwolken

Bei der Umsetzung der Registrierung muss die Besonderheit beachtet werden, dass die Skalierung der Punktwolken nicht bekannt ist und sich unterscheiden. Das heißt die Punktwolken liegen in unterschiedlichen Maasstäben vor. Um ein gutes Verfahren zu finden was mit dieser Besonderheit umgehen kann wurden mehrere Ansätze verglichen.

In einem ersten Ansatz wurde versucht ein Pipeline zu erstellen die eine gute Initiale Lösung findet ohne den ganzen möglichen Suchraum zu durchsuchen. Die Pipeline sucht zuerst für die Quell- und Ziel-Punktwolke S und T nach der größten Ebene in der Punktwolke und richtet die Punktwolke so aus, dass die gefundene Ebene auf der Ebene liegt, die die x und y Achse bilden. Zudem wurden die Punktwolken so skaliert, dass die

begrenzenden Boxen gleich groß sind. Des weiteren werden aus beiden Punktwolken nur ein Teilmenge P_c der Punkte in einem Radius r um dem Punkt c der das Zentrum der Masse der Punktwolken repräsentiert entnommen. Damit soll Rauschen und unvollständige Fragmente an den Rändern unterdrückt werden und ein Teil des Hintergrunds soll ausgeblendet werden. Aus dieser Teilmenge werden Subsample gezogen um den Rechenaufwand zu minimieren. In diesem Zustand haben Quell- und Ziel-Punktwolke eine gute initiale Transformation. Für die zu registrierende Punktwolke wird zunächst mittels SIFT 3D [40] eine Verbesserung der initiale Transformation gesucht. Danach wird ein ICP-Durchlauf gestartet der auch die Skalierung der Ziel-Punktwolke schätzt. Um das Ergebnis nach der Schätzung der Skalierung weiter zu verbessern wird noch ein ICP-Durchlauf gestartet - diesmal ohne Schätzung der Skalierung.

Ein weiterer Ansatz ist es DCP so abzuwandeln, dass statt Translations-Vektor und Rotations-Matrix direkt die ganze Transformations-Matrix geschätzt wird. Dazu muss der SVD-Head so angepasst werden das er statt einer 3×3 Rotations-Matrix R und dem Translations-Vektor (\vec{t}) die Transformations-Matrix T zurück liefert wird. Um das zu erreichen muss die Eingabe der Größe $N \times 3$ auf eine Eingabe der Größe $N \times 4$ erweitert werden. Hier kann die Eingabe um einen Vektor mit Einsen erweitert werden. Das führt dazu das die Singulärwert-Zerlegung von H im SVD-Head nun eine 4×4 Matrix ist. Die Annahme die wir treffen ist das H als Transformations-Matrix interpretiert werden kann.

In einem letzten Ansatz wird die Skalierung geschätzt in dem ein vorgegebener Bereich an Werten für die Skalierung in einer vorgegebenen Schrittgröße s durchsucht wird. Wieder werden die Quell- und Ziel-Punktwolke an der XY-Ebene ausgerichtet und eine Teilmenge P_c um das Zentrum c entnommen wie im ersten Ansatz. Auch werden wieder Subsample gezogen. In jedem Skalierungs-Schritt wird die Punktwolke mit der aktuellen Skalierung skaliert und danach mit einem Registrierungs-Verfahren registriert. Um die Ergebnisse der einzelnen Registrierungen zu messen wird der Abstand zwischen der transformierten Quell-Punktwolke und der Ziel-Punktwolke berechnet. Der Abstand $d(S, T)$ wird so berechnet, dass für jeden Punkt p aus der Punktwolke T der Abstand zum nächsten Punkt in der Punktwolke S berechnet wird.

Man könnte auch den Abstand von allen Punkten in S messen, aber das kann zu Problemen bei kleinen Skalierungen führen, da wenn im extrem Fall die Punktwolke S sehr klein ist alle Punkte in S nahezu keinen Abstand mehr zueinander haben. Man kann S also auch durch einen Punkt p_S abstrahieren. Bei der Registrierung muss S nur sehr nah an einen Punkt p_t in T sein sodass gilt $p_t \approx p_S$ und der Abstand zwischen S und T geht gegen 0. Dadurch werden sehr kleine Skalierung durch dieses Maß bevorzugt. Nimmt man statt aller Punkte in S alle Punkte in T wird der Fehler in diesem Fall größer als 0 sein, es sei den T ist auch sehr klein.

Mit diesem robustem Maß kann man nun die Güte der einzelnen Skalierungs-Iterationen bewerten und die beste Skalierung mit zugehörigen Transformation für Rotation und Translation finden. Da die Wahl des Registrierungs-Verfahren offen bleibt wurden hier mehrere Verfahren mit einander verglichen. Es wurden zwei ICP-Implementationen, DCP, PointNetLK und RPM-Net miteinander verglichen.

3.4 Umsetzung Segmentierung

Zur Segmentierung der Pflanzen-Punktwolke in Stamm und Blätter wurde ein Ansatz verfolgt der an den in [21] angelehnt ist, der mittels der Hauptkrümmung eines Punktes ermitteln soll ob es sich um ein Blatt oder einen Stiel handelt. Hierbei wird eine einfache Entscheidungsregel $f(x)$ mittels eines Schwellwerts T_k genutzt: Ist die Stärke der Krümmung $k(x)$ des Punktes höher als der Schwellwert handelt es sich um einen Stiel da diese einen größere Krümmung haben als Blätter. Die Schwierigkeit ist es einen guten Schwellwert und eine gute Kennzahl für die Stärke der Krümmung zu finden.

Die Hauptkrümmung eines Punktes p_i kann über die Normalen des Punktes und der k nächsten Nachbarpunkte P_i berechnet werden.

$$\vec{m}_j = (I - \vec{n}_i \otimes \vec{n}_i) \cdot \vec{n}_j \quad (12)$$

Aus den Abbildungen \vec{m}_j (Siehe Gleichung 12) für alle P_i kann die Kovarianzmatrix C_i berechnet werden. Die Berechnung von C_i ist in Gleichung 13 zu sehen.

$$C_i = \frac{1}{k} \sum_{j=1}^k (\vec{m}_j - \vec{m}) \otimes (\vec{m}_j - \vec{m}) \quad (13)$$

Die Hauptkrümmung kann aus den Eigenwerten $0 \leq \lambda_1 \leq \lambda_2 \leq \lambda_3$ von C_i bestimmt werden. λ_3 ist die stärkste Krümmung und λ_2 die schwächste Krümmung.

Einige untersuchte Ansätze für eine Funktion $k(p_i)$ sind in Gleichung 14 zu finden.

$$\begin{aligned} k_1(p_i) &= \lambda_3 \\ k_2(p_i) &= \lambda_2 \\ k_3(p_i) &= (\lambda_3 + \lambda_2)/2 \end{aligned} \quad (14)$$

Je höher der Wert der Funktion $k(p_i)$ aus den Gleichungen in 14 ist desto Wahrscheinlicher gehört ein Punkt zum Stiel einer Pflanze. Die Entscheidungsregel dafür ist in Gleichung 15 zu sehen. Ein guter Wert für den Schwellwert T_k muss in Experimenten für die Funktionen k_1 , k_2 und k_3 gefunden werden. Diese Experimente haben gezeigt, dass k_1 die besten Ergebnisse liefert.

$$f(p_i) = \begin{cases} 1 & k(p_i) \geq T_k \\ 0 & \text{sonst} \end{cases} \quad (15)$$

In einem weiteren Ansatz wurde eine Implementierung von PointNet auf einem Datensatz von Pflanzen-Punktwolken trainiert um so einen geeigneten Classifier zu trainieren. Der Classifier soll für jeden Punkt einer Punktwolke bestehend aus Position und Normalen eine Schätzung liefern was der Punkt repräsentiert. Mögliche Repräsentationen können Stamm, Blatt oder Hintergrund sein. Weitere denkbare Repräsentationen können die Früchte und Blüten der Pflanzen sein. Wird die Farbe der Punktwolke mit einbezogen, können auch Krankheitsbilder wie vertrocknende Blätter in die Repräsentation eingeschlossen werden. Da die Ergebnisse mit PointNet nicht gut genug waren wurde eine

verbesserte Version PointNet++ auf dem Datensatz trainiert. Diese wurde mit und ohne Normalen, mit 2 Labeln ohne Hintergrund und mit 3 Labeln mit Hintergrund trainiert.

Nach der Segmentierung wird das Ergebnis noch einmal überarbeitet. Für jedem Punkt p_i werden die Schätzungen N_i der k ($k = 10$) nächsten Nachbarn bestimmt und aus deren Repräsentations-Schätzungen ein Histogramm H_i erzeugt. Die Schätzung mit dem höchsten Histogramm-Wert wird als neue Schätzung s_i für den Punkt p_i genutzt. Die Berechnungs-Vorschrift ist in Gleichung 16 zu finden. Dieser Vorgang wird für alle Punkte solange wiederholt bis es bei den Punkten zu keinen Änderungen mehr kommt oder eine maximale Iterations-Obergrenze erreicht wird.

$$\begin{aligned} L &= \{0, 1, 2\} \\ w(x) &= \begin{cases} 0,5 & x = 2 \\ 1 & \text{sonst} \end{cases} \\ H_i(x) &= \sum_{j=0}^k (w(x)|N_{ij} = x) \\ x &\in L \\ s_i &= \operatorname{argmax}_x(H_i(x)) \end{aligned} \tag{16}$$

3.5 Umsetzung Server

Der Server ist mit dem Python-Framework Flask erstellt. Flask bietet eine Schlanke API um REST-Endpunkte zu erstellen und Daten vom Client anzunehmen.

Ein Hintergrund-Prozess führt die einzelnen Jobs aus und sorgt für den Lastausgleich. Die Anfragen an den Server werden asynchron verarbeitet. Jede Anfrage wird in die Job-Queue eingeordnet. Diese wird vom Hintergrund-Prozess abgearbeitet. Einzige Ausnahme bildet hier das Speichern der Bilder. Die Bilder müssen synchrone zum Request auf der Platte persistiert werden, da Flask die Datei-Streams nach dem Lebenszyklus eines Requests schließt.

Beim Start des Servers wird neben Starten des Hintergrund-Prozesses auch der aktuelle Stand der Datenhaltung eingelesen und der Status des Servers aufgebaut. Bei der Datenhaltung wurde auf eine Datenbank verzichtet, da die Anwendung Datenhaltungs-Technisch simpel ist und die meisten Daten als BLOB [41] vorliegen und daher nicht ideal für ein relationales Datenbank-Modell sind. Die Daten werden direkt auf der Festplatte des Host-Systems abgelegt, wobei die Ergebnisse als JSON-Datei abgelegt werden. Des weiteren werden zwei Instanzen von PointNet++ gestartet. Eine für die Segmentierung des Hintergrundes und einer für die Segmentierung der Pflanze.

Der Server bietet folgende Schnittstellen die den Betrieb der Anwendung ermöglichen:

GET /listings/{Messreihe}

Dient dazu zu einer Messreihe den aktuellen Status abzuholen. Der Status der Messreihe setzt sich aus den einzelnen Pipeline-Status zusammen.

PUT /results/{Messreihe}/{Zeitstempel}

Dient dazu zu einem Zeitpunkt einer Messreihe die ermittelten Werte wie Anzahl Blätter oder Volumen abzuholen.

```

{
    "LeaveCount": 7,
    "Height": 0.276259834557858,
    "Volume": 0.025656320729475497,
    "GrothSinceLastSnapshot": 1.1,
    "BackgroundRegistration": {
        "Transformation": [
            [0.9995419979095459, 0.0299260001629591, -0.00
                4519070032984018, -0.030479200184345245],
            [-0.029895899817347527, 0.9995309710502625, 0.
                0065834098495543, 0.025272000581026077],
            [0.004713969770818949, -0.006445290055125952,
                0.9999679923057556, 0.0013244400033727288],
            [0.0, 0.0, 0.0, 1.0]
        ],
        "Scale": 1.3
    }
}

```

Listing 1: Beispiel Ergebnisse eines Zeitstempels

POST /data/{Messreihe}/{Zeitstempel}

Dient dazu neue Datensätze hinzu zu fügen. Es muss eine Sammlung von Bildern einer Pflanze mit geliefert werden. Wird der Endpunkt angesprochen werden die Bilder gespeichert und die Pipeline zum generieren der Punktwolke in der Job-Queue hinzugefügt. Wird als Zeitstempel „background“ angegeben wird dieser Datensatz als Hintergrund für die derzeitige Messreihe interpretiert.

PUT /data/{Messreihe}/{Zeitstempel}

Dient dazu Pipelines für einen Zeitstempel einer Messreihe zu starten. Hierzu wird im Payload des Request an den Server eine JSON-Datei übermittelt welche eine Liste der Pipelines enthält (Beispiel siehe Listing 2). Die spezifizierten Pipelines werden, in der angegebene Reihenfolge, der Job-Queue hinzugefügt.

```

{
    "jobs" : [
        {
            "jobName" : "SegmentBackground",
            "jobParameter" : {}
        }
    ]
}

```

Listing 2: Beispiel Payload zum starten einer Pipeline

Es stehen folgende Pipelines zur Verfügung:

- Punktwolke generieren
- In Shapnet-Format überführen
- Entfernung des Hintergrundes
- Segmentierung Pflanze
- Blatt/Stamm Trennung
- Blätter zählen
- In Registrierungs-Format überführen
- Hintergrund-Registrierung
- Größen berechnen

3.6 Umsetzung Pipelines

Punktwolke generieren

Die Punktwolke wird auf Basis der hoch geladenen Bilder zu einem Zeitstempel generiert. Beim Anlegen eines neuen Zeitstempels wird die Pipeline automatisch gestartet, kann aber auch manuell neu gestartet werden sollte es während der Generierung zu einem Server-Ausfall kommen.

In Shapnet-Format überführen

Diese Pipeline überführt die Punktwolke in das Shapnet-Format. Die Punktwolke muss in diesem Format vorliegen um die beiden Segmentierungs-Pipelines nutzen zu können. Bevor die Punktwolke in das Shapnet-Format überführt wird können zwei optionale Schritte durchgeführt werden. Bei der Hintegrund-Segmentierung wird die Punktwolke mittels der größten in der Punktwolke zu findenden Ebene an der XY-Ebene ausgerichtet. Bei der Pflanzen-Segmentierung werden alle als Hintergrund gelabelten Punkte entfernt. Danach beginnt die eigentliche Überführung in das Shapnet-Format. Zuerst wird die Punktwolke so verschoben, dass die Bounding-Box im Koordinaten-Ursprung beginnt und sich auf den positiven Bereich der Achsen erstreckt. Danach wird die Punktwolke in der Form normiert, dass sich alle Punkte der Punktwolke zwischen den Punkten $(0, 0, 0)$ und $(1, 1, 1)$ befinden. Zuletzt werden $n = 16384$ Punkte aus der Punktwolke zufällig gezogen, wobei die Punkte nicht zurück gelegt werden.

Entfernung des Hintergrundes

Die im Shapnet-Format vorliegende Punktwolke wird mit der Instanz von PointNet++ für die Hintegrund-Segmentierung segmentiert. Das Ergebnis wird im Speicher des Host-Systems abgelegt. Da die Segmentierung etwas verrauscht ist wird das Ergebniss mit einem nächste Nachbarn Vote verbessert. Im Anschluss wir das Ergebnis auf die original Punktwolke übertragen, da sonst zu wenig Punkte für die Segmenetierung der Pflanze übrig bleiben. Auch wird der Hintegrund entfernt und aus den verbleibenden Punkten, die nun nur noch Pflanzen-Punkte enthalten wieder eine Punktwolke im Shapnet-Format erstellt. Um die als Pflanze erkannten Punkte auf die originale Punktwolke zu übertragen, wird zu jedem Punkt der als Pflanze erkannt wird in einem Radius

r in der originalen Punktwolke nach Punkten gesucht und die gefundenen Punkte in die neue Punktwolke die nur die Punkte der Pflanze enthält übertragen. Die verbleibenden Punkte in der Original-Punktwolke, die nur noch Hintergrund enthalten, werden auch gespeichert um diese später für die Registrierung zu nutzen.

Segmentierung Pflanze

Auf dem Ergebniss der Hintergrund-Entfernung wird PointNet++ zur Segmentierung der Pflanze gestartet. Auch hier wird das Ergebnis im Speicher des Host-Systems abgelegt. Wieder wird das Segmentierungs-Ergebniss wie bei der Hintergrundentfernung verbessert. Im Falle der Pfansen-Segmentierung ist dieser Schritt nicht zwangsläufig nötig, da die Ergebnisse gut genug sind.

Blatt/Stamm Trennung

Die Punktwolke die die segmentierte Pflanze enthält wird in zwei Punktwolken aufgeteilt. Wobei die eine Punktwolke nur noch Punkte enthält die Blätter repräsentieren und eine die entsprechend nur noch Punkte enthält die Stiele repräsentieren.

Blätter zählen

Die Punktwolke P die die Blätter enthält wird nun mit einer 3D Interpretation des Flood-Fill-Algorithmus untersucht. Hierbei wird ein zufälliger Punkt in der Punktwolke gewählt und in die Menge Q aufgenommen. Nun wird solange bis Q keine Punkte mehr enthält ein Punkt p aus Q entnommen und mittels nächster Nachbarn-Suche im Radius r nach weiteren Punkten in der Nähe gesucht. Gefundene Punkte werden in Q aufgenommen, wenn sie nicht in B enthalten sind. Der Punkt p wird danach in die Menge B aufgenommen. Ist Q leer wird die Menge B aus P entfernt und der Blatt-Zählstand um eins erhöht. Der Vorgang wird so lange wiederholt, bis keine Punkte mehr in P enthalten sind.

In Registrierungs-Format überführen

Zuerst wird die Punktwolke wieder anhand der größten Ebene die in der Punktwolke zu finden ist an der XY-Ebene ausgerichtet. Danach wird um das Zentrum der Punktwolke ein Ausschnitt entnommen. Im folgenden wird die Punktwolke wie beim Shapenet Format normiert und es werden zufällig $n = 1024$ Punkte aus der Punktwolke gezogen.

Hintergrund-Registrierung

Um einen Zeitstempel t einer Messung mit dem Hintergrund der Messreihe zu registrieren muss sowohl die Punktwolke P_t für den Zeitstempel t als auch die Punktwolke für den Hintergrund im Registrierungs-Format vorliegen. Ist das gegeben kann die Registrierung gestartet werden. Hierbei wird ein Skalierungs-Faktor s und eine Transformation T ermittelt. Das Registrierungs-Ergebnis $P_{Registration}$ der Punktwolke P_t kann dann mit der Formel $P_{Registration} = (P_t \cdot s) \cdot T$ ermittelt werden. Wobei beachtet werden muss, dass erst die Skalierung und dann die Transformation angewandt wird.

Größen berechnen

Ist die Punktwolke P_t zum Zeitstempel t mit dem Hintergrund registriert, können die Größen Höhe und Volumen nun leicht berechnet werden. Die Höhe kann über den

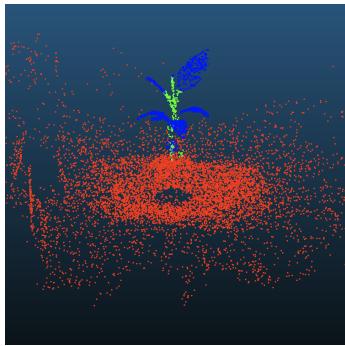


Abbildung 6: Hintegrund-Segmentierung

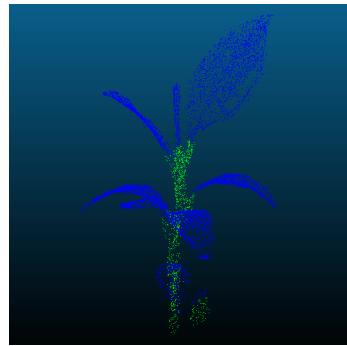


Abbildung 7: Planzen-Segmentierung

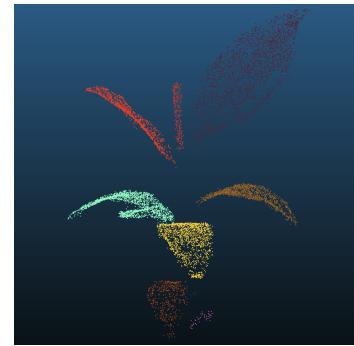


Abbildung 8: Blatt-Segmentierung

höchsten z-Wert der Punkte in P_t ermittelt werden. Um das Volumen zu berechnen, muss für P_t die Länge l , Breite b und Höhe h ermittelt werden (siehe Gleichungen 17 - 19). Das Volumen v lässt sich dann folgendermaßen berechnen: $v = h \cdot b \cdot l$.

$$l = \begin{cases} |minX| + maxX & minX \leq 0 \\ maxX - minX & \text{sonst} \end{cases} \quad (17)$$

$$b = \begin{cases} |minY| + maxY & minY \leq 0 \\ maxY - minY & \text{sonst} \end{cases} \quad (18)$$

$$h = \begin{cases} |minZ| + maxZ & minZ \leq 0 \\ maxZ - minZ & \text{sonst} \end{cases} \quad (19)$$

Ist die Höhe für den vorherigen Zeitstempel $t - 1$ auch bekannt, kann das relative Wachstum seit dem letzten Zeitpunkt ermittelt werden. Dieser Schritt kann nicht für den ersten Zeitstempel ausgeführt werden.

4 Ergebnisse

4.1 Vergleich von Verfahren zur Generierung von 3D-Punktwolken auf Basis von Bildern

Um eine geeignete Anwendung zur Generierung von 3D-Punktwolken auszuwählen muss erst entschieden werden nach welchen Gütekriterien verschiedene Verfahren betrachtet werden sollen und wie wichtig diese sind. Bei dieser Arbeit ist die nötige Anzahl der Bilder die zur Generierung einer Punktwolke mit genug Information nötig sind, so wie die Dauer die Punktwolke zu erstellen die wichtigsten Kriterien.

Um zu messen wie viele Bilder benötigt werden um eine Szene gut zu repräsentieren muss ein Goldstandart von der fotografierten Szene als 3D-Punktwolke erstellt werden, mit dem Verglichen werden kann. Dieser Goldstandart kann erstellt werden, indem alle Fotografien genutzt werden die zur Verfügung stehen und damit alle Verfahren eine Punktwolke erstellen lassen. Unter den erstellten Punktwolken kann die ausgesucht werden die die Szene am besten repräsentiert. Das trifft auf die Punktwolke zu die den höchsten Detail-Grad hat und möglichst wenig Fehler, wie fehlende Teile der Szene oder Rauschen enthält. Die so erstellte Szene sollte nachbearbeitet werden um etwaige Fehler wie Rauschen manuell zu entfernen.

Nun kann mit weniger Bildern aus dem selben Datensatz ein weitere Punktwolke generiert werden und die Distanz der Punkte der Goldstandart-Punktwolke zum jeweils nächsten Punkt der erstellten Punktwolke gemessen werden. Die Summe dieser Abstände kann als Fehlermaß genutzt werden. Bei der Berechnung der Abstände muss beachtet werden, dass die Punktwolken mit dem Goldstandart registriert ist.

Nach einem manuellen Auswahlverfahren sind ODM und Colmap als geeignete Anwendung zur Generierung von Punktwolken gewählt worden, da diese die einzigen untersuchten Anwendungen sind die gute Ergebnisse bei wenig Bildern erzielen die die Szene erkennen lassen. Hierzu wurden auf einer Menge von 25 Bildern die Implementationen ODM, Colmap, OpenCV SfM-Pipeline, Meshroom (nutzt AliceVision) und OpenMVG miteinander verglichen. Die generierten Punktwolken sind in Abbildung 9 zu sehen. Es ist deutlich zu erkennen, das bis auf Colmap und ODM alle anderen Verfahren schwierigende Probleme in der Representation haben. Meshroom hat Probleme feine Strukturen zu erkennen. OpenMVG generiert zu wenig Punkte und OpenCV hat ein Problem bei der Kamera-Kalibrierung wodurch es zu schlechten Ergebnissen kommt.

Um die beiden Anwendungen weiter zu vergleichen wurde aus 73 Bildern sowohl mit Colmap als auch mit ODM eine Punktwolke generiert, da ODM die Szene besser repräsentiert und weniger Rauschen beinhaltet wurde die mit ODM erstellet Punktwolke als Goldstandart gewählt.

Im Folgenden werden aus Teilmengen der Bilder jeweils für ODM und Colmap Punktwolken generiert. Die Teilmengen bestehen aus 5 bis 70 Bildern wobei immer 5 Bilder mehr pro Schritt genutzt werden. Bei der Wahl der Bilder pro Schritt wird beachtet, dass die Bilder ähnliche Ausschnitte enthalten, da diese zur Generierung von Punktwolken nötig sind.

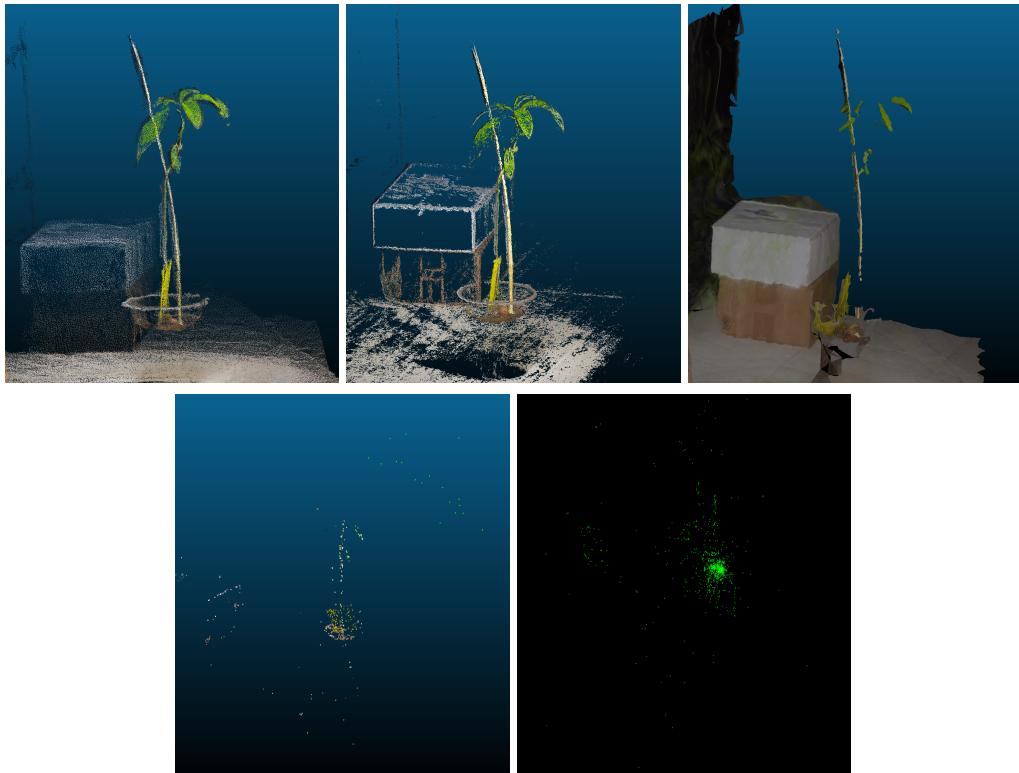


Abbildung 9: Ergebnisse auf Datensatz mit 25 Bildern. Von oben links nach unten rechts: ODM, Colmap, Meshroom, OpenMVG, OpenCV

In zwei Vergleichen wurden zum einen die Durchschnittliche Distanz für jeden Punkt zum nächsten Punkt in der Goldstandard-Punktwolke verglichen und zum anderen die Anzahl generierter Punkte pro Schritt verglichen. Die Ergebnisse sind in Abbildung 10 und 11 zu sehen. Es ist zu erkennen, dass Colmap zwar mehr Punkte generiert als ODM, aber ab einer bestimmten Anzahl Bilder überwiegt das Rauschen in den mit Colmap generierten Punktwolken so stark, dass der Abstand zur Goldstandard-Punktwolke größer als der mit ODM erreichte Abstand wird.

Generell lässt sich in den generierten Punktwolken beobachten, dass Colmap mehr Rauschen enthält als ODM. Exemplarisch in den Abbildungen 12 und 13 zu sehen. Ein Nachteil von ODM ist, dass es um die Kanten herum sehr viele Hintergrundpunkte mit aufgenommen werden die eine Art Halo um die erkannten Strukturen bilden. Dadurch können feine Strukturen in einander überfließen. Dies ist auch bei Colmap zu beobachten, allerdings nur in einem kleineren Ausmaß. Bei Colmap hat man zusätzlich das Problem, dass es zu größeren Lücken in erkannten Oberflächen kommt. Beide Probleme sind in Abbildung 14 und 15 zu sehen. Des Weiteren kann es vorkommen, dass Colmap zwei Szenen in den Bildern erkennt was insbesondere bei Nutzung von vielen Bildern vorkommt (Abbildung 16).

Ein weiterer Punkt bei der Bewertung des Verfahrens zur Generierung von 3D Punktwolken ist die Zeit die benötigt wird die Punktwolke zu generieren. Hier dominiert ODM klar. Obwohl mangels der GEO-Position der Bilder, ODM nur in der Lage ist die CPU parallel zu nutzen und nicht die GPU werden die Punktwolken wesentlich schneller ge-

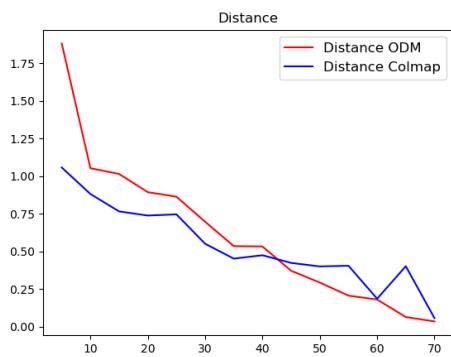


Abbildung 10: Distanz der Punktwolke mit bestimmter Anzahl Bilder zur Goldstandart-Punktwolke.

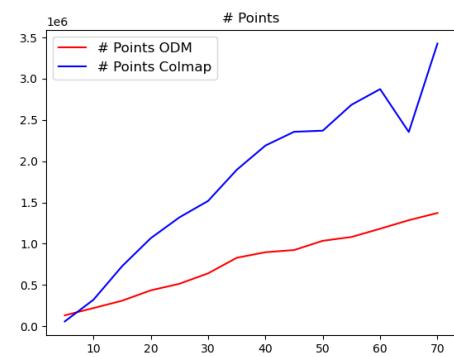


Abbildung 11: Anzahl Punkte die mit einer bestimmten Anzahl Bilder generiert werden kann.



Abbildung 12: ODM mit 40 Bildern - Ansicht von der Seite



Abbildung 13: Colmap mit 40 Bildern - Ansicht von der Seite



Abbildung 14: ODM mit 40 Bildern - Ansicht von Oben



Abbildung 15: Colmap mit 40 Bildern - Ansicht von Oben



Abbildung 16: Colmap mit 55 Bildern und doppelt erkannter Szene.

neriert als mit Colmap, welches die GPU nutzt und diese auch gut auslastet. ODM benötigt zur Generierung einer Punktwolke mit 73 Bildern 566 Sekunden während Colmap für die gleiche Datenbasis 4148 Sekunden benötigt. Sollten GEO-Positionen für die Bilder bekannt sein kann ODM die GPU nutzen und somit die Zeit die benötigt wird die Punktwolken zu generieren weiter verbessern.

Da ODM wesentlich weniger Rauschen beinhaltet, keine Probleme mit doppelt erkannten Szenen hat und weniger Zeit zur Generierung der Punktwolken benötigt wurde in dieser Arbeit ODM zur Generierung von Punktwolken genutzt, wobei die Dauer die zur Generierung der Punktwolke benötigt wird der ausschlaggebende Faktor für die Entscheidung ist.

4.2 Vergleich von Verfahren zur Registrierung 3D-Punktwolken

In einem ersten Schritt wurden verschiedene Lösungen aus dem Deep-Learning Bereich miteinander verglichen. Es wird die Distanz zwischen transformierter Quell-Punktwolke und Ziel-Punktwolke wie im Abschnitt 3.3 beschrieben gemessen. Neben der Distanz berichten wir über den bei der Evaluation gemessenen Loss. Die einzelnen Verfahren sind alle in dem Python-Paket learning3d [42] implementiert und nutzen die selbe Datenbasis ModelNet40 für das Training und sind somit gut vergleichbar. Für DCP und RPM-Net wurden das vortrainierte Model vom Author des Pakets genutzt. PointNetLK musste trainiert werden und wurde mit den empfohlenen Angaben des Authors trainiert. Die Evaluation wurde drei mal mit zufälligen Daten wiederholt und aus den drei Durchläufen die Mittelwerte für die ermittelten Werten gebildet. Die Ergebnisse sind in Tabelle 1 zu finden.

In einem zweiten Schritt wurden die Verfahren auf konkreten Beispielen der Problemstellung verglichen. Neben DCP, RPM-Net und PointNetLK wird auch die ICP Implementation aus dem Python-Paket open3d [43] und eine weitere in c++ implementierte ICP Version RICP verglichen. Hier wurden exemplarisch je eine Avocado- und eine

	DCP	RPM-Net	PointNetLK
Distanz	0, 0292	0, 0663	0, 026
Loss	0, 922	0, 061	0, 111

Tabelle 1: Vergleich von Registrierungs-Verfahren auf ModelNet40. Distanz und Loss sind jeweils Mittelwerte über alle Datensätze in der Iteration.

	DCP	RPM-Net	PointNetLK	ICP	RICP
Banane	0.0585	0.0129	0.1673	0.0117	0.0178
Avocado	0.0721	0.012	0.2235	0.0122	0.0245

Tabelle 2: Vergleich von Registrierungs-Verfahren auf konkreten Beispielen der Problemstellung. Für jede Pflanze wird die Distanz zwischen Quelle und Ziel angegeben

Bananen-Pflanze verglichen. Wie im vorherigen Vergleich wird die Distanz zur Zielpunktfolge in den Ergebnissen wieder gegeben. Die Ergebnisse sind in Tabelle 2 zu sehen.

Aus den Ergebnissen der Messung in Tabelle 2 ist zu erkennen, dass ICP die besten Ergebnisse für die Registrierung liefert. Die Neuronalen-Netze liefern keine guten Ergebnisse. Mit Ausnahme von RPM-Net. Die Ergebnisse für RPM-Net liegen in etwa gleich auf mit den Ergebnissen die für ICP erreicht wurden und sind besser als die Ergebnisse von RICP.

4.3 Vergleich von Verfahren zur Segmentierung von Pflanzen auf 3D-Punktwolken

In Experimenten mit dem handgeschriebenen Classifier konnte keine gute Parametrisierung gefunden werden, die eine gute Unterteilung in Blätter und Stämme erreichen konnte. Dies liegt in erster Linie an der Qualität der Punktwolken. Diese haben das Problem, dass die oft sehr feinen Stiele der Pflanze nicht als Zylinder sondern als Ebene in den Punktwolken repräsentiert werden. Das ist in Abbildung 17 zu sehen. Ein weiteres Problem ist eine allgemein gültige Parametriesierung zu finden. Ein Beispiel dafür ist in Abbildung 17 zu sehen. Hier wurde mit dem selben Schwellwert klassifiziert.

Die Annahme das DCP eine gute Schätzung für die Transformations-Matrix liefern kann hat sich, auch nach umfangreichem Training, nicht bestätigt und wird daher nicht weiter betrachtet.

Datenbasis für das Training von PointNet++

Als Datenbasis für das Training von PointNet++ wurden 144 handgelabelte Punktwolken von verschiedenen Pflanzen gewählt. Darunter sind Tomaten, Mais, Paprika, Avocado, Bananen und weitere nicht bekannte Sorten. Da diese Datenbasis für das Training eines Neuronalen Netz recht klein ist wurde aus jeder einzelnen Punktwolke bis zu 20 Subsample erstellt. Diese wurden so erstellt, dass zufällig n Punkte aus einer Punktwolke gezogen und entfernt wurden. Des weiteren sind die Daten so aufbereitet das der Boden der Punktwolke an der XY-Ebene ausgerichtet ist und der Stiel bei geradem Wachstum

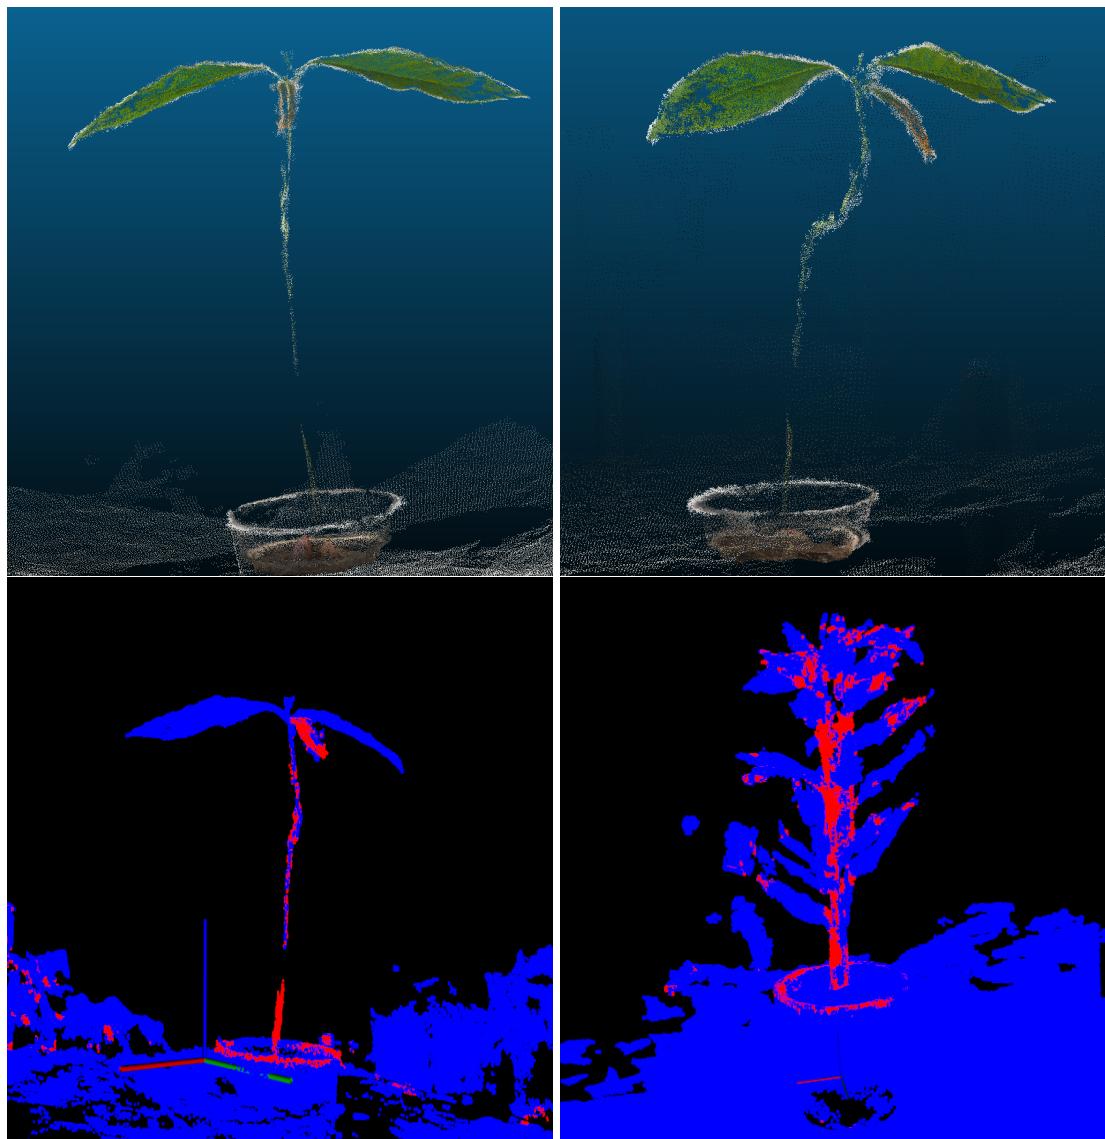


Abbildung 17: Oben: ODM Seitenansicht die als Ebene erkannten Stiel zeigt.
Unten: Segmentierungs-Ergebniss für zwei verschiedene Pflanzen mit dem selben Schwellwert.

	t11	t6	t10	t9	t4	t7	t12	t13
Loss	0,044	0.056	0.079	0.05	0.038	0.054	0.051	0.127
Genauigkeit	0,98	0.976	0.969	0.982	0.986	0.981	0.98	0.95
IoU	0.925	0.908	0.893	0.811	0.813	0.788	0.841	0.827

Tabelle 3: Evaluations-Ergebnisse der verschiedenen Netze. Links ohne Hintergrund. Rechts mit Hintergrund.

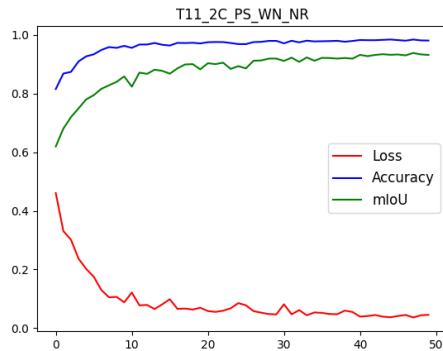


Abbildung 18: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen und Normalisierung ohne zufällige Rotationen

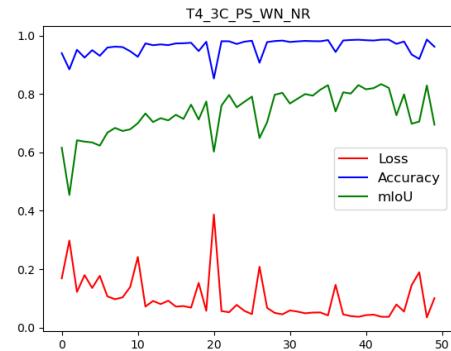


Abbildung 19: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen und Normalisierung ohne zufällige Rotationen

Richtung z-Achse zeigt. Auch sind die Punkte in der Punktfolge auf 1 normiert. Das heißt sie liegen in dem Raum den die beiden Punkte $(0, 0, 0)$ und $(1, 1, 1)$ bilden. Die Daten werden in einem Verhältnis 80 zu 10 zu 10 in Trainings-, Test- und Evaluations-Datensatz aufgeteilt.

Vergleich Training mit und ohne Hintergrund

In einem ersten Vergleich wird die Güte der Segmentierung zwischen dem Training mit und ohne Hintergrund verglichen. Die Ergebnisse des Trainings sind in Abbildung 18 und 19 zu sehen. Die Ergebnisse der Evaluation sind in Tabelle 3 zu sehen. Sowohl die Ergebnisse des Trainings, als auch die Ergebnisse der Evaluation zeigen deutlich, dass die Segmentierung ohne Hintergrund die besseren Ergebnisse liefert. Das wird vermutlich daran liegen, dass der Anteil der Punkte die zum Hintergrund gehören dominiert. Da die Segmentierung mit Hintergrund aber zur Entfernung des Hintergrundes benötigt wird, wird in einem zweiten Vergleich die Hintergrund-Segmentierung neu trainiert. Diesmal wird aber ein Großteil der Hintergrund-Punkte entfernt, indem nur das Zentrum der Punktfolge beim Training betrachtet wird. Die Ergebnisse sind in Abbildung 20 zu sehen. Wie in Abbildung 20 zu sehen ist verbessern sich die Ergebnisse für das Training mit weniger Hintergrund deutlich.

Vergleich Training mit und ohne Normalen

Um zu überprüfen ob sich der Einsatz von Normalen lohnt wird PointNet++ ohne Normalen trainiert und die Ergebnisse mit den Ergebnissen des Trainings mit Normalen

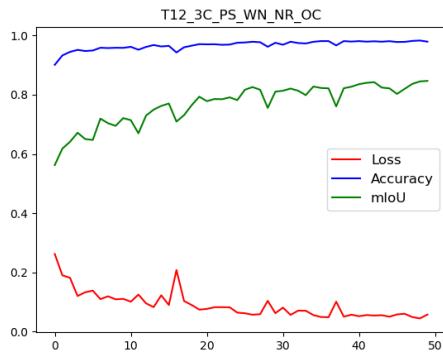


Abbildung 20: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen und Normalisierung ohne zufällige Rotationen. Mit Ausschnitt um das Zentrum.

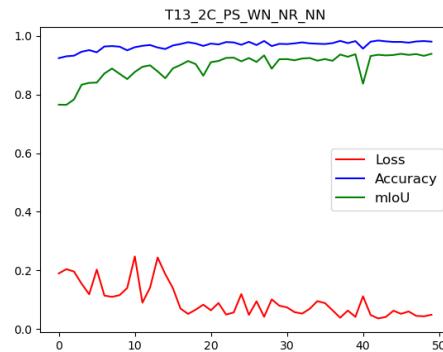


Abbildung 21: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen und Normalisierung ohne zufällige Rotationen. Ohne Normalen

(Abbildung 18) verglichen. Die Ergebnisse des Trainings ohne Normalen sind in Abbildung 21 zu sehen. Es ist ein kleiner Unterschied zum Training mit Normalen zu erkennen. Mit Normalen liefern die ersten Epochen zwar schlechtere Ergebnisse, aber nach einigen Epochen gleicht sich die Güte an und es kommt zudem zu weniger Ausreißern. Der Einsatz von Normalen scheint sich also in geringem Maß zu lohnen.

Vergleich Training mit und ohne Normalisierung

Es soll Überprüft werden ob PointNet++ mit oder ohne Normalisierung bessere Ergebnisse liefert. Des weiteren soll geprüft werden, ob auch nicht normalisierte Eingabe-Daten gute Segmentierungs-Ergebnisse liefern wenn PointNet++ mit normalisierten Daten trainiert wurde. Dieser Vergleich wird aufgestellt, da die Punktwolken für die Segmentierung auf eine bestimmte Anzahl Punkte reduziert werden und das Ergebniss - zumindest bei der Hintergrund-Segmentierung - zurück auf die vollständige Punktwolke übertragen werden muss. Muss die Punktwolke nicht normalisiert werden, kann das Ergebniss direkt auf die vollständige Punktwolke übertragen werden. Im Falle einer Normalisierung müsste diese erst umgekehrt werden, aber diese Information wird von PointNet++ nicht zur Verfügung gestellt und müsste ermittelt werden. Alternativ dazu könnten auch die Ergebnisse von der normalisierten Punktwolke auf die nicht normalisierte Punktwolke übertragen werden, was aber mit mehr Rechenaufwand verbunden ist.

Wird die Normalisierung komplett verhindert, kann das Auswirkungen auf die Güte der Ergebnisse der Segmentierung haben.

In Tabelle 4 werden die Ergebnisse der Evaluation von PointNet++ auf nicht normalisierten Daten nach dem Training mit normalisierten Daten verglichen. Da die Ergebnisse sich für die Segmentierung mit Hintergrund stark verschlechtern, wenn die Daten nicht normalisiert werden wird PointNet++ ohne Normalisierung erneut trainiert. Die Ergebnisse für das erneute Training sind in Abbildung 22 für zwei Klassen und in Abbildung 23 für drei Klassen zu sehen.

	t4 mit normalisiert Daten	t4 mit nicht normalisiert Daten	t11 mit normalisiert Daten	t11 mit nicht normalisiert Daten
Loss	0,038	0,175	0.044	0.044
Genauigkeit	0,986	0,946	0.98	0.98
IoU	0,81	0,684	0.926	0.925

Tabelle 4: Vergleich von Evaluations-Ergebnissen von den mit normalisierten Daten trainierten Netzen t4 (mit Hintergrund) und t11(ohne Hintergrund) mit jeweils normalisierten und nicht normalisierten Daten.

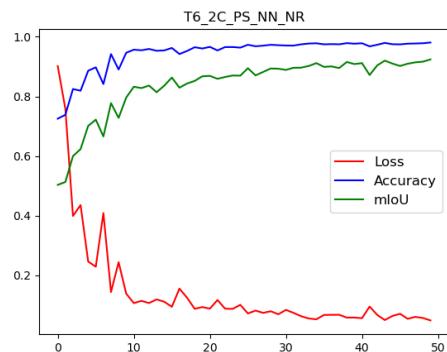


Abbildung 22: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen, ohne Normalisierung und ohne zufällige Rotationen

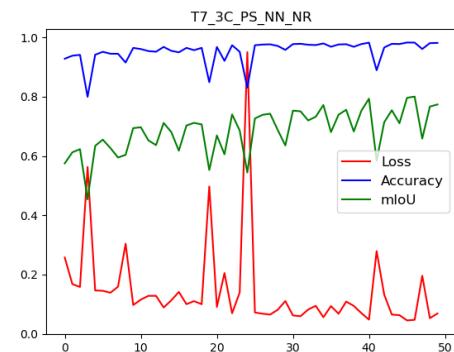


Abbildung 23: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen, ohne Normalisierung und ohne zufällige Rotationen

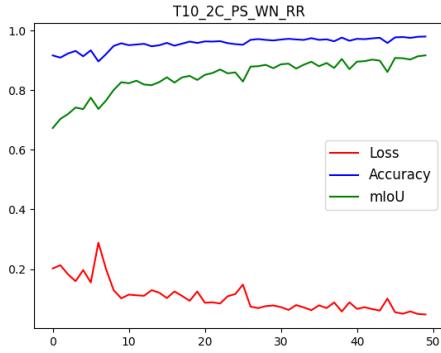


Abbildung 24: PointNet++ Trainings-Ergebnisse pro Epoche mit 2 Klassen, mit Normalisierung und zufälliger Rotationen

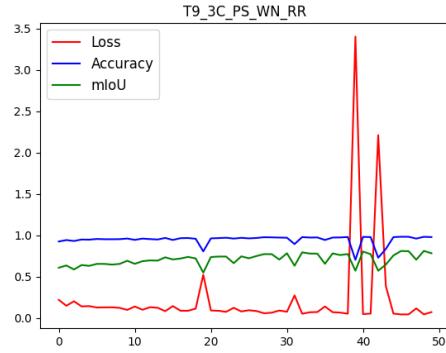


Abbildung 25: PointNet++ Trainings-Ergebnisse pro Epoche mit 3 Klassen, mit Normalisierung und zufälliger Rotationen

Gegenüber dem Training mit Normalisierung ist das Training ohne Normalisierung etwas schlechter. Insbesondere für das Netz mit drei Klassen haben die Ausreißer für Loss-, Accuracy- und IoU-Werte zugenommen. Das führt zu dem Schluss, dass PointNet++ mit Normalisierung genutzt werden sollte und der zusätzliche Rechenaufwand zum übertragen der Ergebnisse auf die vollständige Punktwolke in Kauf genommen werden sollte.

Vergleich Training mit und ohne zufällige Rotationen

Die Tests des Servers haben gezeigt, dass es bei der Segmentierung der freigestellten Pflanzen zu starken Fehlern kommt, wenn diese rotiert sind. Diese Fehler sind in Abbildung 26 und 27 zu sehen. Wird die Evaluation eines ohne zufällig rotierte Punktwolken trainierte Netz mit zufällig rotierten Punktwolken ausgeführt sinkt der IoU-Wert auf 0,6 und Accuracy auf 0,875. Das hat zu der Erkenntnis geführt, dass PointNet++ anfällig für die Ausrichtung von Punktwolken ist.

Aus diesem Grund wurde das Training für das zwei und drei Klassen-Netz mit zufälligen Rotationen wiederholt um eine Robustheit gegen Rotationen anzutrainieren. Die Ergebnisse für zwei Klassen-Netz ist in Abbildung 24 zu sehen. Die Ergebnisse für das 3 Klassen-Netz in Abbildung 25. Beim Training von dem Netz mit drei Klassen sind starke Ausreißer in den Loss-Werten zu erkennen die sich auch in der Accuracy und dem IoU - wenn auch nicht so stark - wiederspiegeln. Diese Beobachtung kann man bei dem anderen Netzen nur in wesentlich kleinerem Ausmaß feststellen. Dennoch sind die Ergebnisse wesentlich schlechter für das Training mit zufälligen Rotationen als das Training ohne. Im Einsatz sollt also bei der Entfernung des Hintergrundes darauf geachtet werden, dass dieser zumindest grob an der XY-Ebene ausgerichtet ist.

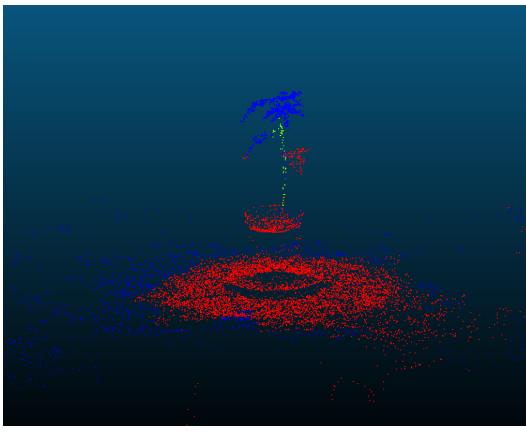


Abbildung 26: Fehlgeschlagene Segmentation einer Bananen-Pflanze. Verursacht durch Rotation der Punktwolke

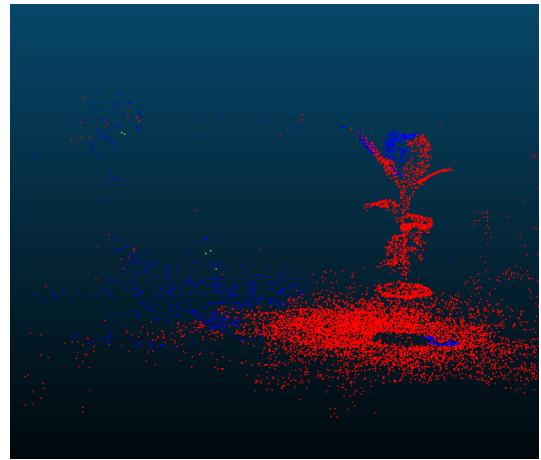


Abbildung 27: Fehlgeschlagene Segmentation einer Tomaten-Pflanze. Verursacht durch Rotation der Punktwolke

5 Fazit und Ausblick

Generierung der Punktwolken

Die Generierung von Punktwolken mit ODM liefert zwar gute Ergebnisse und ist vergleichsweise schnell. Allerdings ist es dennoch die Komponente die am meisten Laufzeit in Anspruch nimmt. Da keine Geo-Informationen zu den Bildern vorliegen, kann die GPU von ODM nicht eingesetzt werden. An der Stelle könnte ODM erweitert werden und die alternative Implementierung die ohne Geo-Informationen auskommt könnte parallelisiert werden.

Sollte sich in Zukunft bei Smartphones eine RGB-D Kamera als Standart etablieren, könnte diese Technologie genutzt werden um eine schnelle Generierung der Punktwolken zu ermöglichen.

Ein weiterer Ansatz der untersucht werden könnte ist die Generierung von Punktwolken mit Neuronalen Netzen. Hier gibt es einige interessante Ansätze die im Rahmen dieser Arbeit nicht untersucht wurden. Diese Ansätze ermöglichen es aus einem Bild eine Punktwolke zu generieren, was dem Ziel die zu übertragende Datenmenge gering zu halten entgegen kommt.

Registrierung

Die Ergebnisse der Registrierung sind zwar für den Zweck ausreichend, aber könnten zuverlässiger und genauer sein. Insbesondere die nicht bekannte Skalierung bereitet Probleme.

Bei der Datengewinnung könnte zu den Bildern auch eine GPS-Position ermittelt werden und so Punktwolken mit gleichem Maßstab erstellt werden. Das würde die Registrierung erleichtern, da die Skalierung nicht mehr geschätzt werden müsste.

Ein weiterer Ansatz der in dieser Arbeit nicht verfolgt wurde ist ScaleLK. ScaleLK hat eine ähnliche Architektur wie PoinNetLK allerdings wird neben Rotation und Transla-

tion auch eine Schätzung für die Skalierung liefert.

Segmentierung

Die Segmentierung ist für die Hintergrundentfernung noch recht fehleranfällig. Hier könnte probiert werden mit einem größerem Datensatz zu trainieren oder mehr Punkte während des Trainings zu nutzen.

Des weiteren kann die Segmentierung der Pflanze erweitert werden um zusätzliche Informationen über eine Pflanze zu erhalten. Zum Beispiel können neben Blättern und Stielen auch Blüten und Früchte erkannt werden, was für die Analyse des Ertrags einer Fruchtfolge genutzt werden könnte. Um das zu bewerkstelligen muss für jedes Merkmal ein weiters Label hinzugefügt werden und die Datenbasis, die für das Training genutzt wird, um Punktwolken erweitert werden die diese Merkmale auch beinhalten.

Server

Um die Perfomance des Servers zu steigern könnte für die in c++ Implementierten Funktionalitäten ein Python-Binding erstellt werden. Bisher werden diese Funktionen über System-Kommandos angesteuert. Mit einem Python-Binding könnten diese direkt aus dem Python-Code angesprochen werden. Dadurch könnten die Daten zwischen den einzelnen Pipelines im Hauptspeicher gehalten werden und müssten nur noch zu Persistierungs-Zwecken auf der Festplatte abgelegt werden.

Da der Server keine Sicherheitsmechanismen zur Verfügung stellt ist von einem Einsatz in der Praxis in diesem Zustand abzuraten. Es sollte mindestens ein User-Management hinzugefügt werden um die Schnittstellen vor Missbrauch zu schützen.

Literatur

- [1] I. Masih, S. Maskey, F. Mussá, and P. Trambauer, “A review of droughts on the african continent: A geospatial and long-term perspective,” *Hydrology and Earth System Sciences*, vol. 18, pp. 3635–3649, 09 2014.
- [2] N. Mehendale and S. Neoge, “Review on lidar technology,” *ssrn preprint ssrn:3604309*, 2020.
- [3] A. Taneja, “Top 10 smartphones with a dedicated depth sensor camera to capture perfect bokeh shots,” 2020.
- [4] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *International journal of computer vision*, vol. 60, no. 2, pp. 91–110, 2004.
- [5] H. Bay, A. Ess, T. Tuytelaars, and L. Van Gool, “Speeded-up robust features (surf),” *Computer vision and image understanding*, vol. 110, no. 3, pp. 346–359, 2008.
- [6] M. Calonder, V. Lepetit, C. Strecha, and P. Fua, “Brief: Binary robust independent elementary features,” in *European conference on computer vision*, pp. 778–792, Springer, 2010.
- [7] E. Rublee, V. Rabaud, K. Konolige, and G. Bradski, “Orb: An efficient alternative to sift or surf,” in *2011 International conference on computer vision*, pp. 2564–2571, Ieee, 2011.
- [8] J. L. Schönberger and J.-M. Frahm, “Structure-from-motion revisited,” 2016.
- [9] J. L. Schönberger, E. Zheng, M. Pollefeys, and J.-M. Frahm, “Pixelwise View Selection for Unstructured Multi-View Stereo,” in *European Conference on Computer Vision (ECCV)*, 2016.
- [10] pierotofy, “Open drone map - a command line toolkit to generate maps, point clouds, 3d models and dems from drone, balloon or kite images.,” 2020.
- [11] alalek, “Structure from motion module,” 2016.
- [12] P. Moulon, P. Monasse, and R. Marlet, “Adaptive structure from motion with a contrario model estimation,” in *Proceedings of the Asian Computer Vision Conference (ACCV 2012)*, pp. 257–270, Springer Berlin Heidelberg, 2012.
- [13] M. Jancosek and T. Pajdla, “Multi-view reconstruction preserving weakly-supported surfaces,” in *CVPR 2011*, IEEE, jun 2011.
- [14] P. Moulon, P. Monasse, R. Perrot, and R. Marlet, “Openmvg: Open multiple view geometry,” in *International Workshop on Reproducible Research in Pattern Recognition*, pp. 60–74, Springer, 2016.
- [15] R. Arandjelović and A. Zisserman, “Three things everyone should know to improve object retrieval,” in *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2911–2918, IEEE, 2012.

- [16] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [17] H. Fan, H. Su, and L. Guibas, “A point set generation network for 3d object reconstruction from a single image,” 2016.
- [18] M. Tatarchenko, A. Dosovitskiy, and T. Brox, “Octree generating networks: Efficient convolutional architectures for high-resolution 3d outputs,” 2017.
- [19] N. Wang, Y. Zhang, Z. Li, Y. Fu, W. Liu, and Y.-G. Jiang, “Pixel2mesh: Generating 3d mesh models from single rgb images,” 2018.
- [20] Y. Xia, C. Wang, Y. Xu, Y. Zang, W. Liu, J. Li, and U. Stilla, “Realpoint3d: Generating 3d point clouds from a single image of complex scenarios,” *Remote Sensing*, vol. 11, no. 22, 2019.
- [21] I. Ziamtsov and S. Navlakha, “Machine Learning Approaches to Improve Three Basic Plant Phenotyping Tasks Using Three-Dimensional Point Clouds1[OPEN],” *Plant Physiology*, vol. 181, pp. 1425–1440, 10 2019.
- [22] W. Gélard, M. Devy, A. Herbulet, and P. Burger, “Model-based segmentation of 3d point clouds for phenotyping sunflower plants,” in *12. International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications*, 2017.
- [23] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, “Pointnet: Deep learning on point sets for 3d classification and segmentation,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 652–660, 2017.
- [24] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, “Pointnet++: Deep hierarchical feature learning on point sets in a metric space,” *arXiv preprint arXiv:1706.02413*, 2017.
- [25] Y. Wang, Y. Sun, Z. Liu, S. E. Sarma, M. M. Bronstein, and J. M. Solomon, “Dynamic graph cnn for learning on point clouds,” *ACM Transactions on Graphics (TOG)*, 2019.
- [26] P. J. Besl and N. D. McKay, “Method for registration of 3-d shapes,” in *Sensor fusion IV: control paradigms and data structures*, vol. 1611, pp. 586–606, International Society for Optics and Photonics, 1992.
- [27] J. Yang, H. Li, D. Campbell, and Y. Jia, “Go-icp: A globally optimal solution to 3d icp point-set registration,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, p. 2241–2254, Nov 2016.
- [28] J. Zhang, Y. Yao, and B. Deng, “Fast and robust iterative closest point,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021.
- [29] K. Derpanis, “Overview of the ransac algorithm,” 2005.
- [30] T. Zinßer, J. Schmidt, and H. Niemann, “Point set registration with integrated scale estimation,” in *Point Set Registration with Integrated Scale Estimation*, 2005.

- [31] S. Xu and Y. Shang, “ScaleLK: Registration of point clouds with different scales using deep learning methods,” *IOP Conference Series: Materials Science and Engineering*, vol. 768, p. 072089, mar 2020.
- [32] Y. Wang and J. M. Solomon, “Deep closest point: Learning representations for point cloud registration,” in *The IEEE International Conference on Computer Vision (ICCV)*, October 2019.
- [33] Y. Aoki, H. Goforth, R. A. Srivatsan, and S. Lucey, “Pointnetlk: Robust and efficient point cloud registration using pointnet,” 2019.
- [34] Z. J. Yew and G. H. Lee, “Rpm-net: Robust point matching using learned features,” *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun 2020.
- [35] W. Yuan, B. Eckart, K. Kim, V. Jampani, D. Fox, and J. Kautz, “Deepgmr: Learning latent gaussian mixture models for registration,” 2020.
- [36] Y. Wang and J. M. Solomon, “Prnet: Self-supervised learning for partial-to-partial registration,” 2019.
- [37] V. Sarode, X. Li, H. Goforth, Y. Aoki, R. A. Srivatsan, S. Lucey, and H. Choset, “Pcrnet: Point cloud registration network using pointnet encoding,” 2019.
- [38] B. Lucas and T. Kanade, “An iterative image registration technique with an application to stereo vision (ijcai),” vol. 81, 04 1981.
- [39] S. Gold, C.-P. Lu, A. Rangarajan, S. Pappu, and E. Mjolsness, “New algorithms for 2d and 3d point matching: Pose estimation and correspondence,” *Advances in neural information processing systems*, pp. 957–964, 1995.
- [40] R. Hänsch, T. Weber, and O. Hellwich, “Comparison of 3d interest point detectors and descriptors for point cloud fusion,” *ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. II-3, 09 2014.
- [41] R. Sears, C. Van Ingen, and J. Gray, “To blob or not to blob: Large object storage in a database or a filesystem?,” *arXiv preprint cs/0701168*, 2007.
- [42] V. Sarode, “Learning3d: A modern library for deep learning on 3d point clouds data.,” 2021.
- [43] Q.-Y. Zhou, J. Park, and V. Koltun, “Open3d: A modern library for 3d data processing,” *arXiv preprint arXiv:1801.09847*, 2018.